EKONOMICKÁ UNIVERZITA V BRATISLAVE
NÁRODOHOSPODÁRSKA FAKULTA

Evidenčné číslo: 101006/I/2026/36161546575830276

METÓDY VYSVETLITEĽNEJ UMELEJ INTELIGENCIE V MODELOVANÍ ZLYHANIA FIRIEM NA SLOVENSKU

DIPLOMOVÁ PRÁCA

2026 **Bc. Matej Kovacs**

EKONOMICKÁ UNIVERZITA V BRATISLAVE
NÁRODOHOSPODÁRSKA FAKULTA

METÓDY VYSVETLITEĽNEJ UMELEJ INTELIGENCIE V MODELOVANÍ ZLYHANIA FIRIEM NA SLOVENSKU

DIPLOMOVÁ PRÁCA

Študijný program: Financie a dane

Školiace pracovisko: Katedra financií

Vedúci záverečnej práce: doc. Mgr. Marek Káčer, PhD.

Bratislava, 2026 **Bc. Matej Kovacs**





Ekonomická univerzita v Bratislave
Národohospodárska fakulta

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Matej Kovács
Študijný program: financie a dane (jednoodborové štúdium, inžiniersky II. st., externá forma)
Študijný odbor: ekonómia a manažment
Typ záverečnej práce: Inžinierska záverečná práca
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Metódy vysvetliteľnej umelej inteligencie v modelovaní zlyhania firiem na SLovensku

Anotácia: Vhodne natrénované metódy umelej inteligencie vďaka svojej väčšej flexibilite, ale aj komplexnosti, dosahujú v porovnaní so štatistickými metódami vyššiu presnosť predikcie. Ich transparentnosť je však výrazne nižšia. Metódy vysvetliteľnej umelej inteligencie (XAI), prípadne interpretovateľného strojového učenia (IML) sa zameriavajú práve na poskytnutie hlbšieho vhľadu do fungovania metód umelej inteligencie. V slovenskej literatúre podobne zamerané štúdie takmer úplne absentujú. Úlohou práce bude na vzorke slovenských firiem použiť zvolenú techniku a porovnať výsledky s logistickou regresiou.

Vedúci: doc. Mgr. Marek Káčer, PhD.
Katedra: KF NHF - Katedra financií
Vedúci katedry: doc. Ing. Juraj Válek, PhD.

Dátum zadania: 01.03.2025

Dátum schválenia: 10.04.2025

doc. Ing. Jana Péliová, PhD.
osoba zodpovedná za realizáciu študijného programu

PREHLÁSENIE

Čestne prehlasujem, že som predloženú písomnú prácu spracoval s použitím uvedenej literatúry.

V Bratislave, ...

Podpis

POĎAKOVANIE

Na tomto mieste by som sa chcel poďakovať vedúcemu mojej diplomovej práce doc. Mgr. Marekovi Káčerovi, PhD., za odborné vedenie, cenné pripomienky, metodické usmernenie a čas, ktorý mi venoval počas spracovania tejto práce.

Osobitné poďakovanie patrí mojej drahej priateľke za neustálu podporu, trpezlivosť, pochopenie a starostlivosť počas obdobia písania tejto práce. Jej povzbudenie a opora pre mňa znamenali veľmi veľa a pomohli mi zvládnuť aj náročnejšie chvíle spojené so štúdiom a spracovaním diplomovej práce.

Zároveň by som sa chcel poďakovať svojej rodine a blízkym za podporu, porozumenie a povzbudenie počas celého štúdia. Ich pomoc a dôvera boli pre mňa dôležitou oporou.

ABSTRAKT

KOVÁCS, Matej: *Metódy vysvetliteľnej umelej inteligencie v modelovaní zlyhania firiem na Slovensku.* - Ekonomická univerzita v Bratislave, Národohospodárska fakulta, Katedra financií. - Vedúci záverečnej práce: doc. Mgr. Marek Káčer, PhD. - Bratislava: NHF EU, 2026, počet strán 94.

Diplomová práca sa zaoberá využitím metód vysvetliteľnej umelej inteligencie pri predikcii zlyhania slovenských podnikov. Cieľom práce je empiricky posúdiť, či moderné prístupy XAI dokážu zlepšiť diskriminačnú schopnosť a interpretovateľnosť predikčných modelov v porovnaní s tradičnou logistickou regresiou. Analýza vychádza z účtovných údajov slovenských podnikov z Registra účtovných závierok za obdobie rokov 2011 až 2019. Zlyhanie podniku je definované ako vstup do konkurzu alebo reštrukturalizácie v nasledujúcom období. Výskumná časť porovnáva tri modelové prístupy: logistickú regresiu ako transparentný ekonometrický referenčný štandard, Explainable Boosting Machine ako vnútorne interpretovateľný nelineárny model a sekvenčný model BiLSTM doplnený o SHAP vysvetlenia. Modely sú hodnotené na testovacom období rokov 2018 až 2019 pomocou metrík ROC-AUC, PR-AUC, KS štatistiky, Brierovho skóre a top-k capture analýzy. Výsledky ukazujú, že najvyššiu diskriminačnú schopnosť dosahuje model EBM s hodnotou ROC-AUC 0,882, PR-AUC 0,028 a KS štatistikou 0,611. EBM zároveň v horných 5 % najrizikovejších podnikov zachytáva viac ako polovicu budúcich zlyhaní. BiLSTM prináša dodatočnú hodnotu najmä v časovej interpretácii rizikových signálov, no jeho výkonnosť nie je štatisticky významne vyššia než výkonnosť logistickej regresie. Práca dospieva k záveru, že vysvetliteľné nelineárne modely môžu pri predikcii zlyhania slovenských podnikov priniesť lepší kompromis medzi predikčnou výkonnosťou, transparentnosťou a praktickou využiteľnosťou než tradičné lineárne modely.

Kľúčové slová: zlyhanie podnikov, vysvetliteľná umelá inteligencia, Explainable Boosting Machine, logistická regresia, BiLSTM, SHAP, kreditné riziko, predikčné modelovanie

ABSTRACT

KOVÁCS, Matej: Methods of Explainable Artificial Intelligence in Modeling Corporate Failure in Slovakia. – University of Economics in Bratislava, Faculty of Economics and Finance, Department of Finance. – Thesis supervisor: doc. Mgr. Marek Káčer, PhD. – Bratislava: FEF UEBA, 2026, number of pages 94.

This diploma thesis examines the application of explainable artificial intelligence methods to the prediction of corporate failure in Slovakia. The main objective is to assess whether modern XAI approaches can improve both the discriminatory performance and interpretability of bankruptcy prediction models compared with traditional logistic regression. The empirical analysis is based on firm-level accounting data from the Slovak Register of Financial Statements covering the period from 2011 to 2019. Corporate failure is defined as a firm entering bankruptcy or restructuring proceedings in the following period. The empirical part compares three modeling approaches: logistic regression as a transparent econometric benchmark, Explainable Boosting Machine as an inherently interpretable nonlinear model, and a sequential BiLSTM model complemented with SHAP explanations. The models are evaluated on a test period covering 2018 and 2019 using ROC-AUC, PR-AUC, the Kolmogorov-Smirnov statistic, Brier score and top-k capture analysis. The results show that the Explainable Boosting Machine achieves the strongest performance, with a ROC-AUC of 0.882, PR-AUC of 0.028 and KS statistic of 0.611. In addition, the model captures more than half of all future failures within the top 5% of firms ranked as most risky. The BiLSTM model provides additional value mainly through the temporal interpretation of risk signals, but its discriminatory performance is not statistically significantly higher than that of the logistic benchmark. The thesis concludes that explainable nonlinear models can provide a better trade-off between predictive accuracy, transparency and practical applicability in corporate failure prediction than traditional linear models.

Key words: corporate failure, explainable artificial intelligence, Explainable Boosting Machine, logistic regression, BiLSTM, SHAP, credit risk, predictive modeling

ZOZNAM SKRATIEK

Skratka	Význam
AI	Artificial Intelligence - Umelá inteligencia
AUC	Area Under Curve - Plocha pod krivkou
BiLSTM	Bidirectional Long Short-Term Memory - Obojsmerná RNN
BPTT	Backpropagation Through Time
CNN	Convolutional Neural Network - Konvolučná neurónová sieť
DNN	Deep Neural Network - Hlboká neurónová sieť
EBM	Explainable Boosting Machine - Vnútorne interpretovateľný model
FAST	Algoritmus na automatickú detekciu významných interakcií v EBM
GA2M	Generalized Additive Model plus Interactions
GAM	Generalized Additive Model - Zovšeobecnený aditívny model
KS	Kolmogorov-Smirnov štatistika
LIME	Local Interpretable Model-agnostic Explainations
LSTM	Long Short-Term Memory
MLE	Maximum Likelihood Estimation
NN	Neural Network - Neurónová sieť
p-hodnota	Pravdepodobnostná hodnota štatistického testu
PR-AUC	Area Under the Precision-Recall Curve
RNN	Recurrent Neural Network - Rekurentná neurónová sieť
ROA	Rentabilita aktív
ROC-AUC	Area Under the Receiver Operating Characteristic Curve
ROS	Rentabilita tržieb
RÚZ	Register účtovných závierok
RUS	Random UnderSampling - Náhodné podvzorkovanie
SHAP	SHapley Additive exPlanations
SME	Malé a stredné podniky
VIF	Variance Inflation Factor
XAI	Explainable Artificial Intelligence - Vysvetliteľná umelá inteligencia

OBSAH

Úvod 11
1 Literárny prehľad 13
1.1 Teoretické východiská modelovania zlyhania firiem 13
1.1.1 Vymedzenie zlyhania podniku a špecifiká slovenského prostredia 13
1.1.2 Vývoj prístupov k modelovaniu zlyhania 15
1.1.3 Nástup strojového učenia a potreba nelinearity 16
1.1.4 Finančné a nefinančné ukazovatele zlyhania podniku 17
1.1.5 Manažment nevyváženosti dát v klasifikačných úlohách 20
1.2 Vysvetliteľná umelá inteligencia (XAI) 22
1.2.1 Koncept vysvetliteľnosti v umelej inteligencii 23
1.2.2 Základné členenie metód XAI 23
1.2.3 Sekvenčné modelovanie a post-hoc vysvetliteľnosť: RNN/LSTM modely so SHAP interpretáciou 25
1.2.4 Vnútorne interpretovateľné modelovanie: Explainable Boosting Machine 26
1.2.5 Vymedzenie metodického rámca práce 28
1.3 Aplikácia XAI vo finančnom modelovaní 28
1.3.1 Význam vysvetliteľnosti vo finančnom rozhodovaní 29
1.3.2 Regulačné požiadavky a dôvera v automatizované rozhodovanie 30
1.3.3 Oblasti využitia XAI vo finančnom modelovaní 31
1.4 Súčasný stav poznania v modelovaní bankrotu 32
1.4.1 Logistická regresia ako referenčný štandard 33
1.4.2 Prístup Black-box s post-hoc vysvetliteľnosťou: RNN a SHAP 34
1.4.3 Glass-box prístup novej generácie: Explainable Boosting Machine 35
1.4.4 Syntéza poznatkov a identifikácia výskumnej medzery 36
2 Cieľ práce 39
3 Metodika a metódy skúmania 40
3.1 Výskumný dizajn a metodický rámec 40
3.2. Dáta a príprava datasetu 41
3.3 Modelové metódy 46
3.3.1 Logistická regresia 47
3.3.2 Explainable boosting machine 49

3.3.3 BiLSTM 50
3.4 Nevyváženosť tried a ich ošetrenie 52
3.5 Ladenie hyperparametrov a výber finálnych modelov 54
3.6 Metódy hodnotenia modelov a interpretácie výsledkov 56
3.7 Softvérové prostredie a reprodukovateľnosť 60
4 Výsledky práce 62
4.1 Výsledky logistickej regresie 62
4.2 Výsledky modelu Explainable Boosting Machine 67
4.3 Výsledky modelu BiLSTM 74
4.4 Porovnanie modelov a zhodnotenie výskumnej otázky 81
5 Diskusia 85
Záver 88
Zoznam literatúry 89

Úvod

Schopnosť včas identifikovať podniky ohrozené finančným zlyhaním patrí medzi dôležité úlohy finančného manažmentu, bankovníctva a riadenia rizík. Zlyhanie podniku nemá dôsledky iba pre vlastníkov a manažment konkrétnej firmy, ale môže ovplyvniť aj veriteľov, dodávateľsko-odberateľské vzťahy, zamestnanosť a stabilitu podnikateľského prostredia. Modely včasného varovania preto predstavujú nástroj, ktorý umožňuje identifikovať rizikové podniky ešte pred ich formálnym vstupom do konkurzu alebo reštrukturalizácie. Predikcia zlyhania podnikov má v ekonomickej literatúre dlhú tradíciu. Medzi najpoužívanejšie prístupy patrí logistická regresia, ktorá si zachováva význam najmä vďaka transparentnosti, jednoduchej interpretácii koeficientov a ekonomickej obhájiteľnosti. Jej obmedzením je však predpoklad lineárneho vzťahu medzi vysvetľujúcimi premennými a pravdepodobnosťou zlyhania. Finančné ukazovatele pritom často pôsobia nelineárne a ich význam sa môže meniť v závislosti od veľkosti, veku, odvetvia alebo celkovej finančnej situácie podniku.

Rozvoj strojového učenia a umelej inteligencie umožnil tieto obmedzenia čiastočne prekonať. Moderné algoritmy dokážu zachytiť nelineárne vzťahy, interakcie medzi premennými a zložité vzory v rozsiahlych dátach. Ich nevýhodou však býva nižšia transparentnosť, čo je vo finančnom sektore zásadný problém. Pri modelovaní kreditného a bankrotového rizika totiž nestačí iba presná predikcia, ale dôležité je aj vysvetliť, ktoré faktory k riziku prispeli a či sú výsledky ekonomicky interpretovateľné. Z tohto dôvodu nadobúdajú význam metódy vysvetliteľnej umelej inteligencie, ktoré sa usilujú spojiť predikčnú výkonnosť s transparentnosťou modelového rozhodovania. Táto diplomová práca sa zameriava na aplikáciu metód vysvetliteľnej umelej inteligencie pri modelovaní zlyhania firiem na Slovensku. Analýza vychádza z účtovných údajov slovenských podnikov za roky 2011 až 2019, pričom zlyhanie je definované ako vstup podniku do konkurzu alebo reštrukturalizácie v nasledujúcom období. Slovenské prostredie je pre takýto výskum vhodné najmä vďaka dostupnosti údajov z Registra účtovných závierok, vysokému podielu malých a stredných podnikov a extrémne nízkej miere formálne pozorovaných zlyhaní.

Hlavným cieľom práce je posúdiť, do akej miery dokážu metódy vysvetliteľnej umelej inteligencie zlepšiť presnosť a interpretovateľnosť predikcie zlyhania slovenských firiem v porovnaní s tradičnou logistickou regresiou. Práca porovnáva tri modelové prístupy: logistickú regresiu ako transparentný ekonometrický referenčný štandard, *Explainable Boosting Machine* ako nelineárny *glass-box* model a sekvenčný BiLSTM model doplnený o

SHAP vysvetlenia. Modely sú hodnotené na samostatnej testovacej vzorke rokov 2018 až 2019, čím sa zachováva chronologický charakter predikčnej úlohy a obmedzuje riziko informačného úniku. Práca je členená do piatich častí. Prvá kapitola predstavuje teoretické východiská modelovania zlyhania podnikov a vysvetliteľnej umelej inteligencie. Druhá kapitola formuluje cieľ práce. Tretia kapitola opisuje dáta, metodický postup a použité modely. Štvrtá kapitola prezentuje a porovnáva výsledky analýz. Záverečná kapitola diskutuje hlavné zistenia, limity práce a možnosti ďalšieho výskumu.

1 Literárny prehľad

1.1 Teoretické východiská modelovania zlyhania firiem

Schopnosť včas identifikovať signály hroziacej finančnej tiesne patrí medzi kľúčové výzvy finančného manažmentu, veriteľov a regulačných orgánov. Problematika predikcie zlyhania firiem prešla za posledných päť desaťročí výrazným vývojom, od jednoduchých analytických ukazovateľov až po sofistikované modely umelej inteligencie. Cieľom tejto kapitoly je vymedziť teoretický rámec zlyhania podniku so zreteľom na špecifiká slovenského ekonomického prostredia, analyzovať historický vývoj predikčných metód a identifikovať metodologické výzvy spojené so spracovaním finančných dát.

1.1.1 Vymedzenie zlyhania podniku a špecifiká slovenského prostredia

V odbornej literatúre neexistuje jednotná a univerzálne akceptovaná definícia zlyhania podniku. Ide o mnohorozmerný pojem, ktorého výklad sa líši v závislosti od toho, či je posudzovaný z pohľadu ekonomickej efektívnosti alebo právneho statusu. V kontexte predikčného modelovania využívajúceho metódy strojového učenia predstavuje jednoznačné a presné definovanie cieľovej premennej (*target variable*) kľúčovú podmienku validity dosiahnutých výsledkov (Fasano et al., 2025).

Z ekonomického hľadiska je zlyhanie podniku často interpretované ako neschopnosť efektívne zhodnocovať vložený kapitál, čo však nemusí nevyhnutne viesť k jeho bezprostrednému zániku. Na trhu môžu dlhodobo pretrvávať aj ekonomicky neefektívne subjekty, pokiaľ sú podporované externými zdrojmi financovania. Na druhej strane, zánik podniku nemusí automaticky znamenať jeho zlyhanie, keďže môže ísť o dobrovoľnú likvidáciu alebo fúziu, ktoré môžu predstavovať racionálnu voľbu z pohľadu vlastníkov (Wilson et al., 2014).

Pre potreby empirického výskumu v podmienkach Slovenskej republiky je najvhodnejšie vychádzať z právnej definície úpadku, ktorá je ukotvená v Zákone č. 7/2005 Z. z. o konkurze a reštrukturalizácii (Zákon č. 7/2005 Z. z., 2005). Podľa platnej legislatívy sa rozlišujú dve formy úpadku a naplnenie ktorejkoľvek z nich je postačujúce na označenie firmy za zlyhanú. Prvou formou je platobná neschopnos, ktorá predstavuje stav, keď dĺžnik nie je schopný plniť svoje peňažné záväzky. V prípade právnickej osoby ide najmä o neschopnosť uhradiť aspoň dva peňažné záväzky po lehote splatnosti dlhšej ako 90 dní voči

viacerým veriteľom, zatiaľ čo pri fyzickej osobe ide o neschopnosť splniť aspoň jeden peňažný záväzok po lehote splatnosti dlhšej ako 180 dní. Druhou formou úpadku je predlženosť, ktorá nastáva vtedy, keď účtovná jednotka s viac ako jedným veriteľom má hodnotu záväzkov vyššiu než hodnotu svojho majetku, pričom hodnotenie vychádza z účtovníctva alebo zo znaleckého posudku a nezahŕňa podriadené záväzky.

Pri modelovaní zlyhania slovenských firiem je nutné zohľadniť špecifický historický vývoj slovenskej ekonomiky. Slovensko má relatívne krátku históriu trhovej ekonomiky, sprevádzanú dynamickými procesmi „vzniku a zániku" podnikov typickými pre obdobie po rozsiahlej privatizácii štátnych podnikov v 90. rokoch. Ako uvádzajú Wilson a kol., práve rýchla tvorba nového súkromného sektora po roku 1990 a následný *creation and destruction* cyklus v post-privatizačnom období výrazne formovali podnikateľské prostredie na Slovensku (Wilson et al., 2014).

Významným faktorom ovplyvňujúcim pravdepodobnosť prežitia firiem na Slovensku je vlastnícka štruktúra. Empirické dôkazy naznačujú, že firmy so zahraničnou majetkovou účasťou vykazujú nižšiu mieru zlyhania vďaka lepšiemu prístupu ku kapitálu, „*know-how*" a externým trhom. Naopak, malé domáce podniky bez zahraničného zázemia sú spravidla náchylnejšie na cyklické výkyvy ekonomiky a vonkajšie faktory. Tieto štrukturálne špecifiká naznačujú, že modely predikcie zlyhania firiem vyvinuté na vyspelých západných trhoch nemusia byť bez úprav plne aplikovateľné na slovenské dáta. Premenné zachytávajúce pôvod firmy alebo zahraničné vlastníctvo by mohli mať dodatočnú informačnú hodnotu, avšak vzhľadom na dátovú dostupnosť sa táto práca sústreďuje najmä na účtovné, odvetvové, veľkostné, vekové a makroekonomické premenné. Uvedené závery potvrdzujú aj novšie výskumy. Baumöhl a kol. vo svojej analýze firiem v nových členských krajinách Európskej únie, vrátane Slovenska, zistili, že zahraničné vlastníctvo a silná finančná výkonnosť významne zvyšujú šance na prežitie podnikov. Tieto zistenia zdôrazňujú, že charakteristiky vyplývajúce z historickej ekonomickej transformácie Slovenska zostávajú dôležité pri hodnotení rizika zlyhania firiem aj v súčasnosti (Baumöhl et al., 2020).

Z hľadiska implementácie metód umelej inteligencie v empirickom výskume predstavuje Slovenská republika špecifickú komparatívnu infraštruktúrnu výhodu v podobe Registra účtovných závierok (RÚZ). Na rozdiel od viacerých vyspelých ekonomík, v ktorých sú detailné finančné výkazy malých a stredných podnikov často neverejné alebo dostupné len prostredníctvom komerčných databáz, slovenský legislatívny rámec zabezpečuje ich systematickú verejnú dostupnosť a digitalizáciu. RÚZ, spravovaný Ministerstvom financií

Slovenskej republiky, tak poskytuje centralizovaný a štandardizovaný prístup k rozsiahlym štruktúrovaným finančným údajom pokrývajúcim prakticky celú populáciu podnikateľských subjektov. Vysoká miera transparentnosti a dátovej dostupnosti tým vytvára priaznivé podmienky na aplikáciu algoritmov s vysokými nárokmi na objem dát, vrátane pokročilých metód strojového učenia a hlbokých neurónových sietí. Zároveň umožňuje realizovať modelovanie na úrovni celej populácie namiesto obmedzených výberových súborov, čo zvyšuje robustnosť, stabilitu a generalizačnú schopnosť výsledných modelov predikcie zlyhania podnikov.

1.1.2 Vývoj prístupov k modelovaniu zlyhania

História predikcie zlyhania firiem sa začala písať v 60. rokoch 20. storočia a prešla tromi hlavnými vývojovými fázami.

Za priekopnícku prácu v oblasti predikcie podnikových zlyhaní sa považuje štúdia Beavera, ktorá skúmala schopnosť jednotlivých finančných ukazovateľov rozlišovať medzi prosperujúcimi a zlyhanými podnikmi. Hoci tento prístup potvrdil informačnú a signálnu hodnotu finančných výkazov, jeho zásadným obmedzením bola nemožnosť komplexného posúdenia finančnej situácie podniku. Firma totiž mohla vykazovať priaznivé hodnoty v jednej oblasti (napr. likvidita), zatiaľ čo v inej (napr. rentabilita) dosahovala neuspokojivé výsledky, čo viedlo k nejednoznačným alebo zavádzajúcim záverom (Beaver, 1966).

Významný metodologický posun priniesol Altman zavedením Z-skóre, ktoré bolo založené na viacrozmernej diskriminačnej analýze. Tento prístup umožnil spojiť viaceré finančné ukazovatele do jedného súhrnného indexu, na základe ktorého bolo možné podniky zaradiť do pásma prosperity, sivej zóny alebo pásma bankrotu. Altmanov model sa na dlhé obdobie stal štandardom v oblasti predikcie zlyhania firiem. Jeho využitie je však podmienené splnením viacerých prísnych štatistických predpokladov, ako sú normalita údajov, rozdelenie dát a lineárne vzťahy medzi premennými. Tieto predpoklady však reálne finančné údaje často nespĺňajú (Altman, 1968; Eisenbeis, 1977).

V 80. rokoch sa dominantnou metodologickou alternatívou stala logistická regresia. V porovnaní s viacrozmernou diskriminačnou analýzou sa vyznačuje menej prísnymi predpokladmi a zároveň umožňuje interpretovať výstup modelu ako pravdepodobnosť zlyhania podniku v intervale od 0 do 1. Logistická regresia dodnes predstavuje „zlatý štandard" v bankovníctve aj akademickom výskume, a to predovšetkým vďaka vysokej miere interpretovateľnosti. Regresné koeficienty umožňujú priamo kvantifikovať vplyv

jednotlivých finančných ukazovateľov na riziko bankrotu, ako to vo svojej práci ukázal už Ohlson. Aj preto logistická regresia v súčasnom výskume často slúži ako referenčný model, voči ktorému sa porovnáva výkonnosť modernejších metód umelej inteligencie (Barboza, 2017; Ohlson, 1980).

1.1.3 Nástup strojového učenia a potreba nelinearity

Napriek tomu, že logistická regresia patrí medzi najčastejšie využívané metódy pri predikcii zlyhania podnikov, súčasná odborná literatúra poukazuje na jej viaceré obmedzenia v podmienkach modernej ekonomiky. Tradičné štatistické modely totiž spravidla vychádzajú z predpokladu lineárnych vzťahov medzi vysvetľujúcimi premennými a pravdepodobnosťou zlyhania. V reálnom podnikateľskom prostredí sú však tieto vzťahy často nelineárne a závislé od širšieho kontextu. Ako uvádzajú Fasano a kol., vplyv jednotlivých finančných ukazovateľov na riziko zlyhania sa môže meniť v závislosti od situácie podniku. Napríklad vysoká zadlženosť môže byť pri rýchlo rastúcom podniku ešte udržateľná, zatiaľ čo pri podniku v stagnácii alebo poklese môže predstavovať závažný rizikový faktor (Fasano et al., 2025).

Rozvoj metód strojového učenia umožnil prekonať viaceré limity tradičných štatistických prístupov k predikcii zlyhania podnikov. Algoritmy, ako sú neurónové siete, rozhodovacie stromy alebo metódy gradientného zosilňovania (*Gradient Boosting*), dokážu automaticky identifikovať zložité nelineárne vzory, interakcie medzi premennými a skryté štruktúry v dátach bez potreby ich explicitného vymedzenia výskumníkom (Friedman, 2001). V podmienkach rozsiahlych dátových súborov preto tieto metódy často dosahujú vyššiu predikčnú presnosť než tradičné štatistické modely, čo potvrdzujú aj porovnávacie štúdie zamerané na predikciu bankrotu podnikov (Barboza, 2017). Ich význam rastie najmä v situáciách, keď cieľom nie je len vysvetliť vzťahy medzi premennými, ale aj čo najpresnejšie identifikovať podniky s vysokým rizikom budúceho zlyhania.

Vyššia predikčná výkonnosť týchto prístupov je však často sprevádzaná nižšou transparentnosťou rozhodovacieho procesu. Mnohé pokročilé modely fungujú ako tzv. čierne skrinky (*black-box models*), pri ktorých je síce možné získať presnú predikciu, no podstatne ťažšie sa vysvetľuje, na základe akých vzťahov a premenných k nej model dospel. Práve táto nízka interpretovateľnosť predstavuje významnú prekážku ich širšieho využitia v regulovaných oblastiach, ako sú bankovníctvo, poisťovníctvo alebo úverové hodnotenie, kde

je dôraz kladený nielen na presnosť, ale aj na odôvodniteľnosť modelových rozhodnutí (Barboza, 2017; Rudin, 2019).

V reakcii na tento problém sa v posledných rokoch intenzívne rozvíja oblasť vysvetliteľnej umelej inteligencie (XAI). Jej cieľom je sprístupniť fungovanie zložitých modelov tak, aby bolo možné lepšie pochopiť, ktoré premenné a akým spôsobom ovplyvňujú výslednú predikciu. Medzi najznámejšie metódy patria *SHapley Additive exPlanations* (SHAP) a *Local Interpretable Model-agnostic Explanations* (LIME), ktoré umožňujú vysvetľovať predikcie aj pri komplexných modeloch, ako sú neurónové siete alebo modely založené na kombinácii viacerých učiacich sa algoritmov (Ribeiro et al., 2016). Do popredia sa dostávajú tzv. *glass-box* modely, ktoré sú interpretovateľné už zo svojej podstaty, teda bez potreby dodatočných vysvetľovacích nástrojov. Do tejto skupiny patrí najmä *Explainable Boosting Machine* (EBM), ktoré spájajú schopnosť zachytiť nelineárne vzťahy s relatívne vysokou mierou interpretovateľnosti (Lundberg & Lee, 2017).

1.1.4 Finančné a nefinančné ukazovatele zlyhania podniku

Predikčná výkonnosť a celková kvalita modelov strojového učenia sú vo veľkej miere podmienené vhodnou voľbou vstupných premenných. Už priekopnícke práce Beavera a Altmana potvrdili, že finančné ukazovatele majú významnú signalizačnú hodnotu pri včasnej identifikácii podnikov ohrozených zlyhaním. V oblasti modelovania zlyhania podnikov odborná literatúra spravidla rozlišuje dve základné skupiny vysvetľujúcich premenných: finančné ukazovatele, ktoré na základe účtovných údajov zachytávajú výkonnosť, likviditu, zadlženosť a finančnú stabilitu podniku, a nefinančné charakteristiky, ktoré odrážajú jeho štrukturálne vlastnosti, trhové postavenie a celkový rizikový profil (Wilson et al., 2014; Altman, 1968; Beaver, 1966).

Finančné ukazovatele tvoria základ predikcie zlyhania podnikov už od 60. rokov 20. storočia. Napriek rozvoju moderných algoritmických prístupov, ako sú EBM a neurónové siete, ktoré umožňujú spracovanie rozsiahlych a komplexných dátových súborov, empirické zistenia naďalej potvrdzujú, že rozhodujúca časť predikčnej schopnosti modelov je sústredená najmä v ukazovateľoch rentability, likvidity, zadlženosti a efektívnosti hospodárenia (Fasano et al., 2025; Maturo et al., 2025). Z toho vyplýva, že technologický pokrok v oblasti modelovania nemení význam ekonomickej podstaty vstupných údajov, ale skôr rozširuje možnosti, ako tieto vzťahy presnejšie zachytiť.

Ukazovatele rentability patria v literatúre medzi najvýznamnejšie determinanty dlhodobého prežitia podniku. Podniky, ktoré dlhodobo generujú straty, oslabujú svoju kapitálovú základňu, znižujú hodnotu vlastného imania a zvyšujú pravdepodobnosť finančných ťažkostí. Medzi kľúčové ukazovatele tejto skupiny patria najmä rentabilita aktív (ROA) a rentabilita tržieb (ROS). Novšie výskumy zároveň poukazujú na to, že vzťah medzi rentabilitou a pravdepodobnosťou zlyhania nemusí byť lineárny. Maturo a kol. vo svojom modeli EBM ukazujú, že pri poklese ROA pod určitú kritickú úroveň dochádza k výraznému nárastu rizika zlyhania, čo naznačuje existenciu prahových efektov, ktoré tradičné lineárne modely nedokážu vždy adekvátne zachytiť (Maturo et al., 2025).

Kým nízka rentabilita spravidla signalizuje dlhodobejší a štrukturálny problém, nedostatočná likvidita môže pôsobiť ako bezprostredný mechanizmus vedúci k zlyhaniu podniku. V podmienkach slovenskej právnej úpravy predstavuje platobná neschopnosť jeden zo zákonných dôvodov na vyhlásenie konkurzu, čo zvýrazňuje význam ukazovateľov schopnosti podniku plniť svoje krátkodobé záväzky. Medzi najčastejšie používané ukazovatele patria bežná likvidita (*Current Ratio*) a pohotová likvidita (*Quick Ratio*), ktoré vyjadrujú mieru krytia krátkodobých záväzkov obežným majetkom, respektíve jeho likvidnejšou časťou. Tieto ukazovatele preto predstavujú dôležité signály krátkodobého finančného zdravia a prevádzkovej stability podniku.

Významnú úlohu pri predikcii zohrávajú aj ukazovatele zadlženosti, napríklad pomer celkových záväzkov k aktívam alebo pomer dlhu k vlastnému imaniu. Tieto premenné odrážajú mieru finančného rizika vyplývajúceho z kapitálovej štruktúry podniku. Nadmerná zadlženosť zvyšuje náklady na obsluhu dlhu, obmedzuje finančnú flexibilitu a znižuje schopnosť podniku absorbovať nepriaznivé vonkajšie vplyvy, ako sú rast úrokových sadzieb, pokles dopytu alebo zhoršenie prístupu k externému financovaniu. Súčasný výskum zároveň zdôrazňuje, že dôležitá nie je len aktuálna úroveň zadlženosti, ale aj jej vývoj v čase. Práve časovú dynamiku zadlženosti dokážu efektívne zachytiť najmä rekurentné neurónové siete, ktoré pracujú so sekvenčným usporiadaním údajov a umožňujú modelovať postupné zhoršovanie finančnej situácie podniku (Fasano et al., 2025).

Dôležitou skupinou premenných sú aj ukazovatele aktivity, ktoré vyjadrujú rýchlosť, akou sa aktíva podniku premieňajú na tržby alebo peňažné toky. V modeloch predikcie zlyhania patrí medzi ich najvýznamnejších zástupcov obrat celkových aktív, ktorý odráža schopnosť podniku efektívne využívať dostupné zdroje na tvorbu výnosov. Nízke hodnoty tohto ukazovateľa môžu signalizovať slabšiu prevádzkovú výkonnosť, nízku efektívnosť

hospodárenia alebo neadekvátne využitie majetku, a preto sú v literatúre spájané so zvýšeným rizikom úpadku (Altman, 1968).

Výlučné zameranie na finančné výkazy má však svoje prirodzené obmedzenia, keďže účtovné údaje poskytujú prevažne retrospektívny pohľad na ekonomickú situáciu podniku. Z tohto dôvodu moderné prístupy k modelovaniu zlyhania čoraz častejšie zahŕňajú aj nefinančné premenné, ktoré môžu významne rozšíriť vypovedaciu schopnosť modelov, najmä pri nekótovaných podnikoch, kde je informačný profil firmy menej zachytený než pri verejne obchodovaných spoločnostiach (Altman et al., 2010). Význam týchto faktorov je obzvlášť výrazný v podmienkach transformujúcich sa ekonomík, medzi ktoré patrí aj Slovenská republika.

Medzi významné nefinančné determinanty patrí vek podniku. Empirické dôkazy zo slovenského prostredia podporujú hypotézu „zraniteľnosti novosti“, podľa ktorej je riziko zlyhania najvyššie v počiatočných fázach existencie podniku, keď ešte nemá vytvorené stabilné väzby s trhom, dodávateľmi, odberateľmi či financujúcimi inštitúciami. Po prekonaní úvodného obdobia toto riziko spravidla klesá, čo naznačuje, že vek podniku môže pôsobiť ako významný stabilizačný faktor (Wilson et al., 2014).

Významnú úlohu zohráva aj veľkosť podniku, ktorá býva najčastejšie vyjadrená logaritmom celkových aktív alebo počtom zamestnancov. Väčšie podniky spravidla disponujú lepším prístupom k externému financovaniu, väčšou schopnosťou diverzifikovať podnikateľské riziká a vyššou odolnosťou voči nepriaznivým hospodárskym šokom. Veľkosť podniku preto v mnohých modeloch vystupuje ako ochranný faktor znižujúci pravdepodobnosť zlyhania (Altman et al., 2010).

Osobitné postavenie v slovenskom prostredí má vlastnícka štruktúra. Výskumné zistenia naznačujú, že podniky so zahraničnou kapitálovou účasťou vykazujú nižšiu mieru zlyhania než čisto domáce subjekty. Tento efekt možno vysvetliť lepším prístupom ku kapitálu, manažérskym skúsenostiam, širším trhovým príležitostiam a silnejším zázemím materských spoločností. V podmienkach slovenskej ekonomiky, ktorá je výrazne prepojená so zahraničnými investíciami, tak vlastnícka štruktúra predstavuje dôležitý determinant podnikovej stability (Wilson et al., 2014).

Riziko zlyhania zároveň nie je v rámci ekonomiky rozdelené rovnomerne, ale líši sa aj podľa odvetvia a regiónu. Vyššiu mieru zlyhania často vykazujú odvetvia charakteristické výraznou cyklickosťou alebo nízkymi bariérami vstupu, napríklad stavebníctvo, gastronómia alebo niektoré segmenty služieb. Dôležitý vplyv majú aj regionálne disparity v rámci Slovenskej republiky, keďže rozdiely v hospodárskej výkonnosti, infraštruktúre a

kvalite podnikateľského prostredia vytvárajú odlišné podmienky pre fungovanie a prežitie podnikov (Wilson et al., 2014).

Zahrnutie finančných aj nefinančných ukazovateľov umožňuje vytvoriť komplexnejší obraz o riziku zlyhania podniku. Kým tradičné lineárne prístupy spravidla posudzujú vplyv jednotlivých premenných oddelene, modernejšie modely dokážu lepšie zachytiť aj ich vzájomné vzťahy. Rizikový význam konkrétneho ukazovateľa sa totiž môže meniť v závislosti od ďalších charakteristík podniku, ako sú jeho vek, veľkosť, odvetvie alebo úroveň rentability. Práve schopnosť zachytiť tieto zložitejšie vzťahy predstavuje jednu z hlavných výhod súčasných prístupov založených na strojovom učení a zároveň zdôvodňuje potrebu kombinovať ekonomicky interpretovateľné premenné s metodicky pokročilejšími modelmi.

1.1.5 Manažment nevyváženosti dát v klasifikačných úlohách

Pri modelovaní kreditného rizika a predikcii zlyhania podnikov predstavuje významný metodologický problém nevyváženosť tried. V typických podnikových dátach totiž počet prosperujúcich subjektov výrazne prevyšuje počet zlyhaných podnikov, čo vedie k situácii, v ktorej štandardné klasifikačné algoritmy prirodzene uprednostňujú väčšinovú triedu. Model tak môže dosahovať zdanlivo vysokú presnosť aj vtedy, ak nedokáže spoľahlivo identifikovať podniky s vysokým rizikom zlyhania. V oblasti predikcie bankrotu je preto nevyhnutné venovať osobitnú pozornosť technikám, ktoré umožňujú túto nerovnováhu zmierniť. Odborná literatúra v tejto súvislosti rozlišuje dva základné prístupy: techniky na úrovni dát, ktoré upravujú tréningovú množinu, a techniky na úrovni algoritmu, ktoré modifikujú samotný proces učenia modelu (He & Garcia, 2009).

Techniky na úrovni dát sa usilujú o vyrovnanie pomeru medzi triedami ešte pred samotným trénovaním modelu. Ich cieľom je zabezpečiť, aby algoritmus nebol pri učení dominantne ovplyvnený väčšinovou triedou a dokázal lepšie zachytiť rozhodovaciu hranicu medzi prosperujúcimi a zlyhanými podnikmi. Tento krok je obzvlášť dôležitý pri modeloch hlbokého učenia, ktoré si okrem dostatočného objemu dát vyžadujú aj dôsledné predspracovanie vstupných premenných. V súlade s metodikou Fasana a kol. je preto vhodné vstupné dáta najprv normalizovať a následne riešiť aj ich triednu nerovnováhu (Fasano et al., 2025).

Jedným z dátových prístupov je náhodné podvzorkovanie (*Random Undersampling*, RUS), pri ktorom sa nevyváženosť tried rieši redukciou počtu pozorovaní vo väčšinovej

triede. Výhodou tohto postupu je najmä nižšia výpočtová náročnosť a kratší čas učenia modelu (Araf et al., 2024; Chawla et al., 2002). Jeho nevýhodou však zostáva riziko straty informácie, keďže odstránením časti zdravých podnikov môžu z dát vypadnúť aj dôležité prípady, ktoré pomáhajú presne určiť hranicu medzi oboma triedami (He & Garcia, 2009). Napriek tomuto obmedzeniu sa táto metóda často využíva pri modeloch založených na rozhodovacích stromoch a kombinovaní viacerých učiacich sa algoritmov. Maturo a kol. ju napríklad aplikovali pri modeli EBM, pričom vychádzali z predpokladu, že pri dostatočne rozsiahlych dátach možno redukovať väčšinovú triedu bez zásadnej straty informačnej hodnoty modelu (Maturo et al., 2025).

V kontexte tejto diplomovej práce predstavuje RUS dátový prístup k riešeniu extrémnej triednej nevyváženosti v tréningovej vzorke pri metóde EBM. Na rozdiel od syntetických metód, ako je napríklad SMOTE, nevytvára nové umelé pozorovania menšinovej triedy, ale znižuje počet pozorovaní nezlyhaných podnikov. Tento postup umožňuje empiricky overiť, či je pri extrémne nevyvážených účtovných dátach vhodnejšie zachovať pôvodnú štruktúru menšinovej triedy a upraviť pomer tried redukciou majority triedy, najmä v kombinácii s interpretovateľným modelom typu EBM.

Popri úpravách tréningových dát existujú aj prístupy, ktoré zachovávajú pôvodnú distribúciu pozorovaní a problém triednej nevyváženosti riešia priamo na úrovni algoritmu. Pri týchto vnútorných stratégiách nedochádza k fyzickej úprave dátovej vzorky, čím sa predchádza posunu v pôvodnej distribúcii dát (Fernández et al., 2018; Johnson a Khoshgoftaar, 2019). Namiesto toho sa modifikuje samotný učiaci algoritmus, najčastejšie prostredníctvom stratovej funkcie (*loss function*) alebo úpravou rozhodovacieho prahu. Jedným z uvedených prístupov je učenie citlivé na náklady (*cost-sensitive learning*), ktoré vychádza z predpokladu, že jednotlivé typy klasifikačných chýb nemajú rovnaké ekonomické dôsledky (Elkan, 2001). V oblasti finančného rizika je spravidla závažnejšie neodhaliť podnik, ktorý v skutočnosti zlyhá, než nesprávne označiť zdravý podnik za rizikový (Araf et al., 2024). Model by preto nemal optimalizovať iba celkovú presnosť, ale najmä minimalizovať očakávanú ekonomickú stratu z nesprávnej klasifikácie, čo sa označuje ako princíp minimálnych očakávaných nákladov (Ling a Sheng, 2008).

V praxi sa *cost-sensitive learning* realizuje najmä dvoma spôsobmi. Prvým je úprava stratovej funkcie, pri ktorej sa chybám spojeným s minoritnou triedou priraďujú počas trénovania vyššie váhy (Johnson a Khoshgoftaar, 2019). Druhým je úprava rozhodovacieho prahu, ktorý sa neposudzuje fixne na úrovni 0,5, ale prispôsobuje sa pomeru nákladov chýb prvého a druhého druhu (Sheng a Ling, 2006). Výhodou týchto prístupov je, že nezasahujú

do pôvodnej dátovej štruktúry, nevyžadujú generovanie syntetických pozorovaní a umožňujú premietnuť ekonomickú logiku rozhodovania priamo do optimalizácie modelu (López et al., 2013; Guo et al., 2017).

Osobitným príkladom stratovej funkcie zohľadňujúcej rozdielne náklady klasifikačných chýb je *Focal loss*, ktorú pôvodne predstavili Lin a kol. pri úlohách detekcie objektov v počítačovom videní, kde sa modely stretávajú s extrémnym nepomerom medzi pozitívnymi vzorkami a dominantnou triedou pozadia (Lin et al., 2020). *Focal loss* rieši nevyváženosť tried prostredníctvom dynamického váženia chýb. Znižuje váhu ľahko klasifikovateľných pozorovaní a presúva kapacitu učenia na ťažko klasifikovateľné prípady s vyššou informačnou hodnotou pre minoritnú triedu. Tento mechanizmus vzniká pridaním modulačného faktora k štandardnej krížovej entropii, pričom hyperparameter γ určuje mieru potlačenia jednoduchých príkladov a parameter α umožňuje zvýšiť penalizáciu chýb pri minoritnej triede. Z metodologického hľadiska tak *Focal loss* umožňuje riešiť nevyváženosť bez syntetického rozširovania menšinovej triedy alebo odstraňovania pozorovaní z väčšinovej triedy, čím sa znižuje riziko preučenia aj straty informácie (Fernández et al., 2018).

1.2 Vysvetliteľná umelá inteligencia (XAI)

Rýchly rozvoj strojového učenia a hlbokého učenia v poslednom desaťročí výrazne rozšíril možnosti prediktívneho modelovania. Komplexné algoritmy, najmä hlboké neurónové siete a ansámblové metódy, dokážu v mnohých klasifikačných úlohách dosahovať vyššiu diskriminačnú schopnosť než tradičné štatistické prístupy. S rastúcou zložitosťou modelov sa však znižuje ich priama transparentnosť, čo vedie k problému označovanému ako *black-box* modelovanie. V oblastiach s vysokými nárokmi na zodpovednosť, medzi ktoré patrí bankovníctvo, kreditné riziko a predikcia zlyhania podnikov, samotná presnosť nestačí. Dôležité je aj porozumieť dôvodom, ktoré viedli k modelovému rozhodnutiu (Barredo Arrieta et al., 2020; Rudin, 2019).

XAI vznikla ako reakcia na tento problém. Jej cieľom je sprístupniť fungovanie modelov tak, aby bolo možné kontrolovať ich rozhodovaciu logiku, identifikovať hlavné determinanty predikcie a posúdiť, či výsledky zodpovedajú ekonomicky zmysluplným vzťahom. Táto kapitola preto predstavuje metodický základ práce: vymedzuje základné pojmy, systematizuje hlavné typy XAI metód a vysvetľuje princípy dvoch prístupov, ktoré sú následne využité pri modelovaní zlyhania podnikov.

1.2.1 Koncept vysvetliteľnosti v umelej inteligencii

V odbornej literatúre sa pojmy súvisiace s transparentnosťou modelov často používajú nejednotne, preto je potrebné odlíšiť najmä interpretovateľnosť a vysvetliteľnosť. Interpretovateľnosť označuje vnútornú vlastnosť modelu, ktorého štruktúru možno pochopiť bez dodatočných nástrojov. Typickými príkladmi sú lineárna regresia, logistická regresia alebo jednoduchý rozhodovací strom. Pri týchto modeloch je možné priamo sledovať, ako sa jednotlivé premenné podieľajú na výslednej predikcii (Lipton, 2018; Linardatos et al., 2021).

Vysvetliteľnosť sa naopak vzťahuje na schopnosť sprostredkovať zrozumiteľný opis fungovania aj pri modeloch, ktorých vnútorná štruktúra nie je pre človeka priamo čitateľná. Ide teda o rozhranie medzi technickým modelom a používateľom, ktoré má umožniť pochopiť, prečo model dospel ku konkrétnemu výstupu. V tomto zmysle možno vysvetliteľnosť chápať ako širší pojem, ktorý zahŕňa nielen vnútorne transparentné modely, ale aj dodatočné vysvetľovacie techniky aplikované na *black-box* algoritmy (Barredo Arrieta et al., 2020).

Z praktického hľadiska je dôležité rozlišovať medzi modelom, ktorý je interpretovateľný už svojou štruktúrou, a modelom, ktorý si vyžaduje dodatočné vysvetlenie. Prvá skupina sa často označuje ako *glass-box* alebo *ante-hoc* prístup, druhá ako *black-box* modelovanie s *post-hoc* vysvetliteľnosťou. Toto rozlíšenie je v práci kľúčové, pretože priamo súvisí s porovnaním dvoch moderných prístupov: RNN+SHAP a EBM.

1.2.2 Základné členenie metód XAI

Metódy XAI možno klasifikovať podľa viacerých hľadísk. Pre potreby finančného modelovania sú najdôležitejšie štyri osi členenia: miera transparentnosti modelu, závislosť vysvetľovacej techniky od konkrétneho algoritmu, rozsah vysvetlenia a forma výstupu (Tabuľka č.1). Toto členenie umožňuje odlíšiť situácie, v ktorých je vysvetliteľnosť súčasťou samotného modelu, od prípadov, keď je potrebné interpretáciu vytvoriť až dodatočne (Barredo Arrieta et al., 2020; Linardatos et al., 2021).

Podľa miery transparentnosti možno rozlišovať vnútorne interpretovateľné modely a modely s nízkou vnútornou transparentnosťou. Do prvej skupiny patria tradičné štatistické modely, rozhodovacie stromy a moderné *glass-box* algoritmy, ako je EBM. Druhú skupinu tvoria najmä hlboké neurónové siete, *Support Vector Machines, Random Forest* alebo

XGBoost, pri ktorých je rozhodovací proces príliš komplexný na priamu ľudskú interpretáciu. Pri týchto modeloch je potrebné využiť *post-hoc* techniky, ako sú SHAP alebo LIME (Lipton, 2018; Lou et al., 2013).

Z hľadiska závislosti od modelu sa XAI metódy delia na modelovo špecifické a modelovo nezávislé. Modelovo špecifické prístupy využívajú znalosť vnútornej architektúry konkrétneho algoritmu, napríklad gradienty alebo mechanizmus pozornosti v neurónových sieťach. Modelovo nezávislé metódy naopak pracujú iba so vstupmi a výstupmi modelu, a preto ich možno aplikovať na rôzne typy klasifikátorov. Táto flexibilita vysvetľuje široké využitie metód SHAP a LIME vo finančnom modelovaní, kde sa porovnávajú modely s odlišnou vnútornou štruktúrou (Dieber & Kirrane, 2020; Lundberg & Lee, 2017).

Ďalším dôležitým hľadiskom je rozsah vysvetlenia. Globálne vysvetlenia opisujú správanie modelu ako celku, napríklad prostredníctvom poradia dôležitosti premenných alebo tvaru vzťahu medzi ukazovateľom a rizikovým skóre. Lokálne vysvetlenia sa zameriavajú na konkrétnu predikciu, napríklad na jednu firmu označenú ako rizikovú. V oblasti kreditného rizika sú potrebné oba typy: globálne vysvetlenia podporujú validáciu a pochopenie modelu, zatiaľ čo lokálne vysvetlenia umožňujú zdôvodniť konkrétne rozhodnutie (Aas et al., 2021).

Tabuľka č.1: Základná taxonómia XAI metód

Hľadisko členenia	**Hlavné kategórie**	**Podstata**	**Príklady relevantné pre prácu**
Transparentnosť modelu	*Glass-box / black-box*	Rozlišuje, či je rozhodovací proces čitateľný priamo zo štruktúry modelu, alebo si vyžaduje dodatočné vysvetlenie.	Logistická regresia, EBM / RNN, XGBoost
Závislosť od modelu	Modelovo špecifické / modelovo nezávislé	Určuje, či je vysvetľovacia metóda viazaná na konkrétny algoritmus, alebo pracuje iba so vstupmi a výstupmi.	*Attention* mechanizmus/ SHAP, LIME
Rozsah vysvetlenia	Globálne / lokálne	Rozlišuje, či sa vysvetlenie týka celého modelu alebo jednej konkrétnej predikcie.	Dôležitosť premenných / vysvetlenie rizika konkrétnej firmy
Forma výstupu	Numerické, pravidlové, vizuálne, textové, kombinované	Opisuje spôsob, akým je vysvetlenie prezentované používateľovi.	SHAP hodnoty, rozhodovacie pravidlá, grafy *shape* funkcií

Zdroj: vlastné spracovanie podľa Barredo Arrieta et al. (2020), Linardatos et al. (2021), Lipton (2018), Lundberg & Lee (2017) a Lou et al. (2013).

Forma výstupu vysvetlenia závisí od toho, komu je interpretácia určená. Analytik môže preferovať numerické príspevky premenných, vývojár vizualizáciu rozhodovacej logiky a manažér rizika stručné slovné odôvodnenie. V praxi sa preto často využívajú kombinované vysvetlenia, ktoré spájajú číselné hodnoty, grafy a textové interpretácie. V tejto práci sú najdôležitejšie numerické a vizuálne formy vysvetlenia: SHAP hodnoty pri *post-hoc* interpretácii rekurentných neurónových sietí (*Recurrent Neural Networks, RNN)* a tvarové funkcie pri modeli EBM (Ullah et al., 2025).

1.2.3 Sekvenčné modelovanie a post-hoc vysvetliteľnosť: RNN/LSTM modely so SHAP interpretáciou

Prvý metodický prístup využívaný v práci vychádza z predpokladu, že finančné zlyhanie podniku je dynamický proces, ktorý sa formuje postupne. Statické modely založené na jednom časovom reze síce umožňujú odhadnúť riziko na základe aktuálnych finančných ukazovateľov, no nedokážu prirodzene pracovať s časovou postupnosťou údajov. Rekurentné neurónové siete (*Recurrent Neural Networks, RNN*) sú naopak navrhnuté tak, aby spracovávali sekvenčné dáta a uchovávali informácie z predchádzajúcich období. V kontexte predikcie zlyhania podnikov to umožňuje zachytiť napríklad postupné zhoršovanie likvidity, rast zadlženosti alebo dlhodobejší pokles rentability (Fasano et al., 2025).

Základné RNN však trpia problémom miznúceho gradientu, ktorý obmedzuje ich schopnosť učiť sa dlhodobejšie závislosti. Tento limit prekonáva architektúra LSTM (*Long Short-Term Memory*), ktorú predstavili Hochreiter a Schmidhuber. LSTM bunka obsahuje sústavu regulačných brán, ktoré rozhodujú o tom, ktoré informácie z minulosti majú byť uchované, aktualizované alebo zabudnuté. Vďaka tomu je tento typ modelu vhodný pre situácie, v ktorých je dôležitý vývoj sledovaných ukazovateľov v čase (Hochreiter & Schmidhuber, 1997).

Tréning sekvenčných neurónových sietí sa realizuje prostredníctvom spätného šírenia chyby v čase (*Backpropagation Through Time, BPTT*), pri ktorom sa sieť rozvinie pozdĺž časovej osi a jej váhy sa optimalizujú vzhľadom na chybu predikcie (Werbos, 1990). Vzhľadom na vysokú kapacitu LSTM modelov je však potrebné kontrolovať riziko preučenia. Na tento účel sa využívajú najmä techniky *Dropout*, teda náhodné vypínanie časti neurónov počas tréningu, a *Early Stopping,* pri ktorom sa učenie zastaví v momente, keď sa zhoršuje výkonnosť na validačnej vzorke (Srivastava et al., 2014; Prechelt, 1998).

Nevýhodou LSTM sietí je nízka vnútorná interpretovateľnosť. Ich rozhodovacia logika je reprezentovaná veľkým počtom parametrov, ktoré nemožno priamo ekonomicky interpretovať. Na vysvetlenie výstupov takéhoto modelu sa preto využíva *post-hoc* metóda SHAP, ktorá vychádza zo Shapleyho hodnôt z kooperatívnej teórie hier. Predikcia modelu sa v tomto rámci chápe ako výsledok spoločného pôsobenia viacerých premenných, pričom cieľom je spravodlivo rozdeliť celkový príspevok medzi jednotlivé vstupy (Shapley, 1953; Lundberg & Lee, 2017).

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(m - |S| - 1)!}{m!} [f(S \cup \{i\}) - f(S)]$$

Vo vzťahu je ϕ_i Shapleyho hodnota *i*-teho príznaku, f predstavuje množinu všetkých príznakov, *S* je podmnožina príznakov bez *i*-teho prvku, *m* označuje celkový počet príznakov a výraz $f(S \cup \{i\})$ - $f(S)$ vyjadruje marginálny prínos danej premennej k predikcii. Kľúčovou vlastnosťou SHAP je aditivita, a teda súčet príspevkov jednotlivých premenných spolu s priemernou predikciou zodpovedá výslednej predikcii modelu pre konkrétny podnik. To umožňuje vytvárať lokálne vysvetlenia individuálnych predikcii aj globálne prehľady najdôležitejších premenných (Lundberg & Lee, 2017).

Pri interpretácii SHAP hodnôt vo finančných dátach je však potrebná opatrnosť. Mnohé finančné ukazovatele sú konštrukčne alebo ekonomicky previazané, napríklad rôzne miery likvidity, rentability alebo zadlženosti. Pri silnej korelácii vstupných premenných môže byť príspevok rozdelený medzi viacero podobných ukazovateľov, čo komplikuje ekonomickú interpretáciu výsledkov. Aas a kol. preto upozorňujú, že pri závislých premenných môže štandardná interpretácia SHAP hodnôt viesť k nestabilným alebo nejednoznačným záverom. V tejto práci je preto SHAP chápaný ako nástroj na podporu interpretácie, nie ako samostatný dôkaz kauzálneho vzťahu medzi premennou a zlyhaním podniku (Aas et al., 2021).

1.2.4 Vnútorne interpretovateľné modelovanie: Explainable Boosting Machine

Druhý metodický prístup predstavuje vnútorne interpretovateľné modelovanie pomocou EBM. Tento model patrí medzi *glass-box* algoritmy, pretože poskytuje vysvetliteľnosť priamo prostredníctvom svojej štruktúry a nevyžaduje externý nástroj na dodatočnú interpretáciu. EBM vychádza z generalizovaných aditívnych modelov (*Generalized Additive Models, GAM*), ktoré rozširuje o schopnosť zachytávať nelineárne vzťahy a vybrané párové interakcie medzi premennými (Hastie & Tibshirani, 2017; Lou et al., 2013).

Základná myšlienka EBM spočíva v tom, že výsledná predikcia nie je tvorená jednou neprehľadnou funkciou vo vysokorozmernom priestore, ale súčtom samostatných funkcií jednotlivých premenných a prípadných interakčných členov. Takáto štruktúra umožňuje vizualizovať, ako konkrétny finančný ukazovateľ ovplyvňuje rizikové skóre, a zároveň zachovať vyššiu flexibilitu než pri logistickej regresii. Model tak dokáže identifikovať prahové efekty, nelineárne priebehy a interakcie bez toho, aby sa úplne stratila čitateľnosť rozhodovacieho mechanizmu (Lou et al., 2013; Maturo et al., 2025).

$$\boldsymbol{g}(\boldsymbol{E}[\boldsymbol{y}]) = \boldsymbol{\beta_0} + \sum_{\boldsymbol{j}} \quad \boldsymbol{f_j}(\boldsymbol{x_j}) + \sum_{\boldsymbol{ij}} \quad \boldsymbol{f_{ij}}(\boldsymbol{x_i}, \boldsymbol{x_j})$$

Vo vzťahu $\boldsymbol{g}$ označuje funkciu prepojenia, β_0 základnú úroveň predikcie, $\boldsymbol{f}_j(x_j)$ hlavný efekt *j*-tej premennej a $\boldsymbol{f}_{ij}(x_i, x_j)$ párovú interakciu medzi dvoma premennými. Každá funkcia $\boldsymbol{f}_j$ môže byť zobrazená ako tvarová funkcia, teda graf tvaru vzťahu medzi hodnotou ukazovateľa a jeho príspevkom k predikovanému riziku. Pri finančných ukazovateľoch je táto vlastnosť mimoriadne dôležitá, pretože umožňuje odhaliť napríklad hranice, pri ktorých sa nízka likvidita alebo záporná rentabilita začína výraznejšie premietať do rizika zlyhania.

EBM sa učí pomocou špecifickej tréningovej procedúry založenej na postupnom učení malých rozhodovacích stromov pre jednotlivé premenné. V literatúre sa tento postup označuje ako *Round-Robin* cyklovanie. Algoritmus opakovane prechádza premenné a postupne aktualizuje ich príspevkové funkcie, čo mu umožňuje zachytiť jemné nelinearity bez toho, aby sa model stal úplne netransparentným. V porovnaní s *black-box* modelmi tak EBM ponúka priaznivý kompromis medzi flexibilitou a interpretovateľnosťou (Lou et al., 2013; Rudin, 2019).

V kontexte tejto práce je význam EBM dvojitý. Po prvé, predstavuje metodickú alternatívu k RNN+SHAP, pretože nevysvetľuje komplexný model dodatočne, ale buduje vysvetliteľnosť priamo do modelovej architektúry. Po druhé, jeho štruktúra je vhodná pre tabuľkové finančné dáta, kde je dôležité nielen predikovať zlyhanie, ale aj identifikovať ekonomicky interpretovateľné prahové efekty a interakcie medzi ukazovateľmi.

1.2.5 Vymedzenie metodického rámca práce

Spektrum metód strojového učenia využívaných pri predikcii zlyhania podnikov je širšie než dvojica RNN+SHAP a EBM. Významné miesto v literatúre zaujímajú aj *Support Vector Machines, Random Forest, XGBoost* alebo ďalšie ansámblové prístupy. Ich predikčná výkonnosť môže byť vysoká, avšak miera a forma interpretovateľnosti sa medzi nimi výrazne líši. *Random Forest* poskytuje informáciu o dôležitosti premenných, no spravidla menej transparentne opisuje tvar jednotlivých vzťahov. Pri *Support Vector Machines* s nelineárnymi jadrami je ekonomická interpretácia rozhodovacej hranice ešte náročnejšia (Barboza et al., 2017).

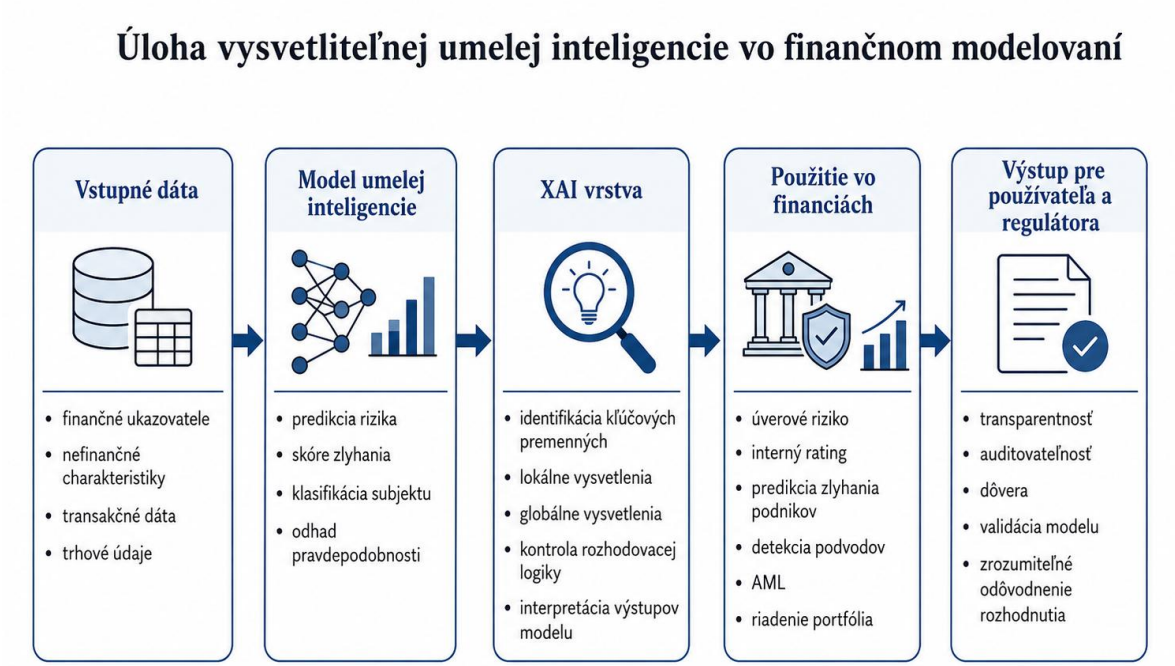
Z tohto dôvodu sa práca sústreďuje na dve metodologicky odlišné riešenia, ktoré reprezentujú hlavné smery súčasnej XAI diskusie. Prístup RNN+SHAP vychádza z priority predikčnej výkonnosti a využíva *post-hoc* vysvetlenie na interpretáciu komplexného sekvenčného modelu. EBM naopak reprezentuje *glass-box* prístup, pri ktorom je vysvetliteľnosť súčasťou modelu od začiatku. Takéto vymedzenie umožňuje porovnať, či je pri predikcii zlyhania slovenských podnikov vhodnejší model s dodatočnou vysvetliteľnosťou, alebo model, ktorý kombinuje nelineárne učenie s vnútornou transparentnosťou.

Uvedené vymedzenie vytvára metodický základ pre výskumnú časť práce. Nasledujúce časti literárneho prehľadu rozvíjajú význam XAI vo finančnom modelovaní a zasadzujú logistickú regresiu, RNN/SHAP a EBM do kontextu súčasného výskumu predikcie bankrotu. Na tomto základe je následne formulovaná výskumná medzera a cieľ práce.

1.3 Aplikácia XAI vo finančnom modelovaní

Finančný sektor patrí medzi oblasti s intenzívnym využívaním metód umelej inteligencie, pričom zároveň podlieha prísnym požiadavkám na riadenie rizík, auditovateľnosť a súlad s regulačným rámcom. V takomto prostredí nepostačuje, aby model dosahoval iba vysokú predikčnú presnosť. Rovnako dôležitá je aj schopnosť transparentne zdôvodniť jeho rozhodnutia, najmä ak majú právne alebo ekonomicky významné dôsledky, ako napríklad zamietnutie úveru, zmena interného ratingu alebo identifikácia podozrivej transakcie. XAI predstavuje súbor prístupov, ktoré umožňujú zmierniť rozpor medzi rastúcou komplexnosťou moderných modelov a požiadavkou na ich interpretovateľnosť v

regulovanom prostredí. Jej význam spočíva v tom, že výsledky modelov neslúžia iba na technickú klasifikáciu pozorovaní, ale často vstupujú do rozhodovacích procesov s priamym vplyvom na klientov, veriteľov, investorov alebo interné riadenie rizík. Cieľom tejto kapitoly je preto vysvetliť, ako XAI prispieva k transparentnosti finančného rozhodovania, aké regulačné a organizačné požiadavky s tým súvisia a v ktorých oblastiach finančného modelovania nachádza praktické uplatnenie (Obrázok č.1).



Obrázok č.1: Úloha vysvetliteľnej umelej inteligencie vo finančnom modelovaní.

Zdroj: vlastné spracovanie podľa Barredo Arrieta et al. (2020), Rudin (2019) a Weber et al. (2024).

1.3.1 Význam vysvetliteľnosti vo finančnom rozhodovaní

Dôvera je jedným zo základných predpokladov fungovania finančného systému. V tradičnom rozhodovaní bola postavená najmä na odbornom úsudku analytika, pravidlách inštitúcie a možnosti spätne preskúmať konkrétne rozhodnutie. S rozširovaním automatizovaných modelov sa však časť rozhodovacej právomoci presúva na algoritmické systémy, ktorých fungovanie nemusí byť pre koncového používateľa bezprostredne zrozumiteľné. Ak model funguje ako tzv. „čierna skrinka", zvyšuje sa riziko, že jeho výstupy síce budú štatisticky presné, ale len ťažko obhájiteľné z ekonomického, právneho alebo etického hľadiska (Lipton, 2018; Rudin, 2019).

V prostredí finančného modelovania preto vysvetliteľnosť plní viacero funkcií. Po prvé, umožňuje analytikom overiť, či model využíva ekonomicky zmysluplné vzťahy, alebo

či sa opiera o nestabilné korelácie a dátové artefakty (Rudin, 2019). Po druhé, podporuje internú validáciu modelu, keďže umožňuje identifikovať premenné, ktoré majú najväčší vplyv na predikciu (Barredo Arrieta et al., 2020). Po tretie, zvyšuje praktickú použiteľnosť výsledkov, pretože manažéri rizika potrebujú nielen vedieť, ktorý podnik je rizikový, ale aj pochopiť, prečo model daný podnik označil za ohrozený. V kontexte predikcie zlyhania firiem má táto požiadavka osobitný význam, keďže samotná klasifikácia podniku ako rizikového je menej užitočná než identifikácia konkrétnych faktorov, napríklad zhoršujúcej sa likvidity, rastúcej zadlženosti alebo dlhodobej stratovosti (Fasano et al., 2025; Maturo et al., 2025). Uvedené funkcie vysvetliteľnosti tak možno chápať ako samostatnú vrstvu medzi predikčným modelom a jeho praktickým využitím v rozhodovacích procesoch finančných inštitúcií, čo znázorňuje aj obrázok č.1.

XAI zároveň umožňuje rozlišovať medzi modelom ako nástrojom predikcie a modelom ako nástrojom ekonomického poznania. Pri predikcii zlyhania podnikov nie je cieľom iba maximalizovať diskriminačnú schopnosť modelu, ale aj porozumieť mechanizmom, ktoré k finančnej tiesni vedú. Vysvetlenia preto plnia diagnostickú funkciu: môžu podporiť včasné varovanie, cielené sledovanie rizikových subjektov a lepšiu komunikáciu modelových výstupov smerom k používateľom, ktorí nenesú technickú zodpovednosť za vývoj algoritmu, ale rozhodujú o jeho praktickom využití (Fasano et al., 2025; Weber et al., 2024).

1.3.2 Regulačné požiadavky a dôvera v automatizované rozhodovanie

Požiadavka vysvetliteľnosti vo financiách nevychádza iba z praktickej potreby analytikov, ale aj z regulačného prostredia. V európskom právnom rámci predstavuje dôležitý základ Všeobecné nariadenie o ochrane údajov (GDPR), najmä článok 22, ktorý sa vzťahuje na rozhodovanie založené výlučne na automatizovanom spracúvaní, ak má právne alebo obdobne významné účinky na dotknutú osobu. V literatúre sa tieto požiadavky často spájajú s konceptom tzv. práva na vysvetlenie, teda s potrebou poskytnúť zrozumiteľné odôvodnenie automatizovaného rozhodnutia a umožniť jeho preskúmanie (Goodman & Flaxman, 2016).

Ďalší významný rámec predstavuje Nariadenie Európskej únie o umelej inteligencii, známe ako *AI Act*. Toto nariadenie zavádza rizikovo orientovaný prístup k regulácii systémov umelej inteligencie a medzi vysokorizikové oblasti zaraďuje aj niektoré systémy používané pri prístupe k základným súkromným službám, vrátane posudzovania kreditnej

bonity fyzických osôb. Hoci predikcia zlyhania podnikov nemusí byť vo všetkých prípadoch totožná s individuálnym rozhodovaním o spotrebiteľskom úvere, regulačná logika je relevantná aj pre podnikové modely, pretože čím významnejšie sú dôsledky modelového výstupu, tým vyššia je potreba transparentnosti, dokumentácie a možnosti kontroly (Regulation (EU) 2024/1689).

Popri ochrane klienta sú významné aj požiadavky prudenciálnej regulácie, najmä v rámci bazilejských dohôd Basel II a Basel III. Tie zdôrazňujú potrebu validácie interných modelov, preukázania ich stability v čase a schopnosti vysvetliť ich rozhodovaciu logiku. Pri netransparentných *black-box* modeloch je náročné posúdiť, či model vychádza z ekonomicky opodstatnených vzťahov, alebo iba z nestabilných korelácií, šumu či dátových artefaktov. Rudin preto argumentuje, že v oblastiach s vysokými nárokmi na zodpovednosť by mali byť preferované modely, ktoré sú interpretovateľné už svojou štruktúrou, prípadne doplnené o spoľahlivé vysvetľovacie techniky (Rudin, 2019).

Z tohto pohľadu nie je vysvetliteľnosť iba doplnkom k predikčnej presnosti, ale jedným z predpokladov akceptovateľného nasadenia umelej inteligencie vo finančnom sektore. Model, ktorý dosahuje vysokú presnosť, ale nedokáže poskytnúť zrozumiteľné a ekonomicky obhájiteľné vysvetlenie, môže byť problematický pri internom schvaľovaní, regulačnom dohľade aj pri komunikácii so zainteresovanými stranami. Vysvetliteľnosť preto predstavuje spojovací článok medzi technickou výkonnosťou modelu a jeho praktickou využiteľnosťou v prostredí riadenia finančných rizík.

1.3.3 Oblasti využitia XAI vo finančnom modelovaní

XAI nachádza uplatnenie v širokom spektre finančných úloh. Najčastejšie sa spomína v oblasti úverového skórovania a hodnotenia kreditného rizika, kde modely predikujú pravdepodobnosť nesplácania alebo zlyhania klienta. V týchto aplikáciách je dôležité nielen rozhodnúť, či je subjekt rizikový, ale aj identifikovať faktory, ktoré k riziku prispievajú. Vysvetlenia tak môžu podporiť rozhodovanie úverových analytikov, internú validáciu ratingových systémov a komunikáciu dôvodov rozhodnutia voči klientom alebo regulačným orgánom.

Osobitne významnou oblasťou je predikcia zlyhania podnikov a systémy včasného varovania. V tejto úlohe má XAI diagnostickú hodnotu, pretože umožňuje rozlíšiť, či je zvýšené riziko spôsobené napríklad nízkou rentabilitou, zhoršenou likviditou, nadmerným

zadlžením alebo nepriaznivou kombináciou viacerých faktorov. Vysvetliteľnosť je v tomto prípade dôležitá aj preto, že zlyhanie podniku je zriedkavý, no ekonomicky závažný jav. Modely preto musia byť schopné identifikovať signály finančnej tiesne včas a zároveň poskytnúť také vysvetlenie, ktoré je použiteľné pre ďalšie analytické alebo manažérske rozhodnutia (Fasano et al., 2025; Maturo et al., 2025).

Ďalšou oblasťou je detekcia podvodov a boj proti praniu špinavých peňazí. Modely používané v týchto úlohách spracúvajú veľké objemy transakčných údajov a často pracujú s veľmi nízkym podielom skutočne podozrivých prípadov. XAI môže znížiť záťaž analytikov tým, že pomáha odlíšiť relevantné varovné signály od falošných poplachov a zdôvodňuje, prečo bola konkrétna transakcia alebo správanie klienta označené ako podozrivé. Podobný význam má vysvetliteľnosť aj v investičnom manažmente, robo-poradenstve a správe portfólia, kde podporuje porozumenie modelovým odporúčaniam a zvyšuje dôveru používateľov v automatizované rozhodovanie (Liu, 2020; Babaei, 2022; Carta, 2021).

Spoločným znakom uvedených aplikácií je potreba hľadať rovnováhu medzi výkonnosťou a transparentnosťou. Moderné modely strojového učenia často poskytujú vyššiu predikčnú presnosť než tradičné štatistické prístupy, no ich praktické využitie vo financiách závisí od toho, či sú ich výstupy zrozumiteľné a preskúmateľné. Táto skutočnosť vytvára priestor pre dve odlišné stratégie: využitie výkonných modelov s dodatočnou *post-hoc* vysvetliteľnosťou alebo použitie modelov, ktoré sú interpretovateľné už svojou vnútornou štruktúrou. Práve tieto dve stratégie, doplnené o tradičný referenčný model logistickej regresie, tvoria jadro súčasnej vedeckej diskusie v oblasti predikcie bankrotu, ktorej sa venuje nasledujúca kapitola.

1.4 Súčasný stav poznania v modelovaní bankrotu

Oblasť predikcie finančného zlyhania podnikov prechádza v súčasnosti významnou paradigmatickou zmenou. Kým posledné desaťročia 20. storočia boli dominované klasickými štatistickými metódami, nástup exponenciálneho rastu výpočtového výkonu a dostupnosti veľkých dát presunul ťažisko výskumu k algoritmom strojového učenia. Cieľom tejto kapitoly je kriticky analyzovať súčasný stav vedeckého poznania prostredníctvom komparácie troch odlišných metodologických prístupov, ktoré v súčasnej literatúre súperia o dominanciu: tradičného prístupu pomocou logistickej regresie, komplexného modelovania pomocou neurónových sietí a moderného prístupu vnútorne interpretovateľných modelov (Tabuľka č.2).

1.4.1 Logistická regresia ako referenčný štandard

Logistická regresia si napriek rozvoju strojového učenia udržiava významné postavenie vo finančnom výskume aj v bankovej praxi. Od práce Ohlsona, ktorý ju aplikoval ako alternatívu k viacrozmernej diskriminačnej analýze, patrí medzi najčastejšie používané metódy binárnej klasifikácie úverového a bankrotového rizika (Ohlson, 1980). Jej pretrvávajúci význam vyplýva najmä z jednoduchej štruktúry, relatívne nízkych nárokov na implementáciu a vysokej miery interpretovateľnosti.

Kľúčovou výhodou logistickej regresie je možnosť interpretovať vzťah medzi vysvetľujúcimi premennými a pravdepodobnosťou zlyhania prostredníctvom regresných koeficientov a pomerov šancí (*Odds Ratio*). Model tak umožňuje kvantifikovať, ako sa zmena konkrétneho finančného ukazovateľa premieta do rizika bankrotu pri nezmenených ostatných podmienkach. Táto vlastnosť je dôležitá najmä v regulovanom prostredí, kde sa od modelov očakáva transparentnosť, stabilita a možnosť ekonomického zdôvodnenia výsledkov (Wooldridge, 2010).

Súčasná literatúra však poukazuje aj na obmedzenia logistickej regresie. Jej základná štruktúra predpokladá lineárny vzťah medzi vysvetľujúcimi premennými a logaritmom pomeru šancí, čo môže byť pri reálnych finančných dátach príliš reštriktívne. Finančné ukazovatele často pôsobia nelineárne, majú prahové efekty a ich význam sa mení v závislosti od ďalších charakteristík podniku. Interakcie medzi premennými musí výskumník v logistickom modeli explicitne definovať, čo znižuje flexibilitu v porovnaní s algoritmami, ktoré ich dokážu identifikovať automaticky (Barboza, 2017; Fasano et al., 2025).

V kontexte tejto diplomovej práce logistická regresia nepredstavuje zastaraný prístup, ale nevyhnutný referenčný štandard. Slúži ako ekonomicky transparentná porovnávacia línia, voči ktorej možno hodnotiť pridanú hodnotu pokročilejších modelov. Takéto postavenie je obhájiteľné najmä preto, že cieľom práce nie je iba maximalizovať predikčnú výkonnosť, ale posúdiť, či moderné metódy vysvetliteľnej umelej inteligencie prinášajú lepší kompromis medzi presnosťou a interpretovateľnosťou než tradičný model.

1.4.2 Prístup Black-box s post-hoc vysvetliteľnosťou: RNN a SHAP

Druhý významný smer v súčasnej literatúre, ktorý tvorí metodologické východisko empirickej časti tejto práce, reprezentuje štúdia Fasano a kol.. Autori sa v nej zaoberajú základnou otázkou finančného modelovania, a to napätím medzi interpretovateľnosťou modelu a jeho predikčnou presnosťou. V centre ich úvah stojí dilema, ktorú v kontexte modernej AI formalizoval Gunning, či má byť uprednostnený jednoduchý a transparentný model, alebo maximálne presný model aj za cenu obmedzenej vnútornej vysvetliteľnosti (Fasano et al., 2025; Gunning, 2019).

Fasano a kol. vychádzajú z predpokladu, že v oblasti predikcie podnikových kríz majú chyby II. typu, teda neodhalenie finančného zlyhania, zásadné ekonomické dôsledky pre veriteľov a ďalšie zainteresované subjekty. Z tohto dôvodu považujú maximalizáciu predikčnej výkonnosti za prioritný cieľ a poukazujú na limity tradičných parametrických metód, ktoré často nedokážu zachytiť komplexné nelineárne vzťahy vo finančných dátach. Ako alternatívu navrhujú využitie pokročilých algoritmov hlbokého učenia. Ich prístup je založený na koncepcii finančného zdravia podniku ako dynamického procesu, ktorý sa vyvíja v čase. Na zachytenie tejto dynamiky implementujú rekurentné neurónové siete s architektúrou LSTM, ktoré sú schopné spracovávať sekvenčné dáta a modelovať časový vývoj finančných ukazovateľov, napríklad postupné zhoršovanie likvidity alebo rast zadlženosti v období pred bankrotom (Fasano et al., 2025; Hochreiter & Schmidhuber, 1997).

Jednou z hlavných výhrad voči neurónovým sieťam v bankovníctve je ich nízka transparentnosť. Fasano a kol. tento problém riešia prostredníctvom *post-hoc* vysvetliteľnosti. Samotný predikčný model je ponechaný v režime *black-box*, aby sa zachoval jeho plný výpočtový potenciál, a interpretácia výsledkov je realizovaná dodatočne pomocou metódy SHAP. Autori ukazujú, že tento dvojstupňový prístup vedie k synergickému efektu. Na jednej strane LSTM model dosahuje na testovacej vzorke talianskych podnikov výrazne vyššiu predikčnú výkonnosť v porovnaní s tradičnými štatistickými metódami aj so štandardnými algoritmami strojového učenia, pričom hodnota AUC presahuje 90 %. Na druhej strane SHAP analýza umožňuje identifikovať kľúčové determinanty finančnej tiesne, predovšetkým ukazovatele zadlženosti a rentability aktív. Výsledky sú tak v súlade s ekonomickou teóriou, pričom zároveň odhaľujú nelineárne prahové efekty, ktoré zostávajú pre lineárne modely nedostupné. Analýza prístupu Fasano a kol. zároveň poukazuje na viaceré metodologické aspekty relevantné pre túto diplomovú

prácu. Autori zdôrazňujú potrebu riešenia nevyváženosti tried pomocou techniky SMOTE, keďže bez jej aplikácie majú neurónové siete tendenciu podceňovať zriedkavé prípady bankrotu. Zároveň upozorňujú na vysokú výpočtovú náročnosť tréningu LSTM sietí a na potrebu dostatočne dlhých historických časových radov, čo môže predstavovať limitujúci faktor najmä v ekonomikách s kratšou históriou trhového vývoja. V kontexte tejto diplomovej práce predstavuje prístup Fasano a kol. metodologický rámec označený ako Model 2. Slúži na overenie hypotézy, že kombinácia komplexného predikčného modelu založeného na rekurentných neurónových sieťach a externej *post-hoc* vysvetliteľnosti prostredníctvom SHAP poskytuje nielen vyššiu predikčnú presnosť v porovnaní s tradičnými metódami, ale aj porovnateľnú úroveň informačnej hodnoty pre koncového používateľa (Fasano et al., 2025).

1.4.3 Glass-box prístup novej generácie: Explainable Boosting Machine

Tretí metodologický smer, ktorý v súčasnej literatúre reprezentuje najnovší vývoj v oblasti XAI, sa vedome odkláňa od využívania netransparentných modelov. Kľúčovým príspevkom v tomto smere je štúdia Maturo a kol. (2025). Autori v nej spochybňujú dlhodobo prevládajúcu paradigmu, že vysoká presnosť predikcie je dosiahnuteľná len za cenu straty transparentnosti. Maturo a kol. navrhujú riešenie založené na vnútorne interpretovateľných modeloch, pričom kriticky poukazujú na limity *post-hoc* vysvetľovacích techník, ako je SHAP. Podľa Rudinovej, ktorej argumentáciu štúdia preberá, tieto metódy predstavujú len aproximáciu správania komplexného modelu a v určitých situáciách môžu viesť k nejednoznačným alebo zavádzajúcim interpretáciám. Ako alternatívu aplikujú model EBM, ktorý patrí do kategórie *glass-box* modelov a poskytuje transparentnosť priamo na úrovni modelovej štruktúry. EBM vychádza z triedy GAM, ktoré pôvodne definovali Hastie a Tibshirani. Na rozdiel od logistickej regresie, ktorej využitie v predikcii bankrotu ukotvil Ohlson, a ktorá je limitovaná predpokladom linearity, EBM využíva moderné techniky gradientného zosilňovania (*Gradient Boosting*). Metodologický základ pre EBM, konkrétne model GA2M vyvinuli Lou, Caruana, Gehrke a Hooker. Týmto spôsobom je možné zachytiť komplexné vzorce správania finančných ukazovateľov pri zachovaní plnej interpretovateľnosti výsledkov (Hastie & Tibshirani, 2017; Lou, 2013; Rudin, 2019).

Analýza realizovaná na rozsiahlej vzorke talianskych podnikov potvrdila, že model EBM dosahuje predikčnú výkonnosť vyjadrenú pomocou AUC, ktorá bola štatisticky nerozlíšiteľná od najvýkonnejších *black-box* algoritmov, ako sú *XGBoost* či *Random Forest*,

a zároveň výrazne prekonala logistickú regresiu. Tieto zistenia naznačujú, že pri tabuľkových finančných dátach nie je nevyhnutné obetovať transparentnosť v prospech presnosti. Významnou pridanou hodnotou EBM je schopnosť automaticky identifikovať párové interakcie medzi finančnými ukazovateľmi. Maturo a kol. napríklad preukazujú, že kombinácia nízkej likvidity a nízkej rentability vedie k multiplikatívnemu nárastu rizika, čo by pri lineárnych modeloch zostalo neodhalené (Maturo et al., 2025).

1.4.4 Syntéza poznatkov a identifikácia výskumnej medzery

Porovnanie uvedených prístupov ukazuje, že súčasná literatúra v oblasti predikcie bankrotu sa nesústreďuje iba na výber jedného dominantného algoritmu, ale na hľadanie vhodného vzťahu medzi predikčnou výkonnosťou, interpretovateľnosťou a praktickou použiteľnosťou modelu. Logistická regresia ponúka vysokú transparentnosť a jednoduchú ekonomickú interpretáciu, no je limitovaná pri zachytávaní nelinearít a interakcií. RNN+SHAP umožňuje modelovať časový vývoj finančného zdravia podniku a dosahovať vysokú predikčnú výkonnosť, avšak za cenu vyššej výpočtovej náročnosti a závislosti od *post-hoc* vysvetlenia. EBM sa naopak usiluje spojiť flexibilitu nelineárneho modelovania s vnútornou interpretovateľnosťou, čo z neho robí perspektívny prístup najmä pri rozsiahlych tabuľkových finančných dátach. Základné metodické rozdiely medzi logistickou regresiou, *black-box* modelmi a *glass-box* modelmi sú prehľadne zhrnuté v Tabuľke č.2, ktorá zároveň ukazuje ich rozdielnu úlohu v empirickej časti tejto práce.

Napriek rastúcemu počtu zahraničných štúdií zostáva otvorenou otázkou, ako sa tieto prístupy správajú v podmienkach malej a vysoko otvorenej ekonomiky, akou je Slovenská republika. Slovenské podnikateľské prostredie sa vyznačuje vysokým podielom malých a stredných podnikov, výraznou triednou nevyváženosťou pri pozorovaní zlyhaní a špecifickou dostupnosťou účtovných údajov prostredníctvom RÚZ. Tieto podmienky vytvárajú vhodný priestor na empirické porovnanie tradičného štatistického modelu, sekvenčného *black-box* prístupu s *post-hoc* vysvetlením a moderného *glass-box* modelu.

Výskumná medzera preto nespočíva iba v absencii aplikácie konkrétneho algoritmu na slovenské dáta. Podstatnejšia je chýbajúca komparatívna analýza, ktorá by súčasne zohľadnila diskriminačnú výkonnosť, schopnosť pracovať s nevyváženými dátami, interpretovateľnosť výstupov a použiteľnosť modelu. Práve táto diplomová práca sa usiluje túto medzeru čiastočne zaplniť tým, že porovnáva logistickú regresiu, RNN so SHAP

vysvetlením a EBM na jednotnom dátovom základe slovenských podnikov. Na základe uvedeného teoretického rámca možno formulovať aj hlavný metodologický zámer práce, ktorý má za úlohu overiť, či moderné prístupy XAI dokážu zlepšiť predikciu zlyhania slovenských podnikov v porovnaní s tradičnou logistickou regresiou, a zároveň posúdiť, ktorý z nich poskytuje vhodnejší kompromis medzi presnosťou a interpretovateľnosťou. Výsledky tak môžu prispieť nielen k akademickej diskusii o modelovaní bankrotu, ale aj k praktickej otázke, aké typy modelov sú použiteľné pre transparentné a obhájiteľné riadenie rizika v slovenskom prostredí.

Tabuľka č.2: Porovnanie logistickej regresie, black-box a glass-box modelov

Kritérium	**Logistická regresia**	**Black-box modely**	**Glass-box modely**
Základný princíp	Štatistický model odhadujúci pravdepodobnosť zlyhania pomocou lineárnej kombinácie premenných.	Komplexné modely strojového alebo hlbokého učenia s nepriamo interpretovateľnou štruktúrou; vysvetlenie sa dopĺňa dodatočne.	Modely s vnútorne interpretovateľnou štruktúrou, ktoré zároveň zachytávajú nelineárne vzťahy.
Typické príklady	Logit, Probit	Rekurentné neurónové siete, Random Forest	Explainable Boosting Machine
Interpretovateľnosť	Veľmi vysoká, cez koeficient a pomery šancí	Nízka vnútorná, vysvetlenie pomocou externých nástrojov, napríklad SHAP a LIME	Vysoká; model priamo vizualizuje vplyv premenných aj ich interakcií.
Schopnosť zachytiť interakcie premenných	Obmedzená, musia byť vopred špecifikované.	Vysoká, interakcie sa učia automaticky	Stredná až vysoká, vybrané interakcie možno modelovať
Vhodnosť pre časové dáta	Obmedzená, časovú dynamiku zachytáva len cez odvodené premenné.	Vysoká pri RNN a LSTM, ktoré pracujú s časovým vývojom podniku.	Stredná, časovú dynamiku zachytáva cez odvodené premenné.
Práca s nevyváženými dátami	Možná cez váženie tried, úpravu prahu alebo nákladovo citlivé učenie.	Vyžaduje ošetrenie nevyváženosti, napríklad SMOTE, váženie tried alebo focal loss.	Často sa kombinuje s podvzorkovaním alebo vážením tried.
Výpočtová náročnosť	Nízka, model je rýchly a ľahko reprodukovateľný.	Vysoká, najmä pri hlbokých sieťach a ladení hyperparametrov.	Stredná, náročnejšia než logit, no menej než hlboké siete.
Nároky na veľkosť a kvalitu dát	Nižšie, vhodná aj pri menších štruktúrovaných vzorkách.	Vysoké, vyžadujú dostatok dát na stabilné učenie.	Stredné až vyššie, vhodné pre väčšie tabuľkové dáta.
Hlavné výhody	Jednoduchosť, stabilita, rýchla interpretácia a nízka výpočtová náročnosť.	Vysoká výkonnosť a schopnosť zachytiť komplexné vzory, interakcie aj časovú dynamiku.	Kombinujú vysokú interpretovateľnosť so zachytením nelineárnych vzťahov.
Hlavné nevýhody	Predpoklad lineárnych vzťahov, nižšia flexibilita a potreba ručných transformácií.	Nízka transparentnosť, vyššia náročnosť, riziko preučenia a závislosť od post-hoc vysvetlení.	Vyššia metodická zložitosť, interpretácia je náročnejšia pri mnohých premenných a interakciách.
Úlohy v diplomovej práci	Referenčný model na porovnanie prínosu pokročilejších prístupov.	Reprezentuje výkonný model s dodatočným vysvetlením pomocou SHAP.	Reprezentuje presný model bez straty vnútornej transparentnosti.

2 Cieľ práce

Cieľom praktickej časti je empiricky posúdiť, do akej miery dokážu metódy XAI zlepšiť diskriminačnú schopnosť, praktickú využiteľnosť a interpretovateľnosť predikcie zlyhania slovenských firiem v porovnaní s tradičnou logistickou regresiou. Takto formulovaný cieľ priamo nadväzuje na dlhodobú výskumnú líniu zaoberajúcu sa modelovaním podnikových zlyhaní, ktorú založil Altman (1968) a ktorú v posledných rokoch rozšírili štúdie aplikujúce nelineárne a hlboké učenie (Altman,1968). Praktická časť nadväzuje na teoretickú časť práce, v ktorej boli rozpracované limity lineárnych štatistických modelov, princípy vysvetliteľnej umelej inteligencie a osobitosti klasifikácie extrémne nevyvážených dát v úlohách finančného rizika.

Výskumná otázka práce je formulovaná nasledovne: Do akej miery dokážu metódy XAI, konkrétne EBM a rekurentná neurónová sieť so Shapleyho aditívnym vysvetlením, zlepšiť výkonnosť a interpretovateľnosť predikcie zlyhania slovenských firiem v porovnaní s tradičnou logistickou regresiou? Takto formulovaná otázka predpokladá dvojrozmerné hodnotenie modelov, jednak z hľadiska diskriminačnej schopnosti a jednak z hľadiska vysvetliteľnosti rozhodnutia.

Empirický cieľ práce možno rozdeliť do troch čiastkových úloh. Prvou je zostrojenie porovnávacieho logistického modelu, ktorý vychádza z metodickej logiky Káčera a Alexyho (2025) pre slovenské podniky a zohľadňuje odporúčania Altmana et al. (2010) týkajúce sa dôkladnej práce s finančnými pomerovými ukazovateľmi u neverejne obchodovaných firiem (Káčer a Alexy, 2025; Altman et al., 2010). Druhou úlohou je odhad modelu EBM ako vysvetliteľného nelineárneho prístupu inšpirovaného prácou Maturo et al. (2025), ktorý má zachytiť nelineárne a interakčné vzťahy medzi finančnými ukazovateľmi a pravdepodobnosťou zlyhania (Maturo et al., 2025). Treťou je odhad sekvenčného modelu BiLSTM s *attention* mechanizmom a SHAP vysvetlením, ktorý nadväzuje na architektúry používané v štúdií Fasano et al. (2025) a ktorý umožňuje sledovať vývoj rizikového signálu v čase. Všetky tri modely sú hodnotené pri jednotnom testovacom horizonte rokov 2018 až 2019 (Fasano et al., 2025).

3 Metodika a metódy skúmania

3.1 Výskumný dizajn a metodický rámec

Výskumná časť diplomovej práce je založená na kvantitatívnom predikčnom výskume, ktorého cieľom je overiť, do akej miery dokážu moderné metódy vysvetliteľnej umelej inteligencie zlepšiť predikciu zlyhania slovenských podnikov v porovnaní s tradičným ekonometrickým prístupom. Skúmaný problém je formulovaný ako binárna klasifikačná úloha, v ktorej sa na základe informácií dostupných v roku účtovnej závierky odhaduje pravdepodobnosť zlyhania podniku v nasledujúcom roku. Cieľová premenná preto nadobúda hodnotu 1 v prípade, že podnik zlyhá v období t + 1, a hodnotu 0 v prípade, že k zlyhaniu v nasledujúcom období nedôjde. Takáto formulácia zodpovedá logike modelov včasného varovania, ktorých účelom nie je spätne vysvetľovať už nastané zlyhanie, ale identifikovať podniky so zvýšeným rizikom ešte pred samotnou udalosťou zlyhania (Wilson et al., 2014). Na splnenie tohto cieľa bol zvolený metodický rámec postavený na porovnaní troch odlišných modelových prístupov. Prvý prístup predstavuje logistická regresia, ktorá slúži ako tradičné ekonometrické meradlo výkonnosti. Jej zaradenie je dôležité najmä z dôvodu transparentnosti, jednoduchej interpretácie koeficientov a dlhodobej používanosti v literatúre o predikcii podnikových zlyhaní (Káčer a Alexy, 2025). Druhý prístup predstavuje EBM, ktorý reprezentuje nelineárny, ale stále vysvetliteľný model strojového učenia. Tento model umožňuje zachytiť nelineárne vzťahy medzi finančnými ukazovateľmi a rizikom zlyhania bez úplnej straty interpretovateľnosti (Maturo et al., 2025). Tretí prístup tvorí sekvenčný model BiLSTM, ktorý umožňuje pracovať s časovým vývojom finančných ukazovateľov a testovať, či explicitné modelovanie dynamiky finančného zdravia podniku prináša dodatočnú predikčnú hodnotu oproti statickým modelom (Fasano et al., 2025).

Výskumný dizajn je postavený na chronologickom členení dát, nie na náhodnom rozdelení pozorovaní. Tento postup je metodicky dôležitý, pretože predikcia podnikového zlyhania má prirodzene časový charakter. Modely sú odhadované na historických údajoch, validačná vzorka slúži na výber modelových nastavení a finálne hodnotenie sa realizuje na budúcich obdobiach, ktoré neboli použité pri odhade modelov. Takýto prístup lepšie simuluje reálnu aplikáciu predikčného modelu v praxi a zároveň obmedzuje riziko informačného úniku medzi tréningovou a testovacou vzorkou. Všetky transformačné pravidlá, výberové rozhodnutia a parametre predspracovania sú preto odvodené výlučne z tréningovej alebo validačnej časti dát a následne aplikované na testovacie obdobie. Z

metodologického hľadiska práca nehodnotí modely iba podľa celkovej predikčnej presnosti, ale aj podľa ich interpretovateľnosti a praktickej použiteľnosti. Pri predikcii podnikových zlyhaní je samotná klasifikačná presnosť nedostatočná, najmä vzhľadom na extrémne nízky výskyt pozitívnej triedy. Z tohto dôvodu je dôraz kladený na schopnosť modelov správne zoradiť podniky podľa rizika, identifikovať najrizikovejšie skupiny podnikov a zároveň poskytnúť ekonomicky interpretovateľné vysvetlenie výsledkov. Logistická regresia umožňuje interpretáciu prostredníctvom znamienok koeficientov a odds ratio, EBM prostredníctvom tvarových funkcií a globálnej dôležitosti premenných a BiLSTM prostredníctvom *post-hoc* vysvetlení založených na SHAP hodnotách. Osobitnou metodologickou výzvou je extrémna nevyváženosť cieľovej premennej. Zlyhanie podniku predstavuje v analyzovaných dátach veľmi zriedkavú udalosť, čo ovplyvňuje výber modelov, spôsob ich trénovania aj interpretáciu hodnotiacich metrík. Práca preto nepoužíva jednotný spôsob ošetrenia nevyváženosti pre všetky modely, ale aplikuje modelovo špecifické riešenia. Logistická regresia je ponechaná ako ekonometrický referenčný model, EBM pracuje s vážením tried alebo výberom vzorky v tréningovej fáze a BiLSTM využíva focal loss v kombinácii s vyváženými dávkami. Spoločným princípom je, že validačné a testovacie obdobie si zachovávajú pôvodnú distribúciu tried, aby výsledné hodnotenie zodpovedalo reálnej miere výskytu zlyhaní.

Celková metodika práce je teda založená na porovnaní lineárneho ekonometrického modelu, vysvetliteľného nelineárneho modelu a sekvenčného neurónového modelu v jednotnom časovom hodnotiacom rámci. Takto zvolený prístup umožňuje posúdiť nielen to, ktorý model dosahuje najvyššiu diskriminačnú schopnosť, ale aj to, aký kompromis ponúka medzi presnosťou, transparentnosťou, ekonomickou interpretovateľnosťou a praktickým využitím v systémoch včasného varovania. Cieľom empirickej analýzy preto nie je iba maximalizovať predikčnú výkonnosť, ale vyhodnotiť, či metódy vysvetliteľnej umelej inteligencie dokážu pri práci s verejne dostupnými účtovnými údajmi poskytnúť lepší pomer medzi predikčnou silou a interpretovateľnosťou než tradičná logistická regresia.

3.2. Dáta a príprava datasetu

Analýza vychádza z individuálnych účtovných údajov slovenských podnikov získaných z Registra účtovných závierok Slovenskej republiky. Východiskový panel obsahoval 1 591 645 firmo-rokov, 48 premenných a pokrýval obdobie rokov 2011 až 2019. Základnými identifikačnými premennými boli identifikátor podniku, rok účtovnej závierky

a binárna cieľová premenná target. Tá bola definovaná v predikčnom horizonte jedného roka, teda ako indikátor zlyhania podniku v období t + 1. Hodnota 1 označovala firmo-rok, po ktorom nasledovalo právne identifikovateľné zlyhanie podniku v zmysle konkurzu alebo reštrukturalizácie podľa zákona č.7/2005 Z. z. o konkurze a reštrukturalizácii, zatiaľ čo hodnota 0 označovala firmo-rok bez zlyhania v nasledujúcom období. V pôvodnom datasete sa nachádzalo 3 431 pozitívnych pozorovaní, čo predstavuje mieru zlyhania 0,2155 %. Ide teda o extrémne nevyváženú binárnu klasifikačnú úlohu, pri ktorej na jedno zlyhanie pripadá približne 463 nezlyhaných pozorovaní. V porovnaní s dátami použitými v zahraničných štúdiách, najmä Fasano et al. (2025) a Maturo et al. (2025), je zastúpenie pozitívnej triedy v tejto práci výrazne nižšie, čo následne ovplyvňuje výber modelových metrík aj interpretáciu klasifikačných prahov (Fasano et al., 2025; Maturo et al., 2025).

Východiskový dátový súbor bol spracovaný zo surového exportu účtovných údajov. Pri načítaní dát boli v použitej verzii exportu preskočené prvé tri riadky a názvy stĺpcov boli explicitne definované podľa štruktúry dátového zdroja. Textové premenné, najmä identifikátor firmy, kód SK NACE, právna forma a dátum vzniku podniku, boli ponechané ako reťazce. Ostatné premenné boli konvertované na numerický formát, pričom hodnoty, ktoré nebolo možné interpretovať ako čísla, boli prevedené na chýbajúce hodnoty. Po načítaní boli pozorovania zoradené podľa identifikátora firmy a roku účtovnej závierky, aby bolo možné korektne vytvárať časovo oneskorené a diferenčné premenné. Časové členenie vzorky bolo zvolené chronologicky, nie náhodne. Roky 2011 a 2012 boli ponechané v dátach najmä na konštrukciu historických a sekvenčných premenných. Do tréningového obdobia boli zaradené roky 2013 až 2016, validačnú vzorku tvoril rok 2017 a testovacia vzorka zahŕňala roky 2018 a 2019 (Tabuľka č.3). Takéto časové členenie rešpektuje chronologickú povahu predikčného problému a simuluje reálnu situáciu, v ktorej sa model odhaduje na historických údajoch a následne aplikuje na budúce obdobia (Káčer a Alexy, 2025). Na rozdiel od náhodného delenia dát tento postup znižuje riziko informačného úniku medzi vzorkami.

Tabuľka č.3: Rozdelenie dátového súboru podľa rokov účtovných závierok

Vzorka	**Roky**
Tréningová vzorka	2013 - 2016
Validačná vzorka	2017
Testovacia vzorka	2018 - 2019

Z pôvodných účtovných položiek boli vytvorené finančné pomerové ukazovatele zachytávajúce likviditu, zadlženosť, kapitálovú štruktúru, rentabilitu, prevádzkovú výkonnosť a aktivitu podniku. Pri výpočte pomerových ukazovateľov bolo použité bezpečné delenie (*safe divide*). Ak bol menovateľ nulový, chýbajúci alebo nebolo možné korektne vypočítať výsledok, hodnota pomerového ukazovateľa bola ponechaná ako chýbajúca hodnota. Tým sa zabránilo vzniku nekonečných alebo ekonomicky neinterpretovateľných hodnôt. Medzi vytvorené premenné patrili najmä *cash_ta, current_ratio, quick_ratio, eq_ta, ltd_ta, bl_ta, debt_to_equity, debt_ratio, fixed_asset_coverage, short_debt_ratio, roa1, re_ta, roe, ros, roi, ebitda, ebitda_margin, debt_ebitda, asset_turnover, creditors_days, receivables_days* a *interest_coverage*. EBITDA bola vypočítaná ako súčet výsledku hospodárenia z hospodárskej činnosti a odpisov, pričom chýbajúce hodnoty týchto dvoch zložiek boli pri samotnom výpočte nahradené nulou. Z EBITDA boli následne odvodené ďalšie ukazovatele, najmä *ebitda_margin, debt_ebitda* a *interest_coverage*. Premenné *interest_coverage* a *debt_ebitda*, pri ktorých môžu vznikať extrémne hodnoty v dôsledku nízkeho alebo záporného menovateľa, boli ešte pred winsorizáciou orezané na ekonomicky interpretovateľné intervaly. *Interest_coverage* na interval od −100 do 100 a *debt_ebitda* na interval od −50 do 50.

Do datasetu boli následne zahrnuté aj nefinančné, odvetvové a makroekonomické premenné. Z dátumu vzniku spoločnosti bol odvodený rok založenia podniku a následne vek firmy v príslušnom roku účtovnej závierky. Keďže vek podniku môže mať nelineárny vzťah k riziku zlyhania, bola vytvorená aj jeho logaritmická transformácia *age_log*. Právna forma bola zachytená pomocou binárnej premennej *joint_stock*, ktorá nadobúdala hodnotu 1 v prípade akciovej spoločnosti a hodnotu 0 pri ostatných právnych formách. Veľkostná kategória podniku bola vyjadrená pomocou premenných *micro_company, small_company* a *medium_company*, odvodených z počtu zamestnancov. Podniky s chýbajúcim údajom o počte zamestnancov boli z dôvodu zachovania vzorky zaradené medzi mikropodniky. Odvetvová heterogenita bola kontrolovaná prostredníctvom *dummy* premenných odvodených z textovej kategórie odvetvia. Každá *dummy* premenná nadobudla hodnotu 1 v prípade, že podnik patril do príslušnej odvetvovej skupiny, a hodnotu 0 v opačnom prípade. Takéto zakódovanie umožnilo modelom zohľadniť rozdiely v riziku zlyhania medzi jednotlivými odvetviami, napríklad medzi stavebnictvom, veľkoobchodom, zdravotníctvom, službami, nehnuteľnosťami alebo dopravou a logistikou. Makroekonomické premenné boli priradené na úrovni kalendárneho roka a zahŕňali

medziročnú zmenu hrubého domáceho produktu, mieru nezamestnanosti, zmenu zamestnanosti podľa metodiky ESA, rast nominálnej mzdy, infláciu meranú harmonizovaným indexom spotrebiteľských cien, refinančnú sadzbu Európskej centrálnej banky, priemernú hodnotu trojmesačného EURIBOR-u a podiel verejného dlhu na hrubom domácom produkte. Tieto premenné umožňujú kontrolovať vplyv makroekonomického cyklu, trhu práce, cenového vývoja a úrokového prostredia na pravdepodobnosť podnikového zlyhania.

Analyzovaná vzorka bola následne obmedzená na malé a stredné podniky prostredníctvom zjemneného filtra veľkosti podniku a jeho aktivity, čiastočne podľa veľkostných kritérií použitých v nadväznosti na metodiku Káčera, Ochotnického a Alexyho (2019). Do vzorky boli zaradené podniky s menej ako 250 zamestnancami, pričom podniky s chýbajúcim údajom o počte zamestnancov neboli automaticky vyradené, ak spĺňali ostatné dostupné kritéria veľkosti a aktivity. Finančne veľkostné kritérium bolo definované ako celkové aktíva nižšie ako 43 mil. EUR alebo celkové tržby nižšie ako 50 mil. EUR. Súčasne bol aplikovaný filter aktivity, podľa ktorého museli celkové aktíva dosahovať aspoň 5 000 EUR a tržby aspoň 5 000 EUR v prípade, že bol údaj o tržbách dostupný. Podniky s chýbajúcim údajom o tržbách neboli automaticky vyradené, ak spĺňali ostatné dostupné kritériá (Viď. príloha). Tento zjemnený režim filtra bol zvolený preto, aby sa obmedzil vplyv formálne existujúcich alebo ekonomicky neaktívnych subjektov, ale zároveň aby nedochádzalo k nadmernému znižovaniu vzorky v dôsledku chýbajúcich údajov.

Po aplikácii filtra veľkosti a aktivity sa počet pozorovaní pre logistickú regresiu a EBM znížil na 1 085 539 firmo-rokov. Vo filtrovanej vzorke sa nachádzalo 1 995 pozitívnych pozorovaní, čo zodpovedá miere zlyhania približne 0,184 %. Sekvenčný dataset pre BiLSTM bol následne dodatočne obmedzený na podniky s minimálne dvoma po sebe nasledujúcimi rokmi dostupných údajov, aby bolo možné vytvoriť časové sekvencie. Po tejto úprave obsahoval 756 077 firmo-rokov a miera zlyhania dosiahla 0,176 % (Tabuľka č.4).

Tabuľka č.4: Veľkosť modelových vzoriek po aplikácii filtra veľkosti a aktivity

Dataset	**Riadky**	**Train**	**Valid**	**Test**	**Miera zlyhania**
Logit	1 085 539	543 710	159 248	348 891	0,184 %
EBM	1 085 539	543 710	159 248	348 891	0,184 %
BiLSTM/RNN	756 077	336 895	127 687	285 092	0,176 %

Extrémne hodnoty odvodených finančných premenných boli ošetrené winsorizáciou na 5. a 95. percentile. Winsorizačné hranice boli odhadnuté výlučne z tréningového obdobia 2013 až 2016 a následne aplikované na celý dataset vrátane validačného a testovacieho obdobia. Tento postup zabezpečuje, že transformačné pravidlá nie sú ovplyvnené budúcimi pozorovaniami, a tým znižuje riziko informačného úniku (Káčer a Alexy, 2025). Keďže modelové datasety už obsahovali winsorizované finančné ukazovatele, winsorizácia nebola v jednotlivých modelových notebookoch opakovane aplikovaná. Na zachytenie dynamiky finančnej situácie podnikov boli pre 14 vybraných finančných ukazovateľov vytvorené oneskorené a diferenčné premenné. Išlo o premenné *cash_ta, eq_ta, ltd_ta, roa1, re_ta, roe, ros, current_ratio, quick_ratio, debt_ratio, debt_ebitda, ebitda_margin, interest_coverage* a *asset_turnover*. Pre každý ukazovateľ bola vytvorená hodnota z predchádzajúceho roka, hodnota spred dvoch rokov a dve diferenčné premenné vyjadrujúce rozdiel aktuálnej hodnoty oproti týmto oneskoreným hodnotám. Celkovo tak vzniklo 56 dynamických premenných s príponami *_lag1, _lag2, _diff1* a *_diff2*. Modely tak nezohľadňovali iba aktuálnu úroveň finančných ukazovateľov, ale aj smer a intenzitu ich zhoršovania alebo zlepšovania v čase, čo je pri hodnotení finančného zdravia podnikov osobitne dôležité (Gavurová et al., 2017).

Chýbajúce hodnoty boli spracované modelovo špecifickým spôsobom. Pri logistickej regresii boli odvodené finančné pomerové ukazovatele imputované mediánmi vypočítanými výlučne z tréningového obdobia 2013 až 2016, čím sa zachoval konzistentný počet premenných medzi tréningovou, validačnou a testovacou vzorkou (Káčer a Alexy 2025). Surové účtovné položky boli ponechané bez imputácie pre následný dopočet referenčných premenných v modelovom notebooku. Pri modeli EBM boli chýbajúce numerické hodnoty nahradené technickou hodnotou −999, čo modelu umožnilo vytvoriť osobitné biny pre neznáme hodnoty bez umelej imputácie (Nori et al., 2019). Pri BiLSTM boli nekonečné hodnoty najskôr prevedené na chýbajúce hodnoty a následne boli modelové premenné imputované mediánom z tréningovej vzorky. Ak medián nebolo možné vypočítať, bola použitá hodnota 0. Škálovanie vstupov BiLSTM bolo realizované až v modelovom notebooku, pričom škálovacie parametre boli odhadnuté výlučne na tréningovej vzorke.

Z dôvodu odlišných štatistických a algoritmických požiadaviek jednotlivých modelov boli z predspracovaného panelu exportované tri modelovo špecifické datasety. Dataset data_logit.csv bol určený pre logistickú regresiu a obsahoval surové účtovné položky potrebné na dopočet ekonometrického porovnávacieho štandardu, odvodené finančné ukazovatele, nefinančné premenné, odvetvové *dummy* premenné a

makroekonomické premenné. Dataset data_ebm.csv bol určený pre EBM a obsahoval širší súbor premenných vrátane oneskorených a diferenčných ukazovateľov, pričom chýbajúce numerické hodnoty boli reprezentované hodnotou −999. Dataset data_rnn.csv bol určený pre BiLSTM a obsahoval sekvenčné finančné premenné, ich dynamické transformácie, statické nefinančné, odvetvové a makroekonomické premenné. Takto pripravené datasety tvorili vstup do samostatných modelových pipeline-ov, pričom ďalšie modelovo špecifické úpravy, ako výber premenných, práca s nevyváženosťou tried, ladenie hyperparametrov a finálne hodnotenie modelov, sú opísané v nasledujúcich podkapitolách (Tabuľka č.5).

Tabuľka č.5: Charakteristika exportovaných modelovo špecifických datasetov

Dataset	**Účel**	**Stĺpce**
data_logit.csv	logistická regresia	94
data_ebm.csv	EBM	155
data_rnn.csv	BiLSTM	126

3.3 Modelové metódy

V analytickej časti práce boli použité tri modelové prístupy, ktoré sa líšia funkčným tvarom, spôsobom práce s vysvetľujúcimi premennými, mierou interpretovateľnosti a schopnosťou zachytiť časovú dynamiku finančných ukazovateľov. Prvým modelom bola logistická regresia, ktorá predstavuje tradičný ekonometrický porovnávací štandard a umožňuje priamu interpretáciu koeficientov prostredníctvom znamienok a pomeru šancí (Káčer a Alexy, 2025). Druhým modelom bol EBM, ktorý reprezentuje vysvetliteľný nelineárny model strojového učenia schopný zachytiť nelineárne vzťahy a interakcie medzi premennými pri zachovaní interpretovateľnej štruktúry modelu (Maturo et al., 2025). Tretím modelom bol sekvenčný model BiLSTM, ktorý bol zaradený s cieľom overiť, či explicitné modelovanie vývoja finančných ukazovateľov v čase prináša dodatočnú predikčnú hodnotu oproti statickým modelom (Fasano et al., 2025).

Výber týchto troch metód bol motivovaný snahou porovnať klasický ekonometrický prístup s modernými metódami vysvetliteľnej umelej inteligencie. Logistická regresia slúži ako transparentný referenčný model, ktorý je v literatúre o predikcii podnikového zlyhania dlhodobo používaný (Ohlson, 1980). EBM umožňuje testovať, či nelineárne, ale stále interpretovateľné modelovanie dokáže zvýšiť diskriminačnú schopnosť bez úplnej straty

vysvetliteľnosti. BiLSTM následne rozširuje modelový rámec o sekvenčnú štruktúru, keďže riziko zlyhania podniku môže byť ovplyvnené nielen aktuálnou úrovňou finančných ukazovateľov, ale aj ich predchádzajúcim vývojom. Modely preto predstavujú tri rozdielne prístupy k rovnakému predikčnému problému: lineárny ekonometrický model, nelineárny *glass-box* model a sekvenčný neurónový model.

3.3.1 Logistická regresia

Logistická regresia bola v práci použitá ako základný ekonometrický referenčný štandard, voči ktorému sa porovnávali nelineárny model EBM a sekvenčný model BiLSTM. Jej zaradenie vychádza zo skutočnosti, že logistická regresia patrí medzi najpoužívanejšie metódy pri modelovaní kreditného a bankrotového rizika, pričom umožňuje priamu ekonomickú interpretáciu vzťahu medzi vysvetľujúcimi premennými a pravdepodobnosťou zlyhania podniku. Vzhľadom na binárny charakter cieľovej premennej model odhaduje logaritmus pomeru šancí zlyhania voči nezlyhaniu ako lineárnu funkciu vysvetľujúcich premenných (Ohlson, 1980):

$$log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \sum_{j=1}^{k} \beta_j X_{ij},$$

kde p_i predstavuje pravdepodobnosť zlyhania podniku i, X_{ij} sú vysvetľujúce premenné a β_j sú odhadované parametre modelu. Koeficienty logistickej regresie možno interpretovať prostredníctvom ich znamienka a pomeru šancí. Kladný koeficient znamená, že rast danej premennej zvyšuje odhadovaný pomer šancí zlyhania, zatiaľ čo záporný koeficient indikuje pokles rizika zlyhania pri raste príslušného ukazovateľa.

Modelový postup bol koncipovaný ako striktný ekonometrický referenčný model v nadväznosti na metodickú logiku Káčera a Alexyho (2025). Cieľom logistickej regresie preto nebolo maximalizovať predikčnú výkonnosť za každú cenu, ale vytvoriť transparentný, reprodukovateľný a ekonomicky interpretovateľný referenčný model. Do počiatočnej množiny kandidátnych premenných boli zaradené finančné ukazovatele likvidity, zadlženosti, kapitálovej štruktúry, rentability, aktivity, veľkosti a veku podniku. Zároveň boli do modelu zahrnuté odvetvové *dummy* premenné a ročné *dummy* premenné, aby model zachytával štrukturálnu heterogenitu podnikov podľa sektora a času. Pred samotným odhadom modelu bola vykonaná kontrola chýbajúcich hodnôt, nulovej variability a multikolinearity. Premenné s nadmerným podielom chýbajúcich hodnôt alebo bez variability v tréningovej vzorke neboli zaradené do ďalšieho výberu. Multikolinearita bola

kontrolovaná pomocou VIF, avšak iba pri spojitých premenných, pri ktorých má táto diagnostika štandardnú interpretáciu. Kategorické *dummy* bloky, teda odvetvové a ročné efekty, neboli posudzované rovnakým VIF filtrom ako spojité finančné premenné. Odvetvový blok bol doplnkovo diagnostikovaný pomocou generalizovaného VIF, keďže ide o skupinu vzájomne súvisiacich *dummy* premenných (Káčer a Alexy, 2025).

Aby sa predišlo problému úplnej *kolinearity* pri zahrnutí konštanty, bola z odvetvových *dummy* premenných vynechaná referenčná kategória *industry_stavebnictvo*. Referenčným rokom v ročných efektoch bol rok 2013, pričom do modelu vstupovali ročné *dummy* premenné *year_2014, year_2015* a *year_2016*. Pred odhadom modelu Logit 1 bola zároveň overená lineárna nezávislosť vysvetľujúcich premenných v dizajnovej matici. Na základe tejto kontroly bola z matice odstránená premenná *small_company*, ktorá bola identifikovaná ako presná lineárna kombinácia konštanty alebo predchádzajúcich premenných. Táto úprava bola technickým krokom potrebným na zabezpečenie overenia lineárnej nezávislosti vysvetľujúcich premenných dizajnovej matice a nesúvisela s dodatočným prispôsobovaním modelu testovacím dátam. Výber finálnej špecifikácie bol realizovaný dvojstupňovo. V prvom kroku bol odhadnutý rozšírený model Logit 1, ktorý slúžil na posúdenie štatistickej významnosti, očakávaných znamienok a stability kandidátnych premenných. Do Logit 1 vstupovala množina premenných po filtrovaní chýbajúcich hodnôt, kontrole multikolinearity a úprave dizajnovej matice z dôvodu presnej lineárnej závislosti. V druhom kroku bola odhadnutá finálna špecifikácia Logit 2, ktorá vznikla postupným prehodnocovaním modelovej špecifikácie a ponechaním premenných spĺňajúcich kritériá štatistickej významnosti, očakávaného ekonomického znamienka a interpretačnej stability. Výber premenných bol založený výlučne na tréningovej vzorke a validačnom nastavení, pričom testovacie obdobie rokov 2018 až 2019 nebolo použité pri výbere špecifikácie. Finálna špecifikácia Logit 2 obsahovala 22 premenných. Z finančných a nefinančných ukazovateľov boli ponechané premenné *eq_ta, bl_ta, roa1, ros, creditors_days* a *age_log*, doplnené o vybrané odvetvové *dummy* premenné a ročné efekty. Takáto špecifikácia umožňuje zachytiť kapitálovú vybavenosť, bankové financovanie, rentabilitu, ziskovú maržu, platobnú disciplínu, vek podniku, sektorovú heterogenitu a časové efekty tréningového obdobia.

Odhad logistickej regresie bol realizovaný metódou maximálnej vierohodnosti, ktorá umožňuje odhadnúť parametre modelu tak, aby maximalizovali pravdepodobnosť pozorovanej realizácie cieľovej premennej pri daných hodnotách vysvetľujúcich premenných (Long, 1997). Tento prístup poskytuje priamo interpretovateľné koeficienty a

umožňuje vyjadriť vplyv jednotlivých premenných prostredníctvom pomeru šancí. Zároveň však logistická regresia predpokladá lineárny vzťah medzi vysvetľujúcimi premennými a logaritmom šancí zlyhania, čo môže byť obmedzujúce pri finančných ukazovateľoch, pri ktorých sa môžu vyskytovať nelinearity, prahové efekty a asymetrické vzťahy.

3.3.2 Explainable boosting machine

Druhým použitým modelom bol EBM. Keďže jeho teoretická štruktúra a všeobecný tvar aditívneho modelu boli predstavené v teoretickej časti práce, v metodickej časti je dôraz kladený najmä na jeho empirické použitie. V tejto práci bol EBM použitý ako hlavný predstaviteľ vnútorne interpretovateľného nelineárneho modelovania (Maturo et al., 2025). Umožňuje totiž zachytiť nelineárne vzťahy medzi finančnými ukazovateľmi a pravdepodobnosťou zlyhania bez toho, aby bola interpretácia modelu odkázaná výlučne na dodatočné *post-hoc* metódy. Na rozdiel od logistickej regresie EBM nepredpokladá lineárny vzťah medzi vysvetľujúcimi premennými a logaritmom šancí zlyhania, ale pre jednotlivé premenné odhaduje samostatné tvarové funkcie, ktoré zachytávajú ich parciálny príspevok k predikovanej pravdepodobnosti. Tento prístup je vhodný najmä pri finančných pomerových ukazovateľoch, pri ktorých možno očakávať zložité nelinearity, prahové efekty alebo rozdielny vplyv extrémne nízkych a extrémne vysokých hodnôt. Model zároveň automaticky umožňuje zahrnúť vybrané párové interakcie, čím dokáže zachytiť situácie, v ktorých riziko zlyhania nevychádza iba z izolovanej hodnoty jednej premennej, ale z kombinácie viacerých finančných charakteristík (Lou et al., 2013)

Do EBM vstupoval širší súbor premenných než do logistickej regresie. Okrem základných finančných pomerových ukazovateľov model využíval aj surové účtovné položky, nefinančné charakteristiky podniku, odvetvové *dummy* premenné, makroekonomické premenné a dynamické premenné vo forme oneskorení a diferencií. Takáto špecifikácia umožňuje modelu zachytiť nielen statickú finančnú pozíciu podniku, ale aj zmeny v jeho finančnej situácii v čase. Chýbajúce numerické hodnoty boli v datasete pre EBM reprezentované technickou hodnotou −999, čo umožnilo modelu pracovať s chýbaním hodnoty ako s potenciálne informatívnym stavom bez potreby umelej imputácie dát. V empirickej pipeline boli pri EBM porovnané viaceré stratégie riešenia triednej nevyváženosti a finálny model bol vybraný na základe validačnej výkonnosti. Hyperparametre modelu boli ladené pomocou optimalizačného rámca založeného na *Tree Parzen Estimator* (TPE),

pričom výber finálnej špecifikácie bol realizovaný výlučne na validačnej vzorke, aby sa zabránilo prispôsobeniu modelu testovaciemu obdobiu. Finálny model bol následne použitý na mimovzorkové hodnotenie v rokoch 2018 až 2019 (Nori et al., 2019).

Výhodou EBM v kontexte tejto práce je jeho vnútorne interpretačná štruktúra. Model poskytuje globálnu dôležitosť premenných, tvarové funkcie hlavných efektov a vybrané interakčné efekty (Nori et al., 2019). Tieto výstupy umožňujú porovnať predikčnú výkonnosť EBM s logistickou regresiou a BiLSTM. Zároveň umožňujú analyzovať, ktoré finančné, nefinančné alebo dynamické faktory najviac prispievajú k odhadovanému riziku zlyhania. EBM preto v práci plní dvojitú úlohu, keďže predstavuje vysoko presný nelineárny predikčný model a zároveň transparentný nástroj na ekonomickú analýzu rizikových faktorov podnikového zlyhania.

3.3.3 BiLSTM

Tretím použitým modelom bol sekvenčný model BiLSTM, teda bidirekčná *Long Short-Term Memory* neurónová sieť. Tento model bol zaradený preto, že finančné zlyhanie podniku nemusí byť výsledkom iba aktuálnej hodnoty finančných ukazovateľov, ale môže vyplývať z postupného zhoršovania finančnej situácie v čase. Kým logistická regresia a EBM pracujú primárne so statickou reprezentáciou firmo-roku, BiLSTM umožňuje spracovať časovú postupnosť pozorovaní toho istého podniku a modelovať vývoj jeho finančných charakteristík. *Long Short-Term Memory* siete patria medzi rekurentné neurónové siete určené na prácu so sekvenčnými dátami, pričom ich výhodou je schopnosť uchovávať informáciu z predchádzajúcich časových krokov a pracovať s dlhodobejšími závislosťami (Hochreiter a Schmidhuber, 1997; Minh et al., 2021). V tejto práci bola použitá bidirekčná verzia LSTM, ktorá spracúva vstupnú sekvenciu v oboch smeroch v rámci dostupného historického okna. Model teda pracuje iba s dostupnou sekvenciou historických účtovných pozorovaní podniku, nie s budúcimi hodnotami mimo predikčného horizontu. Bidirekčnosť preto nepredstavuje informačný únik z budúcnosti, ale spôsob, ako v rámci dostupnej historickej sekvencie lepšie zachytiť vzory vývoja finančných ukazovateľov.

Vstup do BiLSTM bol vytvorený ako hybridná architektúra s dvoma vetvami. Prvú vetvu tvoril sekvenčný vstup obsahujúci finančné pomerové ukazovatele a ich dynamické transformácie, zatiaľ čo druhú vetvu tvorili statické vstupy, najmä nefinančné charakteristiky, odvetvové premenné a makroekonomické premenné. Maximálna dĺžka

sekvencie bola nastavená na štyri roky. Kratšie sekvencie boli doplnené nulami a v modeli bola použitá maskovacia vrstva, aby doplnené hodnoty nevstupovali do učenia ako reálne pozorovania. Tento postup umožnil zahrnúť podniky s rôznou dĺžkou dostupnej histórie bez toho, aby bolo potrebné obmedziť analýzu iba na subjekty s kompletnými údajmi za celé sledované obdobie, čím sa maximalizovalo využitie informácií z dostupných časových sekvencií (Fasano et al., 2025). Samotná architektúra modelu kombinovala sekvenčnú vetvu BiLSTM so statickou *dense* vetvou (Tabuľka č. 6). Sekvenčná časť zahŕňala maskovanie, regularizačnú vrstvu *Gaussian noise*, bidirekčnú LSTM vrstvu, *attention* mechanizmus, *batch* normalizáciu a *dropout*. *Attention* mechanizmus bol zaradený preto, aby model nemusel komprimovať celú sekvenciu iba do posledného skrytého stavu, ale mohol priradiť rozdielnu váhu jednotlivým časovým krokom. Statická vetva spracúvala nečasové charakteristiky podniku pomocou plne prepojenej vrstvy, *batch* normalizácie a *dropoutu*. Výstupy sekvenčnej a statickej vetvy boli následne spojené a vstupovali do finálnej dense hlavy so sigmoidnou výstupnou vrstvou, ktorá generovala odhad pravdepodobnosti zlyhania.

Tréning hlbokých neurónových sietí na GPU je inherentne stochastický proces, ktorého výstup závisí nielen od náhodnej inicializácie váh a mini-batch sampling, ale aj od konkrétnej verzie knižníc *TensorFlow* a *cuDNN*, použitého hardvéru a poradia paralelných numerických operácií. Pre zníženie variability výsledkov bol finálny model trénovaný ako 5-*seed ensemble*, ktorého predikcie boli spriemerované, pričom v rámci každého behu boli váhy z posledných epoch ďalej zhladené metódou *Stochastic Weight Averaging* (Izmailov et al., 2018). Výstupné pravdepodobnosti zlyhania boli následne kalibrované izotonickou regresiou na validačnom období, čím sa zlepšila zhoda predikovaných pravdepodobností s pozorovanými frekvenciami zlyhania. Všetky kvantitatívne výsledky uvedené v tejto práci pochádzajú z jediného uloženého behu trénovaného v prostredí Google Colab (TensorFlow 2.x, GPU NVIDIA T4) s pevne zvolenými inicializačnými *seedmi*. Pri opakovanom pretrénovaní na inej hardvérovej alebo softvérovej konfigurácii môžu absolútne hodnoty metrík kolísať v ráde tisícin AUC, kvalitatívne závery o relatívnom poradí modelov a o dôležitosti jednotlivých premenných však ostávajú stabilné.

Vstupy BiLSTM boli pred trénovaním škálované pomocou štandardizácie. Parametre škálovania boli odhadnuté výlučne na tréningovej vzorke a následne aplikované na validačné a testovacie obdobie. Sekvenčné a statické vstupy boli škálované samostatne, keďže majú odlišnú štruktúru aj distribúciu. Tento postup znižuje riziko informačného úniku a zároveň stabilizuje tréning neurónovej siete. Nevyváženosť tried bola pri BiLSTM riešená

v tréningovej fáze pomocou *focal loss* funkcie a *balanced batches* (Lin et al., 2020), pričom tento postup je podrobnejšie opísaný v samostatnej podkapitole venovanej nevyváženosti tried. Interpretácia BiLSTM bola doplnená pomocou SHAP hodnôt, keďže neurónové siete neumožňujú priamu interpretáciu koeficientov ako logistická regresia ani natívne tvarové funkcie ako EBM. SHAP hodnoty preto slúžia ako *post-hoc* vysvetľovacia metóda (Lundberg & Lee, 2017), ktorej cieľom je identifikovať, ktoré premenné a časové kroky najviac prispievali k predikovanej pravdepodobnosti zlyhania. V kontexte tejto práce je BiLSTM chápaný nielen ako alternatívny predikčný model, ale aj ako nástroj na overenie toho, či časový vývoj finančných ukazovateľov obsahuje dodatočnú informáciu nad rámec statickej reprezentácie firmo-roku.

Tabuľka č.6: Súhrn použitých modelových prístupov

Model	**Typ modelu**	**Hlavná úloha v práci**	**Forma interpretácie**
Logistická regresia	lineárny ekonometrický model	referenčný štandard	koeficient, znamienka, odds ratio
EBM	nelineárny glass-box model	hlavný vysvetliteľný model strojového učenia	globálna dôležitosť, tvarové funkcie, interakcie
BiLSTM	sekvenčná neurónová sieť	testovanie prínosu časovej dynamiky	SHAP hodnoty, význam časových krokov

Takto zvolená kombinácia modelov umožňuje porovnať tri odlišné metodologické prístupy k predikcii podnikového zlyhania. Logistická regresia poskytuje transparentný ekonometrický základ, EBM testuje prínos nelineárneho a zároveň vysvetliteľného modelovania a BiLSTM overuje, či explicitné zachytenie časovej postupnosti finančných ukazovateľov zlepšuje identifikáciu rizikových podnikov.

3.4 Nevyváženosť tried a ich ošetrenie

Vzhľadom na mimoriadne nízku mieru zlyhania predstavuje použitý dataset extrémne nevyvážený klasifikačný problém. V pôvodnom datasete tvorili pozitívne pozorovania približne 0,2155 % všetkých firmo-rokov a po aplikácii filtrov zostala miera zlyhania na úrovni približne 0,184 % pri datasetoch pre logistickú regresiu a EBM a približne 0,176 % pri sekvenčnom datasete pre BiLSTM. Pri extrémne nevyvážených dátach môže optimalizácia štandardných *loss functions* viesť k modelom, ktoré dosahujú vysokú presnosť

najmä vďaka dominantnej majoritnej triede, avšak zároveň vykazujú nízku senzitivitu voči zriedkavej pozitívnej triede (He a Garcia, 2009). Nevyváženosť dát bola preto riešená modelovo špecificky, s ohľadom na charakter použitého modelu a jeho štatistické vlastnosti.

Pri logistickej regresii nebolo použité syntetické prevzorkovanie ani umelé vyvažovanie tried. Logistická regresia bola koncipovaná ako tradičný ekonometrický referenčný štandard, ktorého cieľom je poskytnúť transparentný a porovnateľný základ voči nelineárnym a sekvenčným modelom (Káčer a Alexy, 2025). Keďže hlavný význam logistickej regresie spočíva v interpretácii znamienok koeficientov a pomeru šancí, zásahy do pôvodnej distribúcie cieľovej premennej by mohli skomplikovať ekonometrickú interpretáciu odhadnutých parametrov. Model preto pracuje s pôvodnou štruktúrou tried, pričom dôraz je kladený na diskriminačné schopnosti a validáciu mimo tréningového obdobia. Pri EBM boli explicitne porovnané viaceré stratégie riešenia nevyváženosti. Prvou skupinou stratégií bol stratifikovaný *undersampling* majority triedy, pri ktorom sa ponechali všetky pozitívne pozorovania a z majoritnej triedy sa vyberala iba časť nezlyhaných pozorovaní. Tento výber bol stratifikovaný podľa odvetvia, aby sa pri redukcii majoritnej triedy zachovala približná odvetvová štruktúra tréningovej vzorky (Maturo et al., 2025). Testované boli pomery 1 : 1, 1 : 3 a 1 : 5 medzi pozitívnou a negatívnou triedou. Druhou stratégiou bol vážený model, ktorý ponechal celú tréningovú vzorku, ale pri odhade modelu použil váhy tried nepriamo úmerné ich početnosti v rámci tzv. *cost-sensitive learningu* (Elkan, 2001). Výber medzi týmito stratégiami bol realizovaný na validačnej vzorke podľa PR-AUC. Takýto postup umožnil empiricky porovnať, či je pre EBM výhodnejšie zmenšiť majoritnú triedu alebo zachovať celú dátovú informáciu a upraviť iba váhy pozorovaní.

Pri BiLSTM bola nevyváženosť riešená kombináciou *focal loss* funkcie a vyvážených *mini-batchov*. *Focal loss* znižuje váhu ľahko klasifikovateľných prípadov a zvyšuje dôraz na ťažko klasifikovateľné pozorovania, čo je pri extrémne zriedkavej pozitívnej triede vhodnejšie než štandardná binárna *cross-entropy* (Johnson a Khoshgoftaar, 2019). V analytickej pipeline boli parametre *focal loss*, konkrétne *gamma* a *alpha*, priamo zahrnuté do hyperparametrického ladenia. Zároveň boli použité vyvážené *mini-batche,* v ktorých bol podiel pozitívnych pozorovaní umelo zvýšený na 25 %. Tento postup bol aplikovaný iba v tréningovej fáze. Validačná a testovacia vzorka zostali v pôvodnej distribúcii, aby hodnotenie modelu odrážalo reálny výskyt zlyhaní (Fernández et al., 2018).

Použité riešenia nevyváženosti boli zvolené s ohľadom na metodickú povahu jednotlivých modelov. Logistická regresia zachováva pôvodnú distribúciu dát ako tradičný ekonometrický porovnávací štandard (Káčer a Alexy, 2025). EBM empiricky porovnáva

váženie tried a stratifikovaný *undersampling* (Maturo et al., 2025). BiLSTM využíva *focal loss* v kombinácii s vyváženými dávkami, čím sa zmierňuje vplyv extrémnej triednej nevyváženosti počas učenia modelu. Spoločným a kritickým princípom však zostáva, že nevyváženosť bola riešená výlučne v tréningovej fáze. Validačné a testovacie obdobie neboli umelo vyvažované, čím sa zachovala reálna miera zlyhania a zabezpečila sa realistická mimovzorková evaluácia modelov (Fernández et al., 2018).

3.5 Ladenie hyperparametrov a výber finálnych modelov

Ladenie hyperparametrov bolo realizované tak, aby sa minimalizovalo riziko prispôsobenia modelov testovaciemu obdobiu. Testovacia vzorka za roky 2018 až 2019 bola použitá výlučne na finálne *out-of-time* hodnotenie a nevstupovala do výberu premenných, hyperparametrov ani stratégie riešenia triednej nevyváženosti. Modelové rozhodnutia boli uskutočnené na základe tréningovej vzorky z rokov 2013 až 2016 a validačnej vzorky z roku 2017. Takýto postup zabezpečuje, že finálne výsledky majú *out-of-sample* charakter a nie sú výsledkom dodatočného prispôsobenia testovacím dátam (Káčer a Alexy, 2025).

Pri logistickej regresii neprebiehalo hyperparametrické ladenie v zmysle optimalizácie rozsiahleho priestoru parametrov, keďže model bol použitý ako ekonometrický referenčný model. Výber finálnej špecifikácie bol založený na ekonometrickej logike, kontrole multikolinearity, plnej hodnosti dizajnovej matice, štatistickej významnosti a očakávanom ekonomickom znamienku premenných. Najskôr bol zostavený širší *screeningový* model Logit 1, do ktorého vstupovali kandidátne premenné po kontrole chýbajúcich hodnôt, nulovej variability, VIF filtri a zabezpečenie identifikovateľnosti modelovej špecifikácie. Následne bola zostavená finálna špecifikácia Logit 2 (Káčer a Alexy, 2025). Z odvetvových premenných bola ako referenčná kategória vynechaná *industry_stavebnictvo*, referenčným rokom bol rok 2013 a z dôvodu presnej lineárnej závislosti bola odstránená premenná *small_company*. Finálny Logit 2 obsahoval 22 premenných vrátane ukazovateľov *eq_ta, bl_ta, roa1, ros, creditors_days, age_log*, vybraných odvetvových efektov a ročných *dummy* premenných. Testovacia vzorka rokov 2018 až 2019 nevstupovala do výberu špecifikácie a bola použitá až na finálne mimovzorkové hodnotenie.

Pri modeli EBM bolo ladenie realizované v dvoch nadväzujúcich krokoch. Najskôr boli na validačnej vzorke porovnané alternatívne stratégie riešenia triednej nevyváženosti.

Testované boli stratégie stratifikovaného *undersamplingu* majority triedy v pomeroch 1 : 1, 1 : 3 a 1 : 5 medzi pozitívnou a negatívnou triedou, ako aj weighted model ponechávajúci celú tréningovú vzorku (Maturo et al., 2025). Cieľom bolo empiricky overiť, či je pre EBM výhodnejšie redukovať počet nezlyhaných podnikov v tréningovej vzorke alebo zachovať celú dátovú informáciu a upraviť iba váhy tried. Výber stratégie bol uskutočnený podľa validačnej PR-AUC, keďže táto metrika lepšie reflektuje schopnosť modelu identifikovať zriedkavú pozitívnu triedu než celková klasifikačná presnosť (Araf et al., 2024). Po výbere stratégie nasledovalo samotné ladenie hyperparametrov pomocou optimalizačného rámca *Optuna* s využitím TPE algoritmu (Viď príloha). Cieľovou funkciou bola opäť validačná PR-AUC a do optimalizácie vstupovali najmä parametre určujúce flexibilitu a mieru regularizácie modelu, ako počet interakcií medzi premennými, *learning rate*, počet intervalov použitých na rozdelenie spojitých premenných a minimálny počet pozorovaní potrebný na vytvorenie samostatného segmentu modelu (Maturo et al., 2025). Finálna EBM špecifikácia bola následne natrénovaná podľa najlepšej validačnej konfigurácie a použitá na testovacie obdobie 2018 až 2019.

Pri BiLSTM bolo ladenie hyperparametrov potrebné vzhľadom na vyššiu flexibilitu neurónovej siete a väčší počet modelových rozhodnutí. Optimalizácia bola realizovaná pomocou *Optuna* s TPE algoritmom (Bergstra et al., 2011), pričom cieľovou funkciou bola validačná PR-AUC. Ladené boli najmä parametre architektúry a tréningového procesu, vrátane počtu LSTM jednotiek, veľkosti *dense* vrstvy, miery *dropout* regularizácie, *learning rate* a parametrov *focal loss* funkcie, konkrétne *alpha* a *gamma* (Lin et al., 2020). Keďže tréning sekvenčného modelu je výpočtovo náročný, optimalizácia bola realizovaná na tréningovej podvzorke určenej na ladenie hyperparametrov, zatiaľ čo validačná a testovacia vzorka zostali zachované v pôvodnej štruktúre. Finálny model bol následne natrénovaný na celej tréningovej vzorke s použitím vybranej konfigurácie. Súčasťou tréningu boli aj regularizačné a stabilizačné mechanizmy, konkrétne *dropout*, batch normalizácia, *Gaussian noise, early stopping* a znižovanie *learning rate* pri stagnácii validačnej metriky (Fasano et al., 2025). Nevyváženosť tried bola v tréningovej fáze riešená kombináciou *focal loss* a *vyváženýc dávok*, pričom podrobný opis tohto postupu je uvedený v samostatnej podkapitole venovanej nevyváženosti tried.

Výber finálnych modelov bol vo všetkých prípadoch založený na validačnom období, nie na testovacích výsledkoch. Pri logistickej regresii bola rozhodujúca ekonometrická interpretovateľnosť a stabilita špecifikácie, zatiaľ čo pri EBM a BiLSTM bola hlavným optimalizačným kritériom validačná PR-AUC doplnená o kontrolu stability a

schopnosti generalizácie. Testovacia vzorka bola použitá až po uzavretí modelových nastavení. Tento postup je dôležitý pre zachovanie objektívnosti porovnania modelov, keďže zabraňuje tomu, aby boli hyperparametre alebo modelové špecifikácie spätne prispôsobené výsledkom v testovacom období (Fernández et al., 2018).

3.6 Metódy hodnotenia modelov a interpretácie výsledkov

Hodnotenie modelov bolo realizované na samostatnej testovacej vzorke za roky 2018 až 2019, ktorá nevstupovala do odhadu parametrov, výberu premenných, ladenia hyperparametrov ani do výberu stratégií riešenia nevyváženosti tried. Finálne výsledky preto predstavujú mimovzorkové hodnotenie predikčnej schopnosti modelov (Káčer a Alexy, 2025).

Keďže predikcia zlyhania podnikov je v tejto práci formulovaná ako binárna klasifikačná úloha s extrémne nízkou mierou pozitívnej triedy, hodnotenie modelov nebolo založené na samotnej celkovej presnosti (*Accuracy*). Pri takto nevyvážených dátach môže byť klasická presnosť zavádzajúca, keďže model môže dosiahnuť vysokú hodnotu tejto metriky najmä masívnou správnou klasifikáciou majoritnej triedy, ale zároveň vykazovať nízku, či dokonca nulovú schopnosť identifikovať skutočne zlyhávajúce podniky. Z tohto dôvodu boli použité najmä metriky hodnotiace diskriminačnú schopnosť, schopnosť identifikovať pozitívnu triedu, kalibráciu pravdepodobností a praktickú využiteľnosť modelu pri prioritizácii najrizikovejších podnikov. Základnou metrikou diskriminačnej schopnosti bola ROC-AUC, ktorá vyjadruje schopnosť modelu zoradiť skutočne zlyhané podniky vyššie než nezlyhané podniky naprieč všetkými možnými rozhodovacími prahmi. Vyššia hodnota ROC-AUC znamená lepšiu schopnosť modelu rozlišovať medzi podnikmi, ktoré v nasledujúcom období zlyhajú, a podnikmi, ktoré nezlyhajú. Keďže však ROC-AUC môže pri extrémne nevyvážených dátach pôsobiť relatívne optimisticky, bola doplnená metrikou PR-AUC, ktorá vychádza z *precision-recall* krivky a je omnoho citlivejšia na schopnosť modelu identifikovať zriedkavú pozitívnu triedu (Araf et al., 2024). V kontexte tejto práce má PR-AUC osobitný význam, pretože zohľadňuje vzťah medzi podielom správne identifikovaných zlyhaní a podielom falošne pozitívnych označení medzi podnikmi klasifikovanými ako rizikové.

Na úrovni konkrétneho klasifikačného prahu boli sledované metriky presnosť, senzitivita a F1 skóre. Presnosť vyjadruje, aký podiel podnikov označených ako rizikové

skutočne zlyhali, zatiaľ čo senzitivita zachytáva, aký podiel zo všetkých skutočne zlyhaných podnikov model úspešne identifikoval. F1 skóre predstavuje harmonický priemer metrík presnosti a senzitivity a používa sa najmä v situáciách, keď je potrebné zohľadniť kompromis medzi falošne pozitívnymi a falošne negatívnymi prípadmi (Araf et al., 2024). Tieto metriky možno zapísať nasledovne:

$$Presnosť\ pozitívnej\ klasifikácie = \frac{True\ positive}{(True\ positive + False\ positive)}$$

$$Senzitivita = \frac{True\ positive}{(True\ positive + False\ negative)}$$

$$F1 = 2\ x\ \frac{Presnosť\ pozitívnej\ klasifikácie\ x\ Senzitivita}{(Presnosť\ pozitívnej\ klasifikácie + Senzitivita)}$$

kde *True positive* označuje správne identifikované zlyhané podniky, FP nezlyhané podniky nesprávne označené ako rizikové a FN zlyhané podniky, ktoré model neidentifikoval ako rizikové. Tieto metriky boli interpretované opatrne, keďže ich hodnota priamo závisí od zvoleného rozhodovacieho prahu.

Okrem ROC-AUC, PR-AUC a klasifikačných metrík bola použitá aj KS štatistika (Kolmogorov-Smirnov), ktorá meria maximálny rozdiel medzi distribučnou funkciou skóre zlyhaných a nezlyhaných podnikov. Vyššia hodnota KS štatistiky indikuje lepšie oddelenie rizikových a nerizikových pozorovaní v rámci predikčného skóre (Altman et al., 2010). Formálne možno KS štatistiku vyjadriť ako:

$$KS = max|F_1(s) - F_0(s)|$$

kde $F_1(s)$ označuje distribučnú funkciu skóre pre zlyhané podniky a $F_0(s)$ distribučnú funkciu skóre pre nezlyhané podniky. Táto metrika je v oblasti úverového a rizikového modelovania užitočná najmä preto, že poskytuje informáciu o separačnej schopnosti modelu naprieč celým rozdelením rizikového skóre.

Rozhodovacie prahy boli určované na validačnej vzorke, nie na testovacích dátach. V práci boli sledované najmä dva typy prahov. Prvým bol prah odvodený z Youdenovho indexu, ktorý maximalizuje rozdiel medzi mierou správne identifikovaných pozitívnych prípadov a mierou falošne pozitívnych prípadov (Youden, 1950; Káčer et al., 2019). Druhým bol prah maximalizujúci F1 skóre, teda kompromis medzi presnosťou pozitívnej predikcie a senzitivitou. Youdenov index možno zapísať ako:

$$J = Senzitiva + Špecificita - 1$$

kde senzitivita vyjadruje schopnosť modelu správne zachytiť skutočne zlyhané podniky, zatiaľ čo špecificita vyjadruje podiel skutočne nezlyhaných podnikov, ktoré model správne klasifikoval ako nerizikové. Tieto prahy slúžili predovšetkým na porovnanie klasifikačného správania modelov, nie ako univerzálne odporúčané rozhodovacie hranice pre praktické použitie. Pri extrémne zriedkavej udalosti, akou je podnikové zlyhanie, môže aj malá zmena prahu výrazne ovplyvniť počet falošne pozitívnych prípadov. Preto bola pri interpretácii výsledkov väčšia váha kladená na poradie rizikovosti, diskriminačné metriky a *top-k* analýzu než na jednu fixnú klasifikačnú hranicu. Dôležitou súčasťou hodnotenia bola top-k analýza, ktorá vyjadruje, aký podiel všetkých skutočných zlyhaní sa nachádza medzi najrizikovejšími podnikmi zoradenými podľa predikovanej pravdepodobnosti zlyhania. V práci boli sledované najmä hodnoty pre horných 1 %, 5 % a 10 % najrizikovejších pozorovaní. *Top-k capture* možno vyjadriť nasledovne:

$$Top - k\ Capture\ = \frac{\Sigma_i \in Top\ k\ y_i}{\Sigma_{i=1}^{N} y_i}$$

kde *Top k* označuje množinu podnikov s najvyššou predikovanou pravdepodobnosťou zlyhania v horných k percentách rizikového poradia a yi predstavuje skutočnú hodnotu cieľovej premennej. Táto metrika ukazuje, aký podiel všetkých budúcich zlyhaní by bolo možné zachytiť pri kontrole najrizikovejšej časti populácie podnikov. Tento spôsob hodnotenia je prakticky relevantný, pretože modely predikcie zlyhania sa v praxi často nepoužívajú na automatické binárne rozhodnutie o každom podniku, ale skôr ako systémy včasného varovania na prioritizáciu subjektov určených na ďalšiu analýzu, monitoring alebo dohľadovú kontrolu (Fasano et al., 2025).

Popri diskriminačnej schopnosti bola hodnotená aj kalibrácia pravdepodobnostných výstupov. Kalibrácia vyjadruje, do akej miery predikované pravdepodobnosti zodpovedajú empirickej frekvencii zlyhaní. Na tento účel boli použité najmä Brierovo skóre a *log-loss*. Brierovo skóre meria priemernú kvadratickú odchýlku medzi predikovanou pravdepodobnosťou a skutočnou hodnotou cieľovej premennej:

$$Brier\ = \frac{1}{N}\sum_{i=1}^{N} \quad (p_i\ - y_i)^2$$

kde *pi* označuje predikovanú pravdepodobnosť zlyhania a *yi* skutočnú hodnotu cieľovej premennej. *Log-loss* silnejšie penalizuje veľmi sebavedomé nesprávne predikcie a možno ho zapísať ako:

$$LogLoss = -\frac{1}{N}\sum_{i=1}^{N} [y_i log(p_i) + (1 - y_i) log(1 - p_i)]$$

Kalibračné ukazovatele boli interpretované oddelene od diskriminačných metrík, pretože model môže dobre zoraďovať podniky podľa rizika, ale zároveň produkovať pravdepodobnosti, ktoré nie sú dokonale kalibrované. Pri EBM boli hodnotené pravdepodobnosti po Plattovej kalibrácii a pri BiLSTM po izotonickej kalibrácii, pričom kalibračné modely boli odhadnuté na validačnej vzorke a následne aplikované na testovacie obdobie. Pri logistickej regresii bola pravdepodobnostná interpretácia posudzovaná v kontexte jej ekonometrickej štruktúry a odhadu pomocou maximálnej vierohodnosti.

Interpretácia výsledkov bola prispôsobená charakteru jednotlivých modelov. Pri logistickej regresii boli interpretované znamienka koeficientov, ich štatistická významnosť a *odds ratio,* čo umožňuje určiť, či rast danej finančnej premennej zvyšuje alebo znižuje odhadovaný pomer šancí zlyhania. Logistická regresia preto poskytuje najpriamejšiu ekonometrickú interpretáciu, avšak za cenu lineárneho funkčného tvaru (Káčer a Alexy, 2025). Pri EBM bola interpretácia založená na globálnej dôležitosti premenných, tvarové funkcie hlavných efektov a vybraných interakciách. Tvarové funkcie umožňujú analyzovať, ako sa mení príspevok konkrétnej premennej k riziku zlyhania pri rôznych hodnotách finančného ukazovateľa, vďaka čomu EBM umožňuje identifikovať nelineárne a prahové vzťahy, ktoré by logistická regresia nemusela zachytiť (Maturo et al., 2025). Pri BiLSTM bola interpretácia založená na *post-hoc* vysvetlení pomocou SHAP hodnôt (Lundberg & Lee, 2017). Keďže neurónová sieť neposkytuje priamu interpretáciu koeficientov ani tvarové funkcie, SHAP hodnoty boli použité na identifikáciu premenných a časových krokov, ktoré najviac prispievali k predikovanej pravdepodobnosti zlyhania. Tento prístup umožňuje posúdiť, či sekvenčný model využíva najmä aktuálne hodnoty finančných ukazovateľov alebo či významnú úlohu zohrávajú aj historické hodnoty a ich zmeny v čase (Fasano et al., 2025).

Finálne porovnanie modelov bolo založené na kombinácii predikčnej výkonnosti, kalibrácie a interpretovateľnosti. Za výkonnejší model nebol považovaný iba model s najvyššou hodnotou jednej metriky, ale model, ktorý poskytoval najlepší kompromis medzi diskriminačnou schopnosťou, schopnosťou identifikovať zriedkavú pozitívnu triedu, stabilitou výsledkov, kvalitou pravdepodobnostných výstupov a ekonomickou interpretovateľnosťou. Tento prístup je v kontexte predikcie podnikového zlyhania dôležitý, pretože prakticky použiteľný model by mal nielen dosahovať dobré hodnoty štatistických

metrík, ale zároveň umožniť pochopiť, ktoré faktory stoja za zvýšeným rizikom zlyhania (Weber et al., 2024).

3.7 Softvérové prostredie a reprodukovateľnosť

Výpočty modelov boli realizované v programovacom jazyku Python v prostredí Google Colab. Výpočtový postup bol rozdelený do samostatných notebookov podľa jednotlivých fáz analýzy. Prvý notebook slúžil na načítanie surových účtovných údajov, ich predspracovanie, tvorbu odvodených premenných a export modelovo špecifických datasetov. Následne boli použité samostatné notebooky pre logistickú regresiu, EBM a BiLSTM. Finálne porovnanie modelov bolo realizované v osobitnom porovnávacom notebooku. Takéto členenie umožnilo oddeliť dátovú prípravu, odhad jednotlivých modelov a porovnanie výsledkov, čím sa zvýšila transparentnosť a reprodukovateľnosť empirickej časti práce.

Na manipuláciu s dátami a numerické výpočty boli použité najmä knižnice pandas a numpy. Knižnica pandas slúžila na načítanie dát, transformáciu premenných, tvorbu panelovej štruktúry, filtrovanie vzorky, výpočet finančných ukazovateľov a export modelových datasetov. Knižnica *numpy* bola využitá pri numerických operáciách, práci s chýbajúcimi hodnotami a príprave vstupov pre modely. Na ekonometrický odhad logistickej regresie bola použitá knižnica *statsmodels*, ktorá umožňuje odhad modelu MLE a poskytuje výstupy potrebné na interpretáciu koeficientov, štatistickej významnosti a pomeru šancí. Na predspracovanie vstupov, výpočet metrík, škálovanie, kalibráciu pravdepodobností a pomocné modelové postupy bola použitá knižnica scikit-learn. Model EBM bol implementovaný pomocou knižnice *interpret*, konkrétne triedy *ExplainableBoostingClassifier*, zatiaľ čo hyperparametrické ladenie bolo realizované pomocou knižnice *Optuna* s využitím TPE optimalizácie. Sekvenčný model BiLSTM bol vytvorený v knižniciach *TensorFlow* a *Keras*, ktoré slúžili na definovanie architektúry neurónovej siete, tréning modelu, aplikáciu regularizačných prvkov a uloženie výsledného modelu (Nori et al., 2019). Na *post-hoc* interpretáciu BiLSTM boli použité SHAP hodnoty prostredníctvom knižnice *shap* (Lundberg & Lee, 2017). Vizualizácie, kontrolné grafy a výsledkové tabuľky boli vytvárané pomocou štandardných analytických a exportných nástrojov jazyka Python, najmä *matplotlib*, *pickle*, *os* a *json*.

Reprodukovateľnosť výpočtov bola podporená fixovaním na hodnotu RANDOM

SEED = 42 a použitím jednotného časového členenia vzorky vo všetkých modelových pipeline-och. Tréningové obdobie tvorili roky 2013 až 2016, validačné obdobie rok 2017 a testovacie obdobie roky 2018 až 2019. Všetky transformačné pravidlá, vrátane winsorizačných hraníc, mediánov použitých pri imputácii a škálovacích parametrov, boli odvodené výlučne z tréningovej vzorky a následne aplikované na validačné a testovacie obdobie. Tento postup minimalizoval riziko *data leakage* z budúcich období a zabezpečil, že finálne hodnotenie modelov malo *out-of-sample* charakter. Každý model tak pracoval s vopred definovaným vstupným datasetom, ktorého štruktúra bola opísaná v časti venovanej príprave dát.

Výsledky jednotlivých modelov boli ukladané do samostatných výstupných súborov vo formáte *pkl*, konkrétne logit2_results.pkl, ebm_results.pkl a bilstm_results.pkl. Tieto súbory následne vstupovali do porovnávacieho notebooku, v ktorom boli vypočítané spoločné výsledkové tabuľky a porovnávacie metriky modelov. Analýza bola zostavená tak, aby bolo možné pri dostupnosti pôvodného datasetu a priložených notebookov zreplikovať celý postup od surových účtovných údajov až po finálne porovnanie modelov (Viď. príloha). Základné vstupné premenné, výpočty finančných ukazovateľov, filtre vzorky, makroekonomické premenné, dynamické transformácie a charakteristika exportovaných datasetov sú uvedené v prílohách práce. Tieto prílohy slúžia ako reprodukčný protokol, ktorý zabezpečuje maximálnu transparentnosť, spoľahlivosť a rigoróznosť výskumu tým, že umožňuje čitateľovi spätne identifikovať a overiť všetky kľúčové kroky empirickej analýzy (Weber et al., 2024).

4 Výsledky práce

Táto kapitola prezentuje výsledky troch modelových prístupov použitých pri predikcii zlyhania slovenských podnikov. Najskôr sú samostatne vyhodnotené výsledky logistickej regresie, modelu EBM a sekvenčného modelu BiLSTM. Pri každom modeli sú hodnotené jeho diskriminačné schopnosti, správanie pri validačne určených klasifikačných prahoch, *top-k* výsledky a interpretačné výstupy. V závere kapitoly sú modely vzájomne porovnané a výsledky sú použité na zodpovedanie výskumnej otázky práce.

4.1 Výsledky logistickej regresie

Logistická regresia bola v práci použitá ako tradičný ekonometrický porovnávací štandard, voči ktorému sa hodnotil dodatočný prínos nelineárneho modelu EBM a sekvenčného modelu BiLSTM. Finálny model bol odhadnutý ako porovnávací model logistickej regresie s kontrolou multikolinearity, úpravou dizajnovej matice z dôvodu presnej lineárnej závislosti, odvetvovými fixnými efektmi a ročnými *dummy* premennými. Z odvetvových premenných bola ako referenčná kategória vynechaná premenná *industry_stavebnictvo*, aby sa predišlo problému úplnej kolinearity pri zahrnutí konštanty. Z rovnakého dôvodu bola z finálnej matice odstránená aj premenná *small_company*, ktorá bola identifikovaná ako presná lineárna kombinácia konštanty alebo predchádzajúcich premenných. Ako upozorňujú Káčer a Alexy (2025), takýto postup zabezpečuje odstránenie multikolinearity, obmedzuje riziko preučenia (*overfittingu*) a vytvára model vhodný na spoľahlivú ekonometrickú interpretáciu (Káčer a Alexy, 2025).

Finálna špecifikácia *Logit 2* obsahovala 22 premenných. Okrem finančných ukazovateľov *eq_ta, bl_ta, roa1, ros, creditors_days* a *age_log* boli v modeli ponechané aj vybrané odvetvové *dummy* premenné a ročné efekty. Finančné premenné zachytávajú kapitálovú štruktúru, financovanie úvermi, rentabilitu, ziskovú maržu, dobu splatnosti záväzkov a vek podniku. Odvetvové premenné umožňujú kontrolovať rozdiely v riziku zlyhania medzi jednotlivými sektormi a ročné *dummy* premenné zachytávajú rozdiely medzi rokmi tréningového obdobia. Zaradenie odvetvových a ročných *dummy* premenných umožňuje modelu zohľadniť štrukturálnu heterogenitu podnikov podľa sektora a času, pričom logistická regresia si zároveň zachováva úlohu transparentného ekonometrického referenčného modelu (Wilson et al., 2014; Baumöhl et al., 2020).

Na testovacej vzorke za roky 2018 až 2019 dosiahla logistická regresia hodnotu ROC-AUC 0,797 a PR-AUC 0,010 (Obrázok č.2). Hodnota ROC-AUC ukazuje, že model dokáže rozlišovať medzi zlyhávajúcimi a nezlyhávajúcimi podnikmi výrazne lepšie než náhodné zoradenie. Hodnota PR-AUC je vzhľadom na extrémne nízku mieru zlyhania prirodzene nižšia, no potvrdzuje, že identifikácia menšinovej pozitívnej triedy je pri takejto zriedkavej udalosti výrazne náročnejšia. KS štatistika dosiahla na testovacej vzorke hodnotu 0,462, čo poukazuje na stredne silnú separáciu rizikového skóre medzi zlyhanými a nezlyhanými podnikmi. Pre úplnosť je v tabuľke č.7 uvedená aj vyvážená klasifikačná správnosť (*Balanced Accuracy*), definovaná ako priemer senzitivity a špecificity.

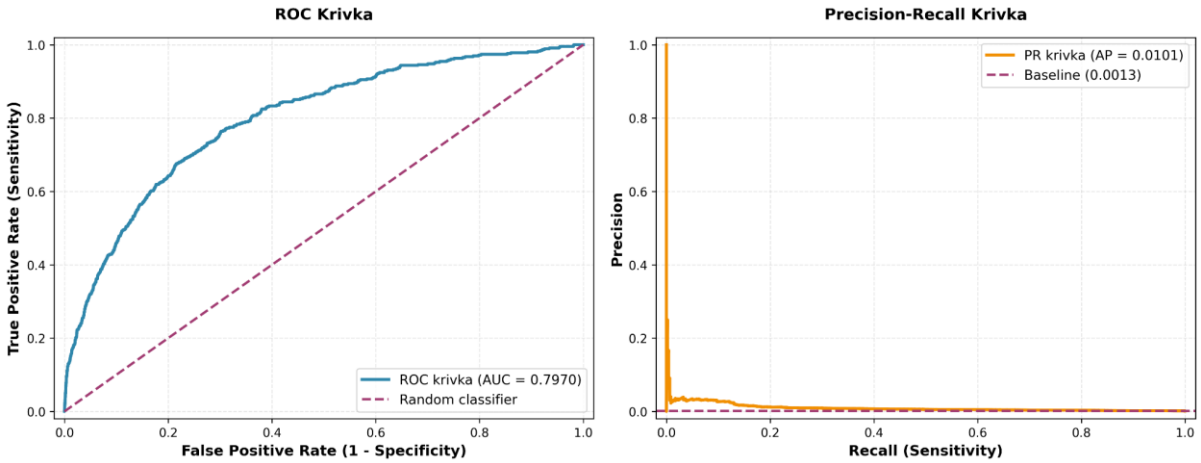
Tabuľka č.7: Súhrn výkonnosti logistickej regresie

Metrika	Validácia 2017	Test 2018 – 2019
Počet pozorovaní	159 248	348 891
Počet zlyhaní	252	462
Miera zlyhaní	0,158 %	0,132 %
ROC-AUC [95 % IS]	0,807	0,797 [0,777; 0,816]
PR-AUC [95 % IS]	0,017	0,010 [0,007; 0,017]
KS štatistika [95 % IS]	0,482	0,462 [0,429; 0,512]
Brierovo skóre	0,001571	0,001323
Vyvážená klasifikačná správnosť (*Balanced Accuracy*)	0,741	0,727

Výsledky z tabuľky č.7 ukazujú, že model si medzi validačným a testovacím obdobím zachoval pomerne stabilnú diskriminačnú schopnosť. ROC-AUC klesla z 0,807 na 0,797, čo predstavuje iba mierne oslabenie výkonnosti mimo validačného roku. PR-AUC klesla z 0,017 na 0,010, čo je pri veľmi nízkej miere pozitívnej triedy očakávaný jav, keďže v testovacom období bola miera zlyhania ešte nižšia než vo validačnom roku. Brierovo skóre zostalo na veľmi nízkej úrovni, čo priamo súvisí s nízkou základnou mierou zlyhania v populácii. V medziročnom porovnaní dosiahol model v roku 2018 ROC-AUC 0,798, zatiaľ čo v roku 2019 dosiahol ROC-AUC 0,795. Celková diskriminačná schopnosť preto zostala medzi oboma testovacími rokmi relatívne stabilná.

Pri validačne určenom prahu podľa Youdenovho indexu, ktorý dosiahol hodnotu 0,0025, model na testovacej vzorke identifikoval 322 zo 462 skutočne zlyhaných pozorovaní. Senzitivita tak dosiahla 69,7 %, čo znamená, že model úspešne zachytil približne sedem z desiatich zlyhaní. Tento výsledok je však dosiahnutý za cenu vysokého počtu falošne pozitívnych prípadov. Model pri tomto prahu označil ako rizikových 84 717

pozorovaní, z ktorých skutočne zlyhalo iba 322. Presnosť pozitívnej predikcie preto dosiahla iba 0,38 %. Tento výsledok plne odzrkadľuje tzv. dilemu presnosti pri extrémne nevyvážených dátach, kde nízky klasifikačný prah síce chráni citlivosť modelu, ale nevyhnutne vedie k masívnemu nárastu falošne pozitívnych označení (Araf et al., 2024). Z tohto dôvodu je v praxi vhodnejšie interpretovať výstupy nielen cez jeden klasifikačný prah, ale primárne ako kontinuálne rizikové skóre umožňujúce zoradiť podniky podľa pravdepodobnosti zlyhania.



Obrázok č.2: ROC krivka a *precision-recall* krivka logistickej regresie na testovacej vzorke.

Tabuľka č.8: Výkonnosť modelu pri Youdenovom prahu a v *top-k* rizikových skupinách

Metrika	Youdenov prah	Top 1 %	Top 5 %	Top 10 %
Prah / skupina	0,0025	-	-	-
Zachytené zlyhania	322	63	148	212
Počet označených pozorovaní	84 717	3 489	17 445	34 890
Presnosť poz. predikcie	0,38 %	1,81 %	0,85 %	0,61 %
Miera záchytu (senzitivita)	69,7 %	13,6 %	32,0 %	45,9 %

**(Poznámka: Pre Youdenov prah stĺpec Počet označených pozorovaní predstavuje TP + FP = 84 717, pre top-k skupiny ide o celkový počet pozorovaní v danom percentile, nie o počet falošne pozitívnych)*

Top-k analýza poskytuje praktickejší pohľad na využiteľnosť logistickej regresie ako nástroja včasného varovania. V hornom 1 % najrizikovejších pozorovaní model zachytil 13,6 % všetkých zlyhaní. V horných 5 % najrizikovejších pozorovaní zachytil 32,0 % zlyhaní a v horných 10 % zachytil 45,9 % zlyhaní (Tabuľka č.8). To znamená, že aj tradičný ekonometrický referenčný prístup dokáže koncentrovať významnú časť budúcich zlyhaní do relatívne malej rizikovej skupiny podnikov. Prakticky to znamená, že ak by sa analytická

pozornosť sústredila výlučne na 5 % najrizikovejších subjektov, bolo by možné zachytiť približne tretinu všetkých budúcich zlyhaní. V odbornej literatúre je práve takýto prístup zoraďovania a prioritizácie firiem odporúčaný ako riešenie tzv. dilemy presnosti pri extrémne nevyvážených dátach, kde klasické binárne rozhodovanie naráža na svoje limity (Fasano et al., 2025). Ekonomická interpretácia logistickej regresie je založená na znamienkach koeficientov a pomere šancí. Pri spojitých premenných *odds ratio* vyjadruje zmenu pomeru šancí zlyhania pri jednotkovej zmene danej premennej, pri zachovaní *ceteris paribus* ostatných premenných. Pri odvetvových *dummy* premenných vyjadruje rozdiel voči referenčnej kategórii (stavebníctvo). Pri ročných *dummy* premenných je referenčným obdobím rok 2013.

Tabuľka č.9: Koeficienty a odds ratio finálneho modelu

Premenná	Koeficient	Odds ratio	95 % IS odds ratio	p-hodnota
eq_ta	-1,010	0,364	0,328 - 0,405	<0,001
bl_ta	2,424	11,290	5,541 - 23,007	<0,001
roa1	-1,535	0,216	0,154 - 0,301	<0,001
ros	-0,216	0,806	0,695 - 0,934	0,004
creditors_days	0,0005	1,0005	1,0005 - 1,0006	<0,001
age_log	0,475	1,608	1,479 - 1,749	<0,001
industry_cestovny_ruch_a_gastro	-0,772	0,462	0,356 - 0,600	<0,001
industry_informacne_technologie	-0,997	0,369	0,231 - 0,590	<0,001
industry_maloobchod	-0,572	0,564	0,453 - 0,702	<0,001
industry_media_vydavatelstva_a_kultura	-0,824	0,439	0,247 - 0,779	0,005
industry_nehnutelnosti	-0,528	0,590	0,464 - 0,750	<0,001
industry_pravo_poradenstvo_a_uctovnictvo	-0,744	0,475	0,356 - 0,634	<0,001
industry_predaj_a_udrzba_vozidiel	-0,402	0,669	0,457 - 0,979	0,039
industry_projektovanie_a_inziniering	-0,868	0,420	0,266 - 0,664	<0,001
industry_reklama	-1,203	0,300	0,161 - 0,561	<0,001
industry_sluzby	-0,812	0,444	0,317 - 0,622	<0,001
industry_sprostredkovanie	-0,432	0,649	0,473 - 0,892	0,008
industry_vyvoj_a_testovanie	-1,183	0,306	0,127 - 0,740	0,009
industry_zdravotnictvo	-1,250	0,286	0,174 - 0,471	<0,001
year_2014	-0,198	0,820	0,701 - 0,960	0,014
year_2015	-0,363	0,696	0,591 - 0,819	<0,001
year_2016	-0,416	0,660	0,560 - 0,778	<0,001

Z finančných premenných má najsilnejší ochranný efekt premenná *eq_ta,* ktorej *odds ratio* dosahuje hodnotu 0,364 (Tabuľka č.9). Vyšší podiel vlastného imania na celkových aktívach výrazne znižuje pomer šancí zlyhania, čo je v súlade s očakávaním, že kapitálovo silnejšie podniky sú odolnejšie voči finančným šokom (Fasano et al., 2025). Podobne premenná *roa1* dosahuje *odds ratio* 0,216, čo potvrdzuje význam rentability aktív ako jedného zo základných indikátorov finančného zdravia. Vyššia rentabilita znižuje pravdepodobnosť zlyhania, keďže ziskovejšie podniky majú väčšiu schopnosť financovať prevádzku a obsluhovať záväzky (Káčer a Alexy, 2025). Premenná *ros* má *odds ratio* 0,806, čo potvrdzuje, že aj vyššia zisková marža je spojená s nižším rizikom.

Naopak, premenná *bl_ta* vykazuje vysoko kladný koeficient a *odds ratio* 11,290. Táto hodnota odráža efekt pri zmene pomeru bankových záväzkov k celkovým aktívam z 0 na 1, t. j. pri hypotetickej situácii, keď sú celkové aktíva financované výlučne bankovým dlhom. Pre interpretáciu prakticky relevantnej veľkosti efektu je informatívnejšia čiastočná zmena v interpretácii. Nárast bl_ta o 0,10 jednotky zodpovedá *odds ratio* približne 1,27, čo naznačuje, že vyššia závislosť od bankového financovania je spojená s výrazne vyššou finančnou zraniteľnosťou podniku, čo je konzistentné s teóriou finančnej tiesne (Lau, 1987; Whitaker, 1999). Premenná *creditors_days* má *odds ratio* 1,0005. Efekt na úrovni jednej jednotky (jeden deň) je prirodzene malý, keďže premenná je meraná v dňoch. Kumulatívne je však ekonomicky relevantný. Predĺženie doby splatnosti záväzkov o 30 dní zodpovedá *pomeru šancí* 1,015. Predlžovanie doby splatnosti záväzkov vo vzťahu k tržbám je teda spojené s rastom rizika zlyhania a kumulatívne signalizuje zhoršenú platobnú disciplínu alebo napätie v prevádzkovom financovaní.

Premenná *age_log* s *odds ratio* 1,608 naznačuje pozitívny vzťah medzi vekom podniku a šancou zlyhania. Tento výsledok si vyžaduje opatrnú interpretáciu, nakoľko môže zachytávať štrukturálne špecifiká prežívajúcich, ale postupne finančne oslabených podnikov (Wilson et al., 2014). Shumway dokumentuje, že vek firmy nevykazuje monotónne klesajúci vzťah s rizikom zlyhania, naopak staršie firmy sa síce vyznačujú dlhšou prevádzkovou históriou, avšak v populácii pretrváva selektívny efekt, pri ktorom finančne oslabené, ale dlhodobejšie existujúce subjekty môžu mať vyššiu kumulovanú expozíciu voči zlyhaniu než mladé podniky s čistou bilanciou (Shumway, 2001).

Odvetvové premenné majú prevažne záporné koeficienty a *odds ratio* nižšie než 1. To znamená, že pri zachovaní *ceteris paribus* majú viaceré odvetvia nižšie šance zlyhania v porovnaní so stavebníctvom (referenčná trieda). Najnižšie *odds ratio* dosiahlo zdravotníctvo (0,286), reklama (0,300) či informačné technológie (0,369). Tento výsledok indikuje, že

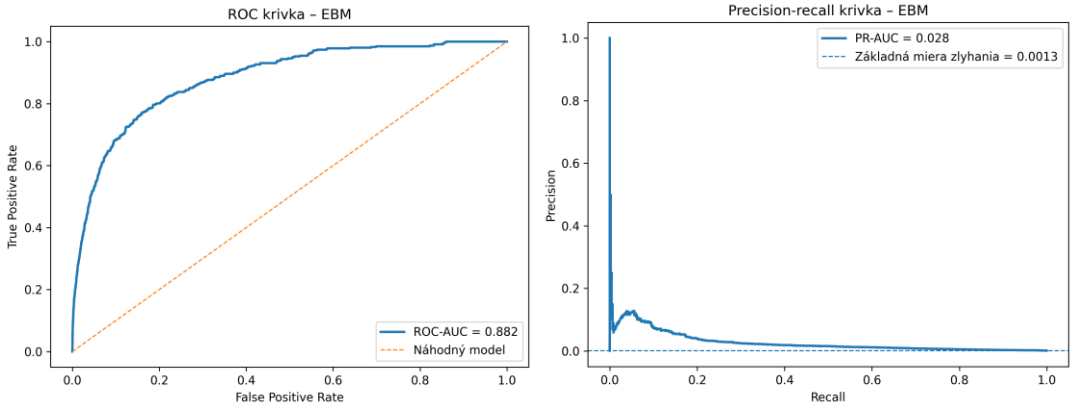
stavebníctvo predstavuje v analyzovanom období relatívne rizikovejší sektor, čo potvrdzujú aj zistenia Baumöhla et al. (2020) o vysokej cyklicite a zraniteľnosti tohto odvetvia (Baumöhl et al., 2020). Výnimkou je odvetvie predaj a údržba vozidiel (OR = 0,669, p = 0,039), ktoré sa od referenčnej kategórie líši štatisticky signifikantne iba na 5 % hladine, pričom interval spoľahlivosti (0,457 - 0,979) je relatívne široký, čo naznačuje väčšiu neistotu odhadu. Rovnako ročné *dummy* premenné ukázali, že šance zlyhania po roku 2013 systematicky klesali (napríklad v roku 2016 klesol pomer šancí na 0,660), čo reflektuje zlepšujúce sa makroekonomické a podnikateľské prostredie v doznievajúcej pokrízovej obnove.

Celkovo výsledky logistickej regresie potvrdzujú význam kapitálovej štruktúry, rentability, financovania úvermi, ziskovej marže, prevádzkového financovania a odvetvovej príslušnosti pri vysvetľovaní rizika zlyhania. Model úspešne a transparentne zachytáva očakávané ekonomické vzťahy. Logistická regresia preto poskytuje metodicky vysoko vhodný a priamočiary *referenčný štandard.* Jej hlavnou vedeckou aj praktickou výhodou je vysoká transparentnosť a stabilná ekonometrická interpretácia obhájiteľná aj v regulovanom bankovom prostredí (Káčer a Alexy, 2025).

4.2 Výsledky modelu Explainable Boosting Machine

Model EBM bol použitý ako natívne interpretovateľná nelineárna špecifikácia, ktorá umožňuje transparentne modelovať nelineárne vzťahy a párové interakcie medzi premennými (Nori et al., 2019). Finálna špecifikácia bola odhadnutá na vyrovnanej trénovacej vzorke so stratégiou *undersample* 1:1, v ktorej každej zlyhanej firme zodpovedalo jedno náhodne vybrané negatívne pozorovanie. Táto stratégia, v literatúre označovaná ako *rare event* vzorkovanie (King & Zeng, 2003), zvyšuje citlivosť modelu na minoritnú triedu tým, že odhadovací algoritmus pracuje s vyváženejším informačným signálom. Súčasne však narúša kalibráciu pravdepodobnostnej škály, čo si vyžaduje následnú pravdepodobnostnú rekalibráciu. Do modelu vstupovalo 152 premenných zahŕňajúcich absolútne finančné hodnoty, pomerové ukazovatele, dynamické premenné prvých a druhých diferencií, trendové lagy, odvetvové binárne premenné a makroekonomické ukazovatele. Súčasťou finálnej špecifikácie bolo 8 automaticky detegovaných párových interakcií, odhadnutých FAST algoritmom, ktoré zachytávajú simultánne pôsobenie dvojíc premenných na riziko zlyhania (Lou et al., 2013).

Na testovacej vzorke rokov 2018 - 2019 zahŕňajúcej 348 891 pozorovaní a 462 skutočných zlyhaní dosiahol model EBM hodnotu ROC-AUC 0,882, PR-AUC 0,028 a KS štatistiku 0,611. Tieto výsledky dokumentujú silnú diskriminačnú schopnosť modelu pri extrémne nevyváženej pozitívnej triede. Miera zlyhaní 0,13 % v testovacej vzorke prirodzene tlačí PR-AUC k nízkym absolútnym hodnotám bez ohľadu na kvalitu modelu (Araf et al., 2024). Z pohľadu mimovzorkového hodnotenia stability je kľúčovým indikátorom zanedbateľný pokles ROC-AUC z validačnej hodnoty 0,887 na testovú 0,882 - stabilita naprieč obdobiami naznačuje, že model nezachytil iba idiosynkratické vzory trénovacej vzorky, ale odhadol ekonomicky stabilné vzťahy (Káčer a Alexy, 2025).



Obrázok č. 3: ROC krivka a *precision-recall* krivka modelu EBM na testovacej vzorke

Tabuľka č.10: Diskriminačná výkonnosť modelu EBM na validačnej a testovacej vzorke

Vzorka / Obdobie	**ROC-AUC**	**PR-AUC**	**KS štatistika**	**Brierovo skóre**
Validácia 2017	0,887	0,071	0,618	-
Test 2018 – 2019	0,882	0,028	0,611	0,001310
Test 2018	0,884	0,034	0,599	0,001485
Test 2019	0,879	0,026	0,632	0,001145
95 % CI (test)	0,867 - 0,897	0,021 - 0,041	0,580 - 0,652	-

**Poznámka: Bootstrapové CI sú odhadnuté z 1 000 bootstrapových vzoriek testovej sady. PR-AUC je citlivejšou mierou výkonnosti pri zriedkavej pozitívnej triede (Araf et al., 2024). Brierovo skóre je reportované po Plattovej kalibrácii.*

Medziročné výsledky potvrdzujú stabilitu diskriminačnej schopnosti modelu naprieč obdobiami. V roku 2018 dosiahol model ROC-AUC 0,884 a PR-AUC 0,034, v roku 2019 ROC-AUC 0,879 a PR-AUC 0,026 (Tabuľka č.10). Vyššia hodnota PR-AUC v roku 2018 súvisí s vyšším absolútnym počtom zlyhaní (255 oproti 207 v roku 2019), čo zvyšuje citlivosť tejto metriky na absolútnu koncentráciu pozitívnych prípadov v danom období. KS štatistika bola naopak vyššia v roku 2019 (0,632 oproti 0,599), čo naznačuje lepšie oddelenie

distribúcii rizikového skóre v druhom testovacom roku. Konzistentnosť výsledkov v oboch rokoch potvrdzuje, že model si zachováva stabilnú výkonnosť naprieč časom, čo je kľúčové kritérium pri jeho nasadení v reálnych podmienkach (Fasano et al., 2025).

Voľba klasifikačného prahu predstavuje rozhodovací problém, pri ktorom majú falošne pozitívne a falošne negatívne klasifikácie rozdielne dôsledky. Pri prahu maximalizujúcom Youdenov index (0,0016) model identifikoval 369 z 462 skutočných zlyhaní, dosiahol senzitivitu 79,9 % pri špecificite 80,6 % (Tabuľka č.11). Súčasne model označil 67 432 zdravých firiem ako rizikových, čo je pri miere zlyhaní 0,13 % nevyhnutným dôsledkom snahy o vysokú citlivosť. Nízka presnosť pozitívnej predikcie (0,54 %) je v tomto kontexte štrukturálnym obmedzením základnej miery a nie indikátorom slabej diskriminačnej schopnosti. Z pohľadu finančného dohľadu, kde je prehliadnutie skutočne zlyhávajúceho podniku závažnejšie než falošné označenie podniku ako rizikového, je metodologicky vhodnejší Youdenov prah. F1-optimálny prah naopak maximalizuje kompromis medzi senzitivitou a precíznosťou, pričom v tomto prípade dosahuje senzitivitu 9,5 % a presnosť pozitívnej predikcie 8,3 %. Tento prístup je vhodnejší v situáciách, kde sú náklady manuálneho preverovania vysoké.

Tabuľka č.11: Klasifikačné metriky modelu EBM v závislosti od rozhodovacieho prahu

Prah	**TP**	**FP**	**FN**	**TN**	**Senzitivita**	**Precision**	**F1**	**Špecificita**
Youden	369	67 432	93	280 997	0,799	0,005	0,011	0,806
F1-optimal	44	485	418	347 944	0,095	0,083	0,089	0,999

**Poznámka: Threshold Youden = 0,0016 odhadnutý na validačnej vzorke 2017. Celkový počet zlyhaní v testovacej vzorke: 462.*

Doplnkovú informáciu o ekonomickej hodnote modelu poskytuje *top-k* analýza. EBM dosiahol v tejto dimenzii mimoriadne výsledky, v hornom 1 % najrizikovejších pozorovaní model zachytil 24,2 % všetkých budúcich zlyhaní s liftom 24,2 (Tabuľka č.12). Kontrola desatiny najrizikovejšej populácie by identifikovala 68,2 % všetkých zlyhaní. Lift 35,1 v hornom 0,5 % dokumentuje, že model sústredí riziko do extrémne kompaktnej skupiny podnikov s mimoriadne vysokou predikčnou hodnotou. Tieto výsledky sú konzistentné s výsledkami Fasano et al. (2025) a naznačujú praktickú využiteľnosť modelu ako nástroja včasného varovania v regulačnom kontexte (Fasano et al., 2025).

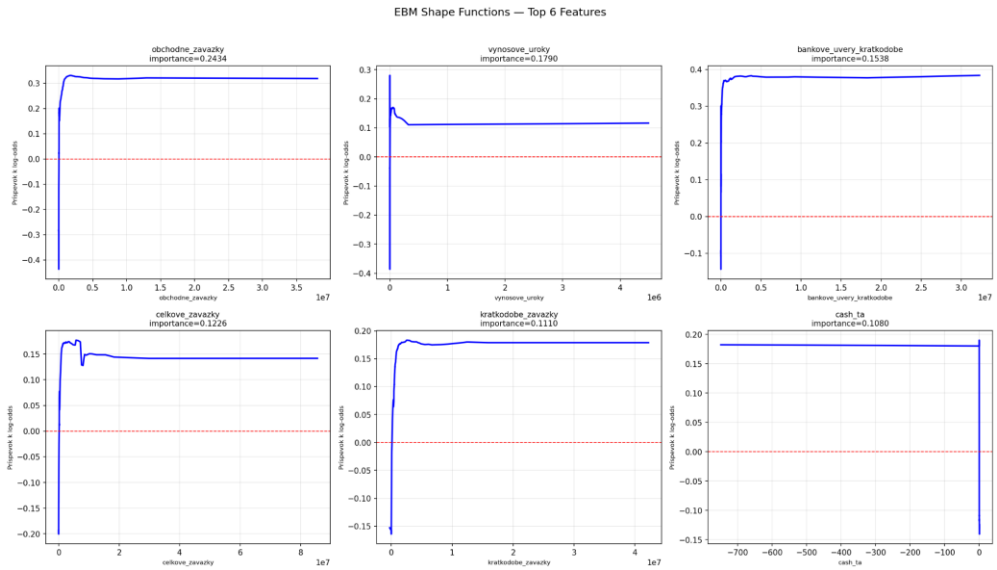
Tabuľka č.12: Top-k analýza modelu EBM na testovacej vzorke (2018 - 2019)

Riziková skupina	Počet pozorovaní	Zachytené zlyhania	Miera zachytenia	Precision	Lift
Top 0,5 %	1 745	81 z 462	17,5 %	4,64 %	35,1
Top 1 %	3 489	112 z 462	24,2 %	3,21 %	24,2
Top 2 %	6 978	157 z 462	34,0 %	2,25 %	17,0
Top 5 %	17 445	243 z 462	52,6 %	1,39 %	10,5
Top 10 %	34 890	315 z 462	68,2 %	0,90 %	6,8

**Poznámka: Lift = miera zachytenia / podiel skupiny v celkovej populácii. Referenčný počet zlyhaní: 462. Precision v skupine = podiel zlyhaných podnikov medzi najrizikovejšími pozorovaniami v danej top-k skupine.*

Kvalita pravdepodobnostných prognóz je kvantifikovaná Brierovým kvadratickým skóre (Brier, 1950). Surový testový výstup dosahuje Brierovo skóre 0,1116, čo odráža systematickú chybu v pravdepodobnostnej škále spôsobenú undersamplingom. Po Plattovej kalibrácii klesá Brierovo skóre na 0,001310, čo je hodnota blízka teoretickému minimu pri miere zlyhaní 0,13 %. Diagnostický sklon 1,014 potvrdzuje, že kalibrované výstupy sú interpretovateľné ako podmienené pravdepodobnosti zlyhania konzistentné s empirickými mierami v kalibračnej vzorke.

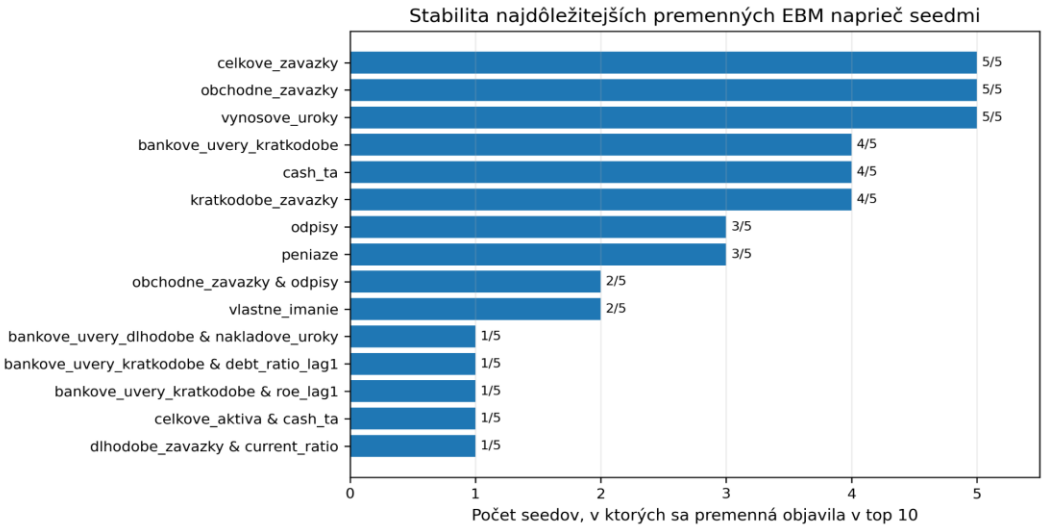
Kľúčovým prínosom EBM oproti nepriehľadným black-box modelom je schopnosť vizualizovať tvarové funkcie pre každú premennú (Maturo et al., 2025). Táto funkcia ukazuje, ako sa rôzne hodnoty danej premennej premietajú do logaritmu šancí zlyhania (*log-odds*), pri zachovaní ostatných premenných na ich priemerných alebo referenčných hodnotách .



Obrázok č.4: Tvarové funkcie modelu EBM pre top premenné.

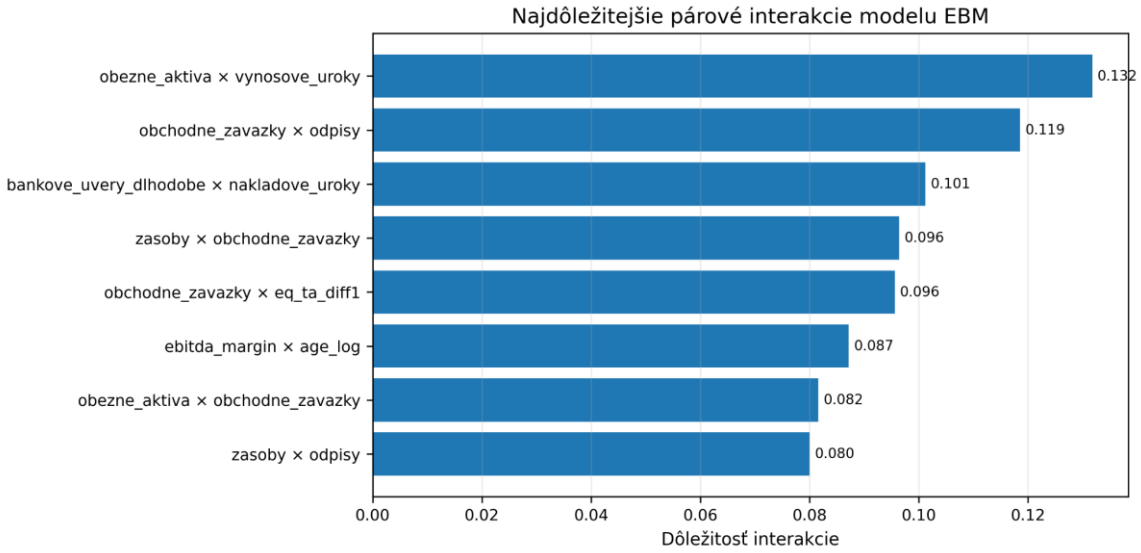
Obrázok č.4 zobrazuje tvarové funkcie šiestich najdôležitejších premenných EBM modelu, pričom každý panel zachytáva marginálny príspevok danej premennej k log-odds pravdepodobnosti zlyhania pri zachovaní *ceteris paribus* (Nori et al., 2019). Najvýznamnejšou premennou sú obchodné záväzky (dôležitosť = 0,2434), ktorých tvarová funkcia vykazuje ostrý diskontinuitný skok. Firmy s nulovými záväzkami dostávajú silný ochranný príspevok (cca -0,40), zatiaľ čo pre akékoľvek kladné hodnoty príspevok skokovo narastá na hodnotu okolo +0,31 a ďalej zostáva konštantný, čo naznačuje, že model reaguje na samotnú prítomnosť obchodných záväzkov, nie na ich absolútny objem. Podobný prahový vzor vykazujú aj krátkodobé bankové úvery (dôležitosť = 0,1538) a krátkodobé záväzky (dôležitosť = 0,1110). Pri nulových hodnotách je ich príspevok k riziku záporný, zatiaľ čo po prekročení určitej úrovne sa stabilizuje približne na úrovni +0,35, respektíve +0,18. Tento výsledok naznačuje, že krátkodobé záväzky môžu zvyšovať nesúlad splatností medzi aktívami a pasívami, ktorý patrí medzi kľúčové prediktory likviditnej krízy (Diamond, 1991).

Tvarová funkcia výnosových úrokov (dôležitosť = 0,1790) sa na prvý pohľad javí ekonomicky menej jednoznačná. Podniky s nulovou hodnotou tejto položky majú záporný príspevok k riziku približne na úrovni −0,40, zatiaľ čo prítomnosť kladných úrokových výnosov posúva príspevok do kladných hodnôt. Tento vzťah možno vysvetliť tým, že v slovenskom účtovníctve môžu výnosové úroky zahŕňať aj vnútroskupinové pôžičky, a preto môžu byť podniky s nenulovou hodnotou tejto premennej častejšie zastúpené v skupinových štruktúrach náchylnejších na kaskádové zlyhanie. Celkové záväzky (dôležitosť = 0,1226) rastú od ochranného záporného príspevku pri nule smerom k stabilnej kladnej úrovni, pričom ich nižšia dôležitosť v porovnaní so samostatnými premennými naznačuje, že EBM uprednostňuje informáciu o štruktúre záväzkov pred ich celkovým objemom, čo je konzistentné s dôrazom literatúry na štruktúru dlhu (Leland & Toft, 2019). Napokon, tvarová funkcia ukazovateľa cash_ta (dôležitosť = 0,1080) ukazuje, že podniky s nižšou hotovostnou rezervou dosahujú vyšší príspevok k riziku zlyhania. So zvyšujúcou sa hodnotou ukazovateľa tento príspevok postupne klesá smerom k neutrálnej úrovni. Výsledok je v súlade s predpokladom, že nižšia likvidita zvyšuje pravdepodobnosť platobnej neschopnosti (Beaver, 1966).



Obrázok č.5: Globálna dôležitosť premenných alebo stabilita top premenných modelu EBM.

Globálna interpretácia modelu EBM bola doplnená analýzou stability najvýznamnejších premenných naprieč piatimi nezávislými odhadmi s rôznymi počiatočnými podmienkami (*seedmi*). Táto analýza slúži ako overenie robustnosti výsledkov. Premenné, ktoré konzistentne vstupujú medzi desať najvýznamnejších naprieč všetkými seedmi, reprezentujú štatisticky stabilné a ekonomicky interpretovateľné vzťahy, nie artefakty konkrétneho odhadu (Káčer a Alexy, 2025). Tri premenné dosiahli maximálnu stabilitu 5/5 (Obrázok č.5). Premenná celkové záväzky zachytáva mieru finančnej páky konzistentne s Altmanovým (1968) Z-skóre. Dominancia premennej *obchodne_zavazky* je konzistentná s Beaverovou (1966) hierarchiou včasných indikátorov finančnej tiesne, ktorá hovorí že zhoršujúca sa platobná disciplína voči dodávateľom je empiricky najspoľahlivejším signálom likvidných ťažkostí. Vysoká stabilita premennej *vynosove_uroky* môže fungovať ako proxy finančnej rezervy alebo odvetvovej pozície, pričom ich predikčná sila môže čiastočne reflektovať sektorové fixed efekty (firmy z odvetví s tradíciou finančných investícií). Spomedzi premenných s čiastočnou stabilitou (4/5) sa opakovane objavovali *bankove_uvery_kratkodobe*, *kratkodobe_zavazky* a *cash_ta*. Ich ekonomická interpretácia je jednoznačná, krátkodobé bankové úvery a záväzky zachytávajú riziko refinancovania, teda situáciu, keď podnik nedokáže pri splatnosti obnoviť alebo nahradiť krátkodobý dlh novým financovaním (Ohlson, 1980). Okamžitá likviditná rezerva *cash_ta* je Beaverovou (1966) primárnou premennou cash flow modelu. Výsledky globálnej dôležitosti premenných naznačujú, že štruktúra záväzkov a krátkodobé financovanie patria medzi hlavné prediktory zlyhania v slovenskom korporátnom prostredí, čo je v súlade so zisteniami Káčera a Alexyho (2025).



Obrázok č.6: Najdôležitejšie párové interakcie modelu EBM.

Identifikované párové interakcie naznačujú, že predikované riziko zlyhania v modeli EBM nie je determinované iba samostatným pôsobením jednotlivých premenných, ale aj ich vzájomnými interakciami. Práve schopnosť zachytiť takéto nelineárne interakčné vzťahy predstavuje jeden z hlavných ekonometrických argumentov pre uprednostnenie EBM pred logistickou regresiou (Maturo et al., 2025). Najvýznamnejšou interakciou bola kombinácia *obezne_aktiva x vynosove_uroky* (dôležitosť 0,132), zachytávajúca spoločný efekt krátkodobých aktív a príjmov z finančných investícií. Firmy s nízkou hodnotou oboch premenných čelia dvojnásobnému likviditnému riziku pri absencii operačných aj finančných rezerv. Interakcia *obchodne_zavazky* × *odpisy* (0,119) naznačuje, že riziko zlyhania rastie najmä pri podnikoch s vysokými záväzkami a nízkymi odpismi. Môže ísť o firmy, ktoré majú vysoké záväzky, ale zároveň nevykazujú vyššiu investičnú aktivitu do fixných aktív. Interakcia *bankove_uvery_dlhodobe* × *nakladove_uroky* (0,101) zachytáva vzťah medzi úrovňou dlhodobých úverov a nákladmi na jeho obsluhu. Podniky s vyšším dlhodobým zadlžením a zároveň vyššími nákladovými úrokmi čelia dlhodobej záťaži obsluhy dlhu, konzistentne s Ohlsonovým (1980) modelom platobnej neschopnosti. Z trendových interakcií je dôležitá najmä kombinácia *obchodne_zavazky* × *eq_ta_diff1* (0,096). Tá ukazuje, že riziko sa zvyšuje vtedy, keď sa vysoké záväzky spájajú so zhoršovaním kapitálovej štruktúry. Model teda nezachytáva iba aktuálnu úroveň zadlženosti, ale aj jej nepriaznivý vývoj v čase (Gavurová et al., 2017).

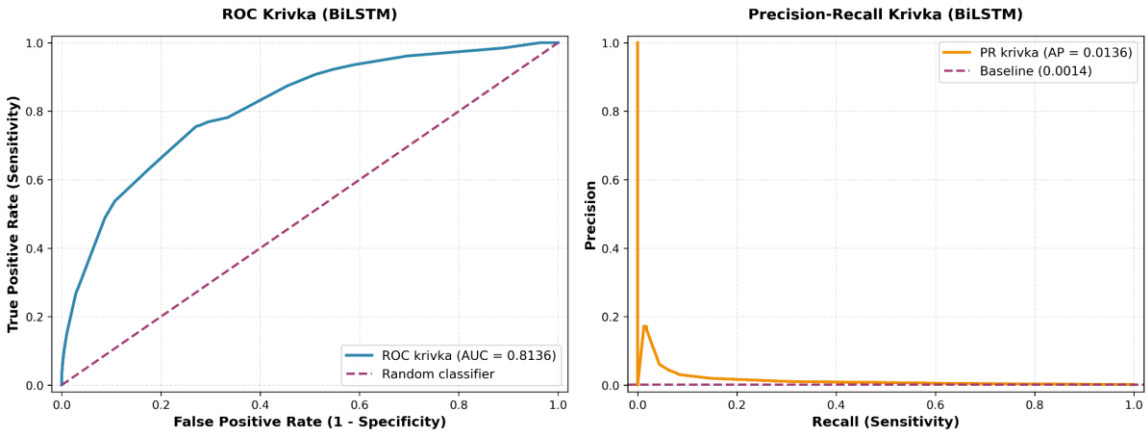
Výsledky modelu EBM dokumentujú, že vnútorne interpretovateľná nelineárna špecifikácia dokáže zachytiť zložitejšie a ekonomicky odôvodnené vzťahy medzi účtovnými

položkami a rizikom zlyhania ako klasická logistická regresia. ROC-AUC vo výške 0,882 na testovacej vzorke, KS štatistika 0,611 a lift 24,2 v hornom 1 % rizikového poradia potvrdzujú silnú diskriminačnú schopnosť modelu, ako aj jeho praktickú využiteľnosť pri predbežnej identifikácii najrizikovejších podnikov. Dominancia záväzkových premenných, krátkodobého financovania a likvidity v globálnom profile dôležitosti je konzistentná s etablovanou literatúrou predikcie zlyhania a potvrdzuje, že záväzková štruktúra a krátkodobé financovanie predstavujú kľúčové zdroje finančnej zraniteľnosti v slovenskom korporátnom prostredí (Beaver, 1966; Altman, 1968; Ohlson, 1980). Tvarové funkcie a párové interakcie ďalej odhaľujú nelinearity a kombinačné efekty, ktoré sú ekonomicky interpretovateľné a metodologicky zodpovedajú najnovším štandardom XAI v oblasti predikcie zlyhania firiem (Maturo et al., 2025).

4.3 Výsledky modelu BiLSTM

Tretím hodnoteným modelom bola sekvenčná neurónová sieť BiLSTM (*Bidirectional Long Short-Term Memory*), zaradená do analýzy s cieľom overiť, či explicitné modelovanie časovej dynamiky finančných ukazovateľov prináša dodatočnú predikčnú hodnotu oproti modelom pracujúcim s jednoročnými prierezovými pozorovaniami. Na rozdiel od logistickej regresie a EBM, BiLSTM spracúva sekvencie historických finančných výkazov, a je preto schopný zachytiť trajektóriu finančného zdravia podniku namiesto jeho stavu v jedinom sledovanom roku. Tento prístup je konzistentný s literatúrou o finančnej tiesni ako postupnom procese (Lau, 1987; Whitaker, 1999), podľa ktorej sa zhoršovanie finančného zdravia podniku prejavuje v sérii pozorovateľných zmien v účtovných ukazovateľoch už niekoľko rokov pred formálnym zlyhaním.

Na testovacej vzorke rokov 2018 - 2019 zahŕňajúcej 285 092 pozorovaní a 389 skutočných zlyhaní dosiahol model hodnotu ROC-AUC 0,814 , PR-AUC 0,014 (Obrázok č.7) a KS štatistiku 0,489 (Tabuľka č.13). Medziročná stabilita výsledkov bola priaznivá. V roku 2018 dosiahol model ROC-AUC 0,812 a PR-AUC 0,019, v roku 2019 ROC-AUC 0,815 a PR-AUC 0,009. Nižšia hodnota PR-AUC v roku 2019 súvisí s menším počtom skutočných zlyhaní (179 oproti 210 v roku 2018), čo zvyšuje citlivosť tohto ukazovateľa na absolútny počet pozitívnych prípadov. Konzistentnosť KS štatistiky naprieč rokmi potvrdzuje, že diskriminačná schopnosť modelu nevykazuje systematický úpadok v čase, čo je pri mimovzorkovej validácii kľúčovým kritériom stability odhadovaných vzťahov.



Obrázok č.7: ROC krivka a *precision-recall* krivka modelu BiLSTM na testovacej vzorke.

Tabuľka č.13: Diskriminačné metriky modelu BiLSTM na testovacej vzorke (2018 – 2019)

Modelový výstup	**ROC-AUC**	**PR-AUC**	**KS**	**Brier**
Jednotlivý model (seed 42)	0,780	0,006	0,417	0,1387
5-seed ensemble (nekalibrovaný)	0,816	0,016	0,489	0,0530
5-seed ensemble (kalibrovaný)	0,814	0,014	-	0,0014

**Poznámka: PR-AUC je citlivejšou mierou výkonu pri extrémne nevyváženej pozitívnej triede (0,22 %). Kalibrovaný Brier hodnotí kvalitu pravdepodobnostných prognóz podľa Briera (1950). Bootstrapové CI pre ROC-AUC a PR-AUC kalibrovaného ensemble: 0,793 – 0,833 a 0,009 – 0,021.*

Medziročná stabilita výsledkov bola priaznivá. V roku 2018 dosiahol model ROC-AUC 0,812 a PR-AUC 0,019, v roku 2019 ROC-AUC 0,815 a PR-AUC 0,009. Nižšia hodnota PR-AUC v roku 2019 súvisí s menším počtom skutočných zlyhaní (179 oproti 210 v roku 2018), čo zvyšuje citlivosť tohto ukazovateľa na absolútny počet pozitívnych prípadov. Konzistentnosť KS štatistiky naprieč rokmi potvrdzuje, že diskriminačná schopnosť modelu nevykazuje systematický úpadok v čase, čo je pri mimovzorkovej validácii kľúčovým kritériom stability odhadovaných vzťahov.

Voľba klasifikačného prahu závisí od toho, akú váhu pripisujeme chybám I. a II. druhu, keďže ich ekonomické dôsledky nie sú rovnaké. Pri prahu maximalizujúcom Youdenov index (0,0018) model identifikoval 247 z 389 skutočných zlyhaní, čo zodpovedá senzitivite 63,5 %. Zároveň však vygeneroval 50 817 falošne pozitívnych prípadov, takže presnosť pozitívnej predikcie zostala na úrovni 0,48 %. Z pohľadu finančného dohľadu, kde má chyba II. druhu, teda prehliadnutie skutočne rizikového podniku, spravidla závažnejšie dôsledky než falošný poplach, je metodologicky vhodnejší Youdenov prah. Prah

optimalizovaný podľa F1 skóre síce dosahuje vyššiu presnosť pozitívnej predikcie 16,3 %, ale zachytáva iba malú časť skutočných zlyhaní, keďže jeho senzitivita je len 1,8 %. Nižší absolútny počet zachytených zlyhaní preto súvisí najmä s veľmi nízkou základnou mierou pozitívnej triedy, nie so slabou diskriminačnou schopnosťou modelu.

Doplnkový pohľad na praktickú využiteľnosť modelu poskytuje *top-k* analýza, ktorá hodnotí jeho schopnosť koncentrovať budúce zlyhania v hornej časti rizikového poradia. Táto vlastnosť priamo relevantnú pre aplikácie v úverovom skóringu a finančnom dohľade.

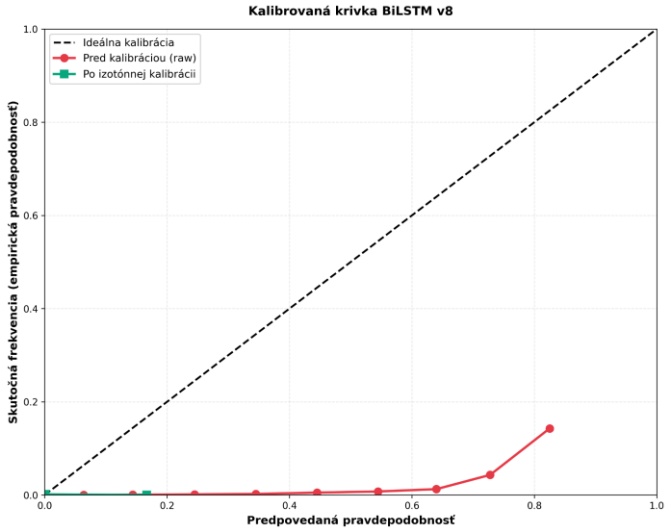
Tabuľka č.14: Top-k analýza modelu BiLSTM na testovacej vzorke.

Riziková skupina	Počet pozorovaní	Zachytené zlyhania	Miera zachytenia	Lift
Top 1 %	2 851	58 z 389	14,9 %	14,9
Top 5 %	14 255	132 z 389	33,9 %	6,8
Top 10 %	28 510	201 z 389	51,7 %	5,2

**Poznámka: Lift = miera zachytenia / podiel skupiny v celkovej populácii. Referenčný počet zlyhaní: 389 (testovacia vzorka 2018 – 2019).*

V hornom 1 % najrizikovejších pozorovaní (2 851 podnikov) model zachytil 14,9 % všetkých budúcich zlyhaní s liftom 14,9. Táto hodnota indikuje, že modelom selektovaná skupina zlyháva takmer pätnásťkrát častejšie než náhodne vybratá vzorka. Kontrola desatiny najrizikovejšej populácie by identifikovala 51,7 % všetkých budúcich zlyhaní v testovacom období (Tabuľka č.14). Tieto výsledky potvrdzujú, že BiLSTM poskytuje informačnú hodnotu prevyšujúcu neinformovaný výber.

Nekalibrovaný výstup modelu dosiahol Brierovo skóre 0,053, čo naznačuje, že predikované pravdepodobnosti neboli dostatočne zosúladené so skutočnou mierou zlyhaní. Po aplikácii monotónnej nelineárnej kalibrácie sa Brierovo skóre znížilo na 0,001. Kalibračný sklon dosiahol hodnotu 1,016, teda veľmi blízko ideálnej hodnote 1,0, čo poukazuje na dobrý súlad medzi predikovanými pravdepodobnosťami a empirickými mierami zlyhaní. Kalibrované výstupy preto možno interpretovať ako odhady pravdepodobnosti zlyhania, nielen ako rizikové skóre. Vizuálne overenie prostredníctvom kalibračnej krivky je uvedené na Obrázku č.8.



Obrázok č.8: Kalibračná krivka modelu BiLSTM pred a po kalibrácii.

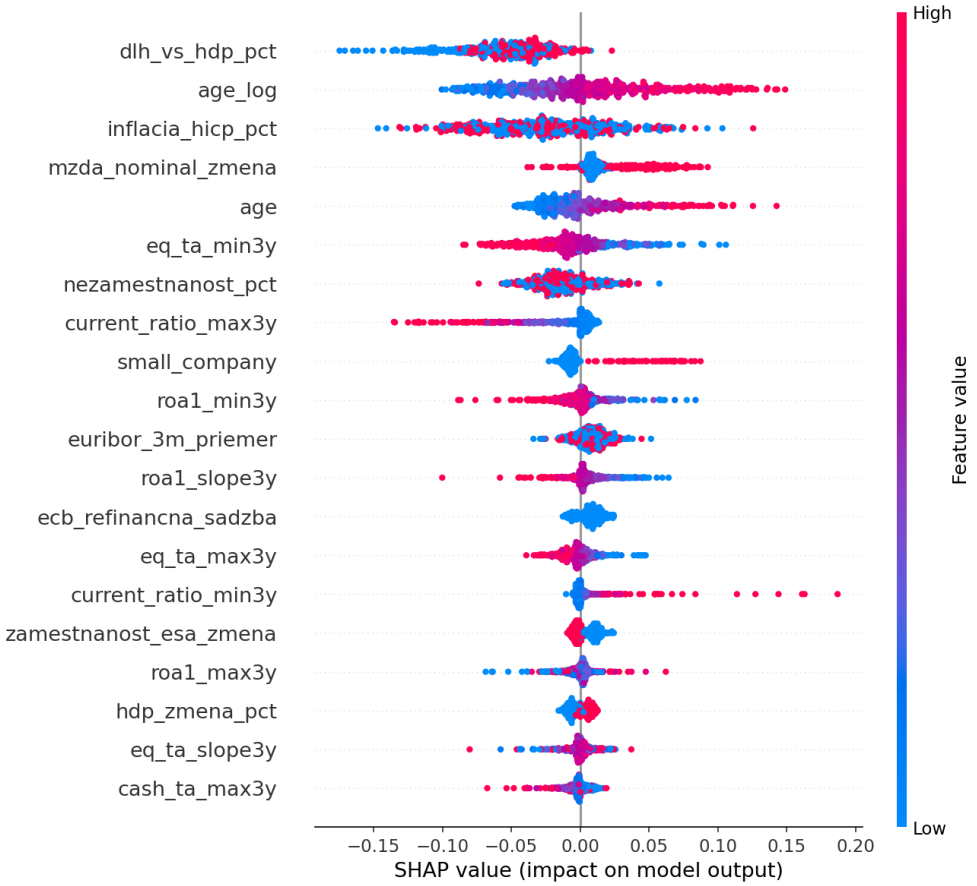
Interpretácia odhadnutých vzťahov bola založená na metóde SHAP, ktorá rozkladá predikciu modelu na príspevky jednotlivých premenných (Shapley, 1953; Lundberg & Lee, 2017). Globálna dôležitosť premenných bola vypočítaná ako priemer absolútnych SHAP hodnôt za vysvetľované pozorovania (n = 500). Výsledky tejto dekompozície sú uvedené v Tabuľke č.15.

Tabuľka č.15: Globálna SHAP dôležitosť - top 10 premenných modelu BiLSTM

Premenná	**Typ premennej**	**Priem. |SHAP|**	**Ekon. mechanizmus**
dlh_vs_hdp_pct	makroekonomická	0,0543	systémové kreditné riziko
age_log	statická / firemnná	0,0418	korporátna mortalita
inflacia_hicp_pct	makroekonomická	0,0410	erózia marží a reálnych miezd
mzda_nominal_zmena	makroekonomická	0,0247	nákladový tlak na firmy
industry_idx	odvetvový embedding	0,0242	sektorové rizikové prémie
eq_ta_min3y	trendová	0,0228	minimálna kapitálová vybavenosť
creditors_days	sekvenčná (fin.)	0,0192	platobná disciplína, Beaver (1966)
nezamestnanost_pct	makroekonomická	0,0187	agregátny dopyt a platobná schopnosť
current_ratio_max3y	trendová	0,0177	maximálna likviditná rezerva
interest_coverage	sekvenčná (fin.)	0,0152	schopnosť obsluhovať dlh, Ohlson (1980)

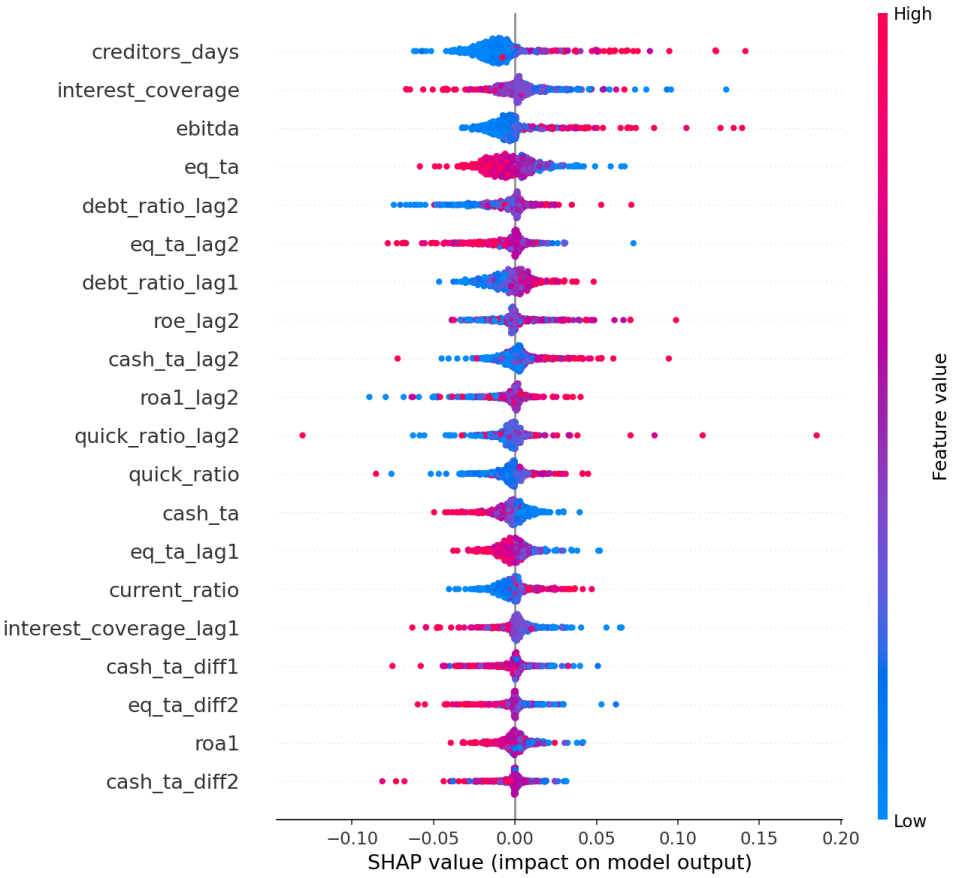
**Poznámka: SHAP hodnoty boli odhadnuté metódou GradientExplainer (Lundberg & Lee, 2017) na vzorke n = 500 pozorovaní (100 pozitívnych, 400 negatívnych) s 100 pozorovaní referenčnej vzorky. Makroekonomické premenné nadobúdajú rovnakú hodnotu pre všetky podniky v danom roku, ich SHAP dôležitosť preto čiastočne zachytáva ročné variácie v agregátnej miere zlyhaní (ročné fixed efekty), nie výhradne individuálne firemnné charakteristiky.*

Najvyššiu priemernú absolútnu SHAP hodnotu dosiahli makroekonomické premenné: pomer verejného dlhu k HDP (*dlh_vs_hdp_pct*, 0,054), inflácia meraná HICP (*inflacia_hicp_pct*, 0,041) a zmena nominálnych miezd (*mzda_nominal_zmena*, 0,025). Tento výsledok naznačuje, že model pri odhade rizika zlyhania významne využíval aj informácie o celkovom makroekonomickom prostredí. V súlade s hypotézou o procyklickom charaktere podnikových zlyhaní možno predpokladať, že vyššia inflácia, rast nákladov a sprísnenie podmienok financovania zvyšujú riziko zlyhania naprieč podnikmi. Tento výsledok však treba interpretovať opatrne. Makroekonomické premenné majú rovnakú hodnotu pre všetky podniky v danom roku, preto ich vysoká SHAP dôležitosť nemusí odrážať iba rozdiely medzi jednotlivými podnikmi (Jiménez & Saurina, 2006). Čiastočne môže zachytávať aj rozdiely medzi rokmi, teda efekt obdobia. Príspevok makroekonomických premenných preto interpretujeme najmä ako prejav systémového rizika, nie ako individuálnu charakteristiku konkrétneho podniku. Rozloženie SHAP hodnôt naprieč pozorovaniami zobrazuje Obrázok č.9.



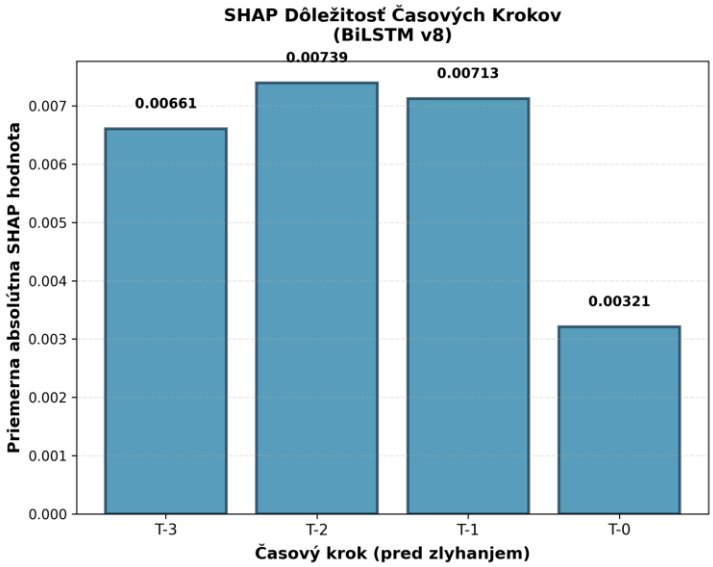
Obrázok č.9: Globálne SHAP hodnoty modelu BiLSTM zobrazujúce makroekonomické a trendové premenné

Z finančných ukazovateľov dosahovala najvyššiu sekvenčnú SHAP dôležitosť premenná *creditors_days* (0,019), zachytávajúca priemernú dobu splatnosti záväzkov voči dodávateľom. Zhoršovanie platobnej disciplíny voči obchodným partnerom patrí medzi spoľahlivé skoré indikátory likviditných problémov (Beaver, 1966). Oneskorené platby totiž môžu signalizovať nedostatok likvidných prostriedkov ešte predtým, ako sa finančné ťažkosti naplno prejavia v súvahových ukazovateľoch. Premenná *interest_coverage* (0,015) vyjadruje schopnosť podniku pokrývať úrokové náklady z prevádzkového zisku. Tento ukazovateľ je významný aj v modeloch Ohlsona (1980) a Altmana (1968), keďže nízka schopnosť obsluhovať dlh môže signalizovať rastúce riziko platobnej neschopnosti (Ohlson, 1980; Altman, 1968). Ukazovatele *eq_ta* a *eq_ta_lag2* (0,013 a 0,012) vyjadrujú kapitálovú vybavenosť podniku. Ich pokles môže signalizovať oslabovanie finančnej rezervy, čo je v súlade s logikou Altmanovho (1968) Z-skóre. Premenná *roe_lag2* (0,012) zachytáva oneskorenú rentabilitu vlastného imania a naznačuje, že model berie do úvahy aj dlhodobejší pokles výnosnosti pred formálnym zlyhaním. Rozloženie SHAP hodnôt naprieč pozorovaniami zobrazuje Obrázok č.10.



Obrázok č.10: Globálne SHAP hodnoty modelu BiLSTM zobrazujúci finančné ukazovatele

Analýza SHAP hodnôt naprieč časovými krokmi ukázala, že najväčší informačný význam mali finančné výkazy z období T−2 a T−1. Priemerná absolútna SHAP hodnota dosiahla pri kroku T−2 hodnotu 0,00740 a pri kroku T−1 hodnotu 0,00713. Nižšiu dôležitosť mali najstarší krok T−3 (0,00661) aj najnovší krok T−0 (0,00321) (Obrázok č.11). Tento výsledok je v súlade s chápaním finančnej tiesne ako postupného procesu (Whitaker, 1999). Finančné problémy sa v účtovných výkazoch často prejavujú už niekoľko rokov pred formálnym zlyhaním, napríklad cez zmeny v zadlženosti, likvidite alebo rentabilite (Whitaker, 1999). Najvyšší informačný prínos preto nesú najmä údaje z jedného až dvoch rokov pred predikovaným obdobím. Nižšia dôležitosť najnovšieho kroku T−0 môže naznačovať, že časť rizikových signálov model zachytáva už v predchádzajúcich obdobiach a následne ich prenáša do finálnej predikcie.



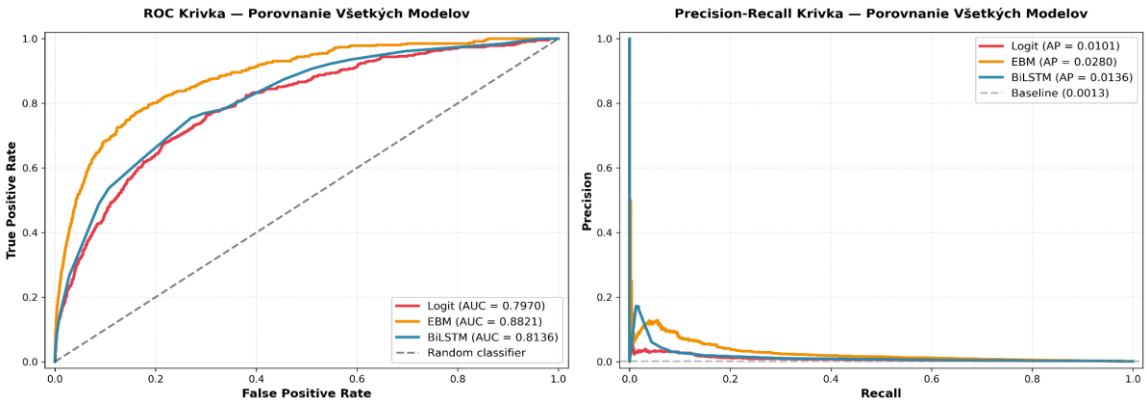
Obrázok č.11: SHAP dôležitosť časových krokov modelu BiLSTM

Celkovo dosiahol model BiLSTM na testovacej vzorke ROC-AUC 0,814 a KS štatistiku 0,489. Výsledky naznačujú, že sekvenčný model dokáže identifikovať relevantné rizikové signály v historickom vývoji finančných ukazovateľov podnikov. SHAP analýza zároveň ukazuje, že model pri odhade rizika využíva kombináciu makroekonomických premenných, firemných charakteristík a časového vývoja finančných ukazovateľov. Výsledky preto potvrdzujú, že historický vývoj finančných ukazovateľov obsahuje relevantnú informáciu o budúcom zlyhaní a predstavuje dôležitý zdroj interpretačnej hodnoty sekvenčného modelu.

4.4 Porovnanie modelov a zhodnotenie výskumnej otázky

Nasledujúca kapitola syntetizuje výsledky všetkých troch odhadnutých modelov v dvoch rovinách, v kvantitatívnom porovnaní diskriminačnej výkonnosti na testovacej vzorke a v kvalitatívnom porovnaní vlastností vysvetliteľnosti a auditovateľnosti. Na základe tohto porovnania je formulovaná odpoveď na výskumnú otázku práce.

Tabuľka č.16 sumarizuje kľúčové výkonnostné metriky všetkých troch modelov na *mimovzorkovej* testovacej vzorke za roky 2018 až 2019. EBM a logistická regresia boli hodnotené na plnej vzorke 348 891 pozorovaní (462 zlyhaní). BiLSTM bol hodnotený na podvzorke 285 092 pozorovaní (389 zlyhaní), pretože vyžaduje sekvencie dĺžky aspoň 4 roky, čím sú vylúčené podniky s kratšou históriou. Rozdiel vo veľkosti vzorky ovplyvňuje porovnateľnosť výsledkov. Priame porovnanie absolútnych hodnôt AUC medzi BiLSTM a ostatnými modelmi môže byť mierne priaznivejšie pre BiLSTM, keďže jeho testovacia vzorka obsahuje relatívne viac etablovaných podnikov so stabilnejšími finančnými vzormi.



Obrázok č. 12: Porovnanie ROC-AUC a PR-AUC modelov Logit, EBM a BiLSTM

Tabuľka č. 16: Porovnanie výkonnosti modelov na testovacej vzorke (2018 – 2019)

Metrika	Logit	BiLSTM	EBM
Testovacia vzorka (n)	348 891	285 092*	348 891
Pozitívne pozorovania	462	389	462
Miera zlyhania	0,132 %	0,136 %*	0,132 %
ROC-AUC [95 % IS]	0,797 [0,777; 0,816]	0,814 [0,793; 0,833]	0,882 [0,867; 0,897]
PR-AUC [95 % IS]	0,010 [0,007; 0,017]	0,014 [0,009; 0,021]	0,028 [0,020; 0,038]
KS štatistika	0,462	0,489	0,611
Brierovo skóre	0,001323	0,001355	0,001310

** BiLSTM bol hodnotený na podvzorke firiem s aspoň 4 rokmi údajov (seq_len = 4); n = 285 092, pozitívnych = 389. Logit a EBM sú hodnotené na plnej testovacej vzorke n = 348 891, pozitívnych = 462. KS štatistika pri BiLSTM je reportovaná pre nekalibrovaný 5-seed ensemble, keďže kalibrácia mení pravdepodobnostnú škálu, nie poradie rizikovosti.*

Brierovo skóre je potrebné interpretovať opatrne, keďže modely sa líšia spôsobom pravdepodobnostnej kalibrácie. Hodnota tejto metriky preto dopĺňa diskriminačné ukazovatele, ale neslúži ako hlavné kritérium výberu modelu. EBM dosahuje ROC-AUC 0,882, čo predstavuje najvyšší výsledok spomedzi všetkých porovnávaných prístupov. Logistická regresia dosiahla AUC 0,797 a BiLSTM AUC 0,814 (Obrázok č.12). Štatistická významnosť rozdielov medzi modelmi je hodnotená DeLongovým testom na zhodných pozorovaniach (DeLong et al., 1988). Výsledky sú zhrnuté v Tabuľke č.17.

Tabuľka č.17: DeLongov test štatistickej významnosti rozdielov ROC-AUC

Porovnanie modelov	ROC-AUC	Rozdiel	z-štatistika	p-hodnota
EBM vs. Logit	0,882 vs. 0,797	EBM +0,085	10,59	<0,001
EBM vs. BiLSTM	0,887 vs. 0,814	EBM +0,073	9,43	<0,001
BiLSTM vs. Logit	0,814 vs. 0,804	BiLSTM +0,009	1,00	0,317

Poznámka: DeLongov test bol vypočítaný na spoločnej podvzorke s dostupnými predikciami oboch modelov, preto sa ROC-AUC môže mierne líšiť od hodnôt v tabuľke č. 15. Test je obojstranný; $p < 0,001$ označuje p-hodnotu nižšiu ako 10^{-6}.

DeLongov test jednoznačne potvrdzuje, že EBM štatisticky významne prekonáva logistickú regresiu ($z = 10,59$, $p < 0,001$) aj model BiLSTM ($z = 9,43$, $p < 0,001$) na spoločnej podvzorke 285 092 pozorovaní. Naproti tomu rozdiel AUC medzi BiLSTM a logistickou regresiou (na tej istej spoločnej vzorke AUC_Logit = 0,804) činí iba 0,009 a nie je štatisticky významný ($z = 1,00$, $p = 0,317$). BiLSTM teda nepreukazuje štatisticky preukázateľné zlepšenie diskriminačnej schopnosti oproti logistickej regresii, hoci jeho bodový odhad AUC je numericky vyšší. Najpravdepodobnejším vysvetlením je kombinácia extrémnej nevyváženosti tried (0,136 % zlyhaní) a redukcie trénovacej vzorky podmienkou *seq_len* = 4, ktoré spoločne obmedzujú množstvo signálu dostupného pre temporálne učenie. Fasano et al. (2025) dosahujú s porovnateľnou LSTM architektúrou výraznejšie zlepšenie nad logitom na talianskych dátach s mierou zlyhaní približne 5 % (Fasano et al., 2025).

Top-k analýza v Tabuľke č. 18 hodnotí modelovú užitočnosť z praktického hľadiska identifikácie najrizikovejších podnikov. EBM zachytil 52,6 % všetkých zlyhaní už v horných 5 % rizikového portfólia (lift 10,5 x), čo je o 20,6 percentuálnych bodov viac ako logistická

regresia (32,0 %) a o 18,7 percentuálnych bodov viac ako BiLSTM (33,9 %). Rozdiely medzi BiLSTM a logitom sú aj tu v rámci štatistickej neistoty, zatiaľ čo EBM významne dominuje pri všetkých hodnotách top-k. Z pohľadu efektívneho portfóliového *screeningu* alebo bankovej expozície je EBM výrazne praktickejším nástrojom hodnotenia rizika (Fasano et al., 2024; Maturo et al., 2025).

Tabuľka č.18: Top-k analýza - miera zachytu zlyhaní v najrizikovejších skupinách

Model	**Top 1 % (n)**	**Top 5 % (n)**	**Top 10 % (n)**	**Top 1 %**	**Top 5 %**	**Top 10 %**	**Lift 5 %**
	Zachytene zlyhania (abs.)			**Miera zachytu (recall)**			
Logit	63	148	212	13,6 %	32,0 %	45,9 %	6,4 x
BiLSTM	58	132	201	14,9 %	33,9 %	51,7 %	6,8 x
EBM	112	243	315	24,2 %	52,6 %	68,2 %	10,5 x

**Poznamka: Lift 5 % = podiel miery zachytu top 5 % oproti zakladnej miere nahodneho modelu. EBM: 52,6 % (10,5x), BiLSTM: 33,9 % (6,8x), Logit: 32,0 % (6,4x).*

Druhou rovinou porovnania je interpretovateľnosť, ktorá tvorí jadro výskumnej otázky. Tabuľka č.18 systematicky zachytáva kľúčové vlastnosti všetkých troch modelov z hľadiska XAI taxonómie (Barredo Arrieta et al., 2020).

Tabuľka č.19: Porovnanie vlastností vysvetliteľnosti modelov

Vlastnost	**Logit**	**BiLSTM**	**EBM**
Typ interpretovateľnosti	Intrinsická	Post-hoc (SHAP)	Intrinsická
Linearita	Lineárna (log-odds)	Nelineárna (LSTM)	Nelineárna (shape fn.)
Interakcie medzi premennými	Manuálny cross-term	Implicitne cez stav LSTM	Automatické párové (8 inter.)
Temporálna dynamika	Nie	Áno (seq_len=4, T-2 dominantný)	Nie
Globálny prehľad	Odds ratio, CI	SHAP feature importance	Tvarové *funkcie* $f_j(x_j)$
Lokálne vysvetlenie	Aditívne skóre	SHAP waterfall / lokálny príklad	Aditívny lokálny profil
Auditovateľnosť	Plná (regulačná)	Stredná (GDPR čl. 22)	Plná (regulačná)
Interpretácia nelinearít	Nie	Obmedzená (black-box LSTM)	Áno (tvarová funkcia)
Stabilita vysvetlení	Vysoka	Stredná (závislosť od seedu)	Vysoká (ensemble 5 seedov)

Logistická regresia je vnútorne interpretovateľný model, keďže každý koeficient možno priamo vyjadriť pomocou pomeru šancí (*odds ratio*), intervalu spoľahlivosti a štatistickej významnosti (Tabuľka č.19). Táto transparentnosť je dôležitá najmä v regulovanom bankovom prostredí, kde sa vyžaduje auditovateľnosť a vysvetliteľnosť modelov *credit scoringu* (Maturo et al., 2025). Jej obmedzením však zostáva lineárna špecifikácia, ktorá neumožňuje prirodzene zachytiť nelineárne vzťahy ani interakcie medzi premennými. Model EBM túto interpretovateľnosť rozširuje o možnosť modelovať nelineárne efekty jednotlivých premenných prostredníctvom tvarových funkcií. Tie ukazujú, ako sa mení príspevok konkrétneho prediktora k riziku zlyhania pri rôznych hodnotách. Napríklad premenná *obchodne_zavazky* vykazuje výraznú zmenu príspevku medzi nulovými a kladnými hodnotami, zatiaľ čo *vynosove_uroky* naznačujú špecifický vzťah pravdepodobne súvisiaci s financovaním v rámci skupinových štruktúr. Takéto nelinearity by v štandardnej logistickej regresii zostali skryté, hoci môžu mať ekonomický význam (Nori et al., 2019). Ďalšou výhodou EBM je schopnosť odhadovať párové interakcie medzi premennými, napríklad spoločný efekt vysokej zadlženosti a nízkej rentability. Model tak dokáže zachytiť situácie, v ktorých riziko zlyhania nevzniká iba pôsobením jednej premennej, ale ich kombináciou. Zároveň si EBM zachováva vysokú mieru transparentnosti, keďže jednotlivé hlavné efekty aj interakcie možno samostatne vizualizovať a ekonomicky interpretovať. BiLSTM tvorí osobitnú hodnotu v podobe časovej interpretácie výsledkov. SHAP hodnoty vypočítané pomocou *GradientExplainer*-u ukazujú, že najväčší informačný prínos má časový krok T−2 s priemernou absolútnou SHAP hodnotou 0,00740, zatiaľ čo najnovší krok T−0 dosahuje hodnotu 0,00321.

Súhrnná odpoveď na výskumnú otázku je, že XAI metódy dokážu zlepšiť predikciu zlyhania slovenských podnikov z hľadiska diskriminačnej schopnosti aj interpretovateľnosti. Hlavný prínos však vyplýva predovšetkým z modelu EBM, nie z rekurentnej neurónovej siete. EBM dosahuje štatisticky významne vyššiu hodnotu AUC než logistická regresia (+0,085; $p < 0,001$), výrazne lepšie výsledky v top-k analýze a zároveň si zachováva vysokú mieru auditovateľnosti. BiLSTM prináša dodatočnú hodnotu najmä v podobe časovej interpretácie rizikových signálov, avšak jeho diskriminačná výkonnosť nie je štatisticky preukázateľne vyššia než výkonnosť tradičného logistického porovnávacieho modleu (Δ AUC = 0,009; $p = 0,317$). Výsledky podporujú záver Maturo et al. (2025), že transparentný XAI model môže pri predikcií zlyhania prekonať aj zložitejšie neurónové siete, najmä ak lepšie spája predikčnú výkonnosť s ekonomickou interpretovateľnosťou (Maturo et al., 2025).

5 Diskusia

Diskusia prepája empirické výsledky všetkých troch modelov s výskumnou otázkou práce a interpretuje ich v kontexte existujúcej literatúry, praktického využitia a limitov štúdie. Celkovú diskriminačnú schopnosť modelov je potrebné hodnotiť vzhľadom na veľmi nízku mieru zlyhaní v testovacej vzorke rokov 2018 až 2019, ktorá dosahuje 0,132 %. Ide o podstatne nižšiu hodnotu než v porovnateľných európskych štúdiách, keďže Fasano et al. (2025) pracujú s talianskym panelom s mierou zlyhaní približne 5 % a Maturo et al. (2025) s podobne vyššou mierou (Fasano et al., 2025; Maturo et al., 2025). Vzhľadom na takto zriedkavý výskyt pozitívnej triedy možno ROC-AUC nad 0,80 pri všetkých troch modeloch považovať za metodicky solídny a vedecky relevantný výsledok.

EBM dosiahol na mimovzorkovej testovacej vzorke ROC-AUC 0,882 a v sledovaných metrikách prekonal oba porovnávané modely. Tento výsledok je v súlade so štúdiou Maturo et al. (2025), ktorá poukazuje na lepšie výsledky EBM oproti logistickej regresii pri predikcii zlyhania podnikov (Maturo et al., 2025). Hlavným zdrojom tohto zlepšenia sú najmä nelineárne tvarové funkcie, ktoré dokážu zachytiť asymetrické účinky finančných ukazovateľov. V tejto práci sa ako najstabilnejšia premenná ukázali *obchodne_zavazky,* ktoré obsadili prvé miesto vo všetkých piatich *seed*-och modelu. To potvrdzuje, že krátkodobá záväzková záťaž predstavuje v slovenskom prostredí robustný signál rizika zlyhania. Významná je aj prítomnosť ôsmich párových interakcií, pričom najvyššiu dôležitosť dosiahla dvojica *obezne_aktiva x vynosove_uroky* (0,132). Tento výsledok naznačuje, že spoločný efekt likvidity a finančných výnosov prináša dodatočnú informáciu nad rámec ich samostatných príspevkov, čím podporuje význam interakčných členov v modeloch zlyhania podnikov (Lou et al., 2013; Maturo et al., 2025).

Z hľadiska interpretovateľnosti, ktorá je jadrom výskumnej otázky, prináša EBM najvýraznejší prínos. Tvarové funkcie umožňujú identifikovať nelineárne vzťahy, ktoré by v logistickej regresii zostali nezachytené. Pri premennej *obchodne_zavazky* model ukazuje výraznú zmenu príspevku medzi nulovými a kladnými hodnotami, čo naznačuje, že riziko sa zvyšuje už pri samotnej prítomnosti obchodných záväzkov, nielen pri raste ich objemu. Tvarová funkcia pre *vynosove_uroky* poukazuje na ekonomicky menej priamočiary vzťah. Podniky s nenulovými výnosovými úrokmi dostávajú kladný príspevok k riziku, čo možno v slovenskom účtovnom prostredí vysvetliť tým, že táto položka môže zahŕňať aj vnútroskupinové pôžičky. Nenulová hodnota tak môže signalizovať zapojenie podniku do

skupinových štruktúr, ktoré môžu byť náchylnejšie na prenos finančných problémov medzi prepojenými subjektmi. Výhodou EBM je, že tieto vzťahy možno vizualizovať a interpretovať priamo zo štruktúry modelu. Model preto poskytuje vysokú mieru transparentnosti a auditovateľnosti bez potreby dodatočnej *post-hoc* interpretačnej vrstvy, čo je dôležité najmä v kontexte regulačných požiadaviek podľa Basel III a EBA *guidelines on internal governance*.

BiLSTM prináša špecifický prínos najmä v časovej interpretácii rizika. SHAP analýza ukazuje, že najvyššiu priemernú absolútnu SHAP hodnotu má časový krok T−2 (0,00740), zatiaľ čo najnižšiu hodnotu dosahuje najnovší krok T−0 (0,00321). Tento výsledok naznačuje, že signály finančnej tiesne možno identifikovať už s predstihom pred formálnym zlyhaním, čo je dôležité pre proaktívny bankový monitoring. Interpretáciu týchto výsledkov však treba doplniť o dve metodické obmedzenia. Po prvé, makroekonomické premenné *dlh_vs_hdp_pct* a *inflacia_hicp_pct* majú rovnakú hodnotu pre všetky podniky v danom roku. Ich vysoké SHAP skóre preto odráža najmä spoločný časový efekt, nie individuálnu charakteristiku konkrétneho podniku. Po druhé, *GradientExplainer* poskytuje iba odhad Shapleyových hodnôt, nie ich presný analytický výpočet. Keďže stabilita tejto aproximácie nebola formálne testovaná, lokálne vysvetlenia pre jednotlivé podniky treba interpretovať opatrne.

Z praktického hľadiska je vhodné využívať jednotlivé modely podľa účelu rozhodovania. Pre portfóliový *screening* a *credit rating* sa ako najvhodnejší javí EBM. *Lift* 10,5 x v horných 5 % najrizikovejších podnikov znamená, že model dokáže zachytiť viac ako polovicu budúcich zlyhaní v relatívne malej časti portfólia. To umožňuje efektívnejšie nasmerovať analytické kapacity na podniky s najvyšším rizikom. Pri priebežnom monitorovaní existujúcich úverových vzťahov môže mať doplnkovú hodnotu BiLSTM, keďže umožňuje identifikovať rizikové signály v časovom vývoji finančných ukazovateľov. Zistenie zvýšeného rizika už v období T−2 môže veriteľovi poskytnúť časový priestor na skoršiu reakciu, napríklad úpravu podmienok financovania alebo reštrukturalizáciu expozície pred formálnym zlyhaním podniku. Logistická regresia si napriek nižšej predikčnej výkonnosti zachováva významnú úlohu v regulačnom reportingu a komunikácii s nefinančnými zainteresovanými stranami. Pomer šancí spolu s intervalmi spoľahlivosti poskytujú jednoduché, transparentné a obhájiteľné vysvetlenie úverových rozhodnutí, čo je dôležité najmä v prostredí regulovaného bankovníctva.

Štúdia má viaceré obmedzenia, ktoré je potrebné zohľadniť. Výsledky vychádzajú zo slovenského panelu a testovacieho obdobia 2018 - 2019, teda z relatívne stabilného

makroekonomického prostredia. Ich platnosť pre krízové obdobia, napríklad pandémiu COVID-19 alebo energetickú krízu v roku 2022, si preto vyžaduje ďalšie overenie. Ďalším obmedzením je definícia zlyhania založená na formálnom insolvenčnom konaní. Tá môže podhodnocovať skutočný rozsah finančnej tiesne, keďže časť podnikov vo finančných problémoch nemusí nikdy vstúpiť do formálneho konania. Pri modeli BiLSTM navyše podmienka minimálnej dĺžky sekvencie seq_len = 4 zvýhodňuje dlhšie existujúce podniky a vylučuje mladšie rizikové subjekty, čím obmedzuje reprezentatívnosť výsledkov pre celú populáciu podnikov. Napokon, vysoké SHAP hodnoty makroekonomických premenných v modeli BiLSTM treba interpretovať opatrne. Keďže tieto premenné majú rovnakú hodnotu pre všetky podniky v danom roku, ich význam odráža skôr spoločný časový efekt než individuálne rizikové charakteristiky konkrétnych podnikov.

Prezentované zistenia otvárajú niekoľko smerovaní pre budúci výskum. Prirodzeným rozšírením je komparatívna stredoeurópska analýza, aplikáciou rovnakej metodiky na panely z Českej republiky, Maďarska alebo Poľska by bolo možné testovať, či dominancia EBM pretrváva aj pri vyšších mierach zlyhaní, alebo či je špecifická pre slovenský kontext. Rovnako prínosné by bolo overiť robustnosť modelov na krízovom období rokov 2020 - 2022. Takáto analýza by ukázala, či si EBM zachováva stabilné tvarové funkcie a či zostáva kalibrácia pravdepodobností spoľahlivá aj v stresových podmienkach. Tieto poznatky sú dôležité najmä pre regulačné stresové testovanie v rámci EBA *stress testing framework*. V oblasti architektúr hlbokého učenia by mohli transformerové modely (Temporal Fusion Transformer, TabTransformer) prekonať BiLSTM pri triede problémov s malým počtom pozitívnych tried a nepravidelne vzorkovanými časovými radmi. Napokon, ďalší výskum by sa mal zamerať aj na formálne overenie regulačnej použiteľnosti tvarových funkcií EBM a SHAP interpretácii BiLSTM v kontexte článku 22 GDPR a odporúčaní EBA. Takéto hodnotenie by umožnilo lepšie posúdiť, či sú výstupy XAI modelov dostatočne transparentné, stabilné a auditovateľné pre praktické využitie v regulovanom finančnom prostredí. Ide o oblasť, v ktorej súčasná literatúra zatiaľ poskytuje len čiastkové závery (Maturo et al., 2025; Barredo Arrieta et al., 2020).

Záver

Cieľom diplomovej práce bolo posúdiť, do akej miery dokážu metódy vysvetliteľnej umelej inteligencie zlepšiť predikciu zlyhania slovenských firiem v porovnaní s tradičnou logistickou regresiou. Práca vychádzala z účtovných údajov slovenských podnikov za roky 2011 až 2019, pričom zlyhanie bolo definované ako vstup podniku do konkurzu alebo reštrukturalizácie v nasledujúcom období. Keďže zlyhanie predstavuje v analyzovaných dátach extrémne zriedkavú udalosť, hodnotenie modelov sa nesústredilo na celkovú presnosť, ale najmä na diskriminačnú schopnosť, PR-AUC, KS štatistiku a schopnosť koncentrovať budúce zlyhania v hornej časti rizikového poradia.

V analytickej časti boli porovnané tri prístupy: logistická regresia ako transparentný ekonometrický referenčný model, Explainable Boosting Machine ako nelineárny *glass-box* model a sekvenčný model BiLSTM doplnený o SHAP interpretáciu. Najvyššiu výkonnosť dosiahol model EBM, ktorý na testovacom období rokov 2018 až 2019 dosiahol ROC-AUC 0,882, PR-AUC 0,028 a KS štatistiku 0,611. Zároveň v horných 5 % najrizikovejších podnikov zachytil 52,6 % všetkých budúcich zlyhaní. Logistická regresia síce dosiahla nižšiu výkonnosť, no potvrdila význam transparentného a ekonomicky interpretovateľného porovnávacieho modelu. BiLSTM priniesol pridanú hodnotu najmä pri interpretácii časového vývoja rizikových signálov, avšak jeho celková diskriminačná schopnosť neprekonala EBM.

Na výskumnú otázku možno odpovedať tak, že metódy vysvetliteľnej umelej inteligencie dokážu zlepšiť predikciu zlyhania slovenských podnikov, pričom najvýraznejší prínos priniesol EBM. Tento model poskytol najlepší kompromis medzi predikčnou výkonnosťou, interpretovateľnosťou a praktickou použiteľnosťou. Výsledky zároveň naznačujú, že pri tabuľkových účtovných dátach nemusí byť najkomplexnejší model automaticky najvhodnejším riešením. Transparentný nelineárny model môže byť stabilnejší, presnejší a jednoduchšie obhájiteľný než sekvenčná neurónová sieť s *post-hoc* vysvetlením.

Medzi hlavné obmedzenia práce patrí viazanosť výsledkov na slovenské podnikové dáta a testovacie obdobie 2018 až 2019, ktoré nezachytáva neskoršie krízové šoky. Budúci výskum by mal overiť stabilitu modelov na dlhšom časovom horizonte a v krízových obdobiach.

Zoznam literatúry

Aas, K., Jullum, M., & Løland, A. (2021). Explaining individual predictions when features are dependent: More accurate approximations to Shapley values. Artificial Intelligence, 298, 103502. https://doi.org/10.1016/j.artint.2021.103502

Altman, E. I. (1968). Financial Ratios, Discriminant Analysis and the Prediction of Corporate Bankruptcy. The Journal of Finance, 23(4), 589–609. https://doi.org/10.2307/2978933

Altman, E. I., Sabato, G., & Wilson, N. (2010). The value of non-financial information in SME risk management. The Journal of Credit Risk, 6(2), 95–127. https://doi.org/10.21314/JCR.2010.110

Araf, I., Idri, A., & Chairi, I. (2024). Cost-sensitive learning for imbalanced medical data: A review. Artificial Intelligence Review, 57(4), Článok 80. https://doi.org/10.1007/s10462-023-10652-8

Barboza, F., Kimura, H., & Altman, E. (2017). Machine learning models and bankruptcy prediction. Expert Systems with Applications, 83, 405–417. https://doi.org/10.1016/j.eswa.2017.04.006

Barredo Arrieta, A., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. Information Fusion, 58, 82–115. https://doi.org/10.1016/j.inffus.2019.12.012

Baumöhl, E., Iwasaki, I., & Kočenda, E. (2020). Firm survival in new EU member states. Economic Systems, 44(1), Článok 100743. https://doi.org/10.1016/j.ecosys.2020.100743

Beaver, W. H. (1966). Financial Ratios As Predictors of Failure. Journal of Accounting Research, 4, 71–111. https://doi.org/10.2307/2490171

Bergstra, J., Bardenet, R., Bengio, Y., & Kégl, B. (2011). Algorithms for Hyper-Parameter Optimization. Neural Information Processing Systems.

DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing the Areas under Two or More Correlated Receiver Operating Characteristic Curves: A Nonparametric Approach. Biometrics, 44(3), 837–845. https://doi.org/10.2307/2531595

Diamond, D.W. (1991). Debt Maturity Structure and Liquidity Risk. Quarterly Journal of Economics, 106, 709-737.

Dieber, J., & Kirrane, S. (2020). Why model why? Assessing the strengths and limitations of LIME. arXiv preprint arXiv:2012.00093. https://doi.org/10.48550/arXiv.2012.00093

Eisenbeis, R. A. (1977). Pitfalls in the application of discriminant analysis in business, finance, and economics. The Journal of Finance, 32(3), 875–900. https://doi.org/10.1111/j.1540-6261.1977.tb01995.x

Elkan, C.P. (2001). The Foundations of Cost-Sensitive Learning. International Joint Conference on Artificial Intelligence.

European Union. (2024). Regulation (EU) 2024/1689 of the European Parliament and of the Council. Official Journal of the European Union.

Fasano, F., Adornetto, C., Zahid, I., La Rocca, M., Montaleone, L., Greco, G., & Cariola, A. (2025). The dilemma of accuracy in bankruptcy prediction: A new approach using explainable AI techniques to predict corporate crises. European Journal of Innovation Management, 28(11), 1–22. https://doi.org/10.1108/EJIM-06-2024-0633

Fernández, A., García, S., Galar, M., Prati, R. C., Krawczyk, B., & Herrera, F. (2018). Cost-sensitive learning. In Learning from imbalanced data sets (pp. 63–78). Springer. https://doi.org/10.1007/978-3-319-98074-4_4

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Gavurová, B., Janke, F., Packová, M., & Prídavok, M. (2017). Analysis of impact of using the trend variables on bankruptcy prediction models performance. Ekonomický časopis, 65(4), 370–383.

Goodman, B., & Flaxman, S. (2016). EU regulations on algorithmic decision-making and a "right to explanation". AI Magazine, 38(3), Article 3. https://doi.org/10.1609/aimag.v38i3.2741

Gunning, D. (2019). DARPA's explainable artificial intelligence (XAI) program. In Proceedings of the 24th International Conference on Intelligent User Interfaces (pp. ii–ii). https://doi.org/10.1145/3301275.3308446

Guo, H., Li, Y., Shang, J., Gu, M., Huang, Y., & Gong, B. (2017). Learning from class-imbalanced data: Review of methods and applications. Expert Systems with Applications, 73, 220–239. https://doi.org/10.1016/j.eswa.2016.12.035

Hastie, T. J., & Tibshirani, R. J. (2017). Generalized additive models. https://doi.org/10.1201/9780203753781

He, H., & Garcia, E. A. (2009). Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263–1284. https://doi.org/10.1109/TKDE.2008.239

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9, 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16, 321–357. https://doi.org/10.1613/jair.953

Izmailov, P., Podoprikhin, D., Garipov, T., Vetrov, D., & Wilson, A. (2018). Averaging weights leads to wider optima and better generalization. arXiv preprint arXiv:1803.05407. https://doi.org/10.48550/arXiv.1803.05407

Johnson, J. M., & Khoshgoftaar, T. M. (2019). Survey on deep learning with class imbalance. Journal of Big Data, 6, Článok 27. https://doi.org/10.1186/s40537-019-0192-5

Káčer, M., & Alexy, M. (2025). SMEs' failure prediction: Are machine learning models superior? Studies in Economics and Finance, 42. https://doi.org/10.1108/SEF-09-2024-0629

King, Gary & Zeng, Langche. (2003). Logistic Regression in Rare Events Data. Journal of Statistical Software. 8. 10.18637/jss.v008.i02.

Lau, A.H. (1987). A 5-State Financial Distress Prediction Model. Journal of Accounting Research, 25, 127-138.

Leland, H., & Toft, K. (2019). Optimal capital structure, endogenous bankruptcy, and the term structure of credit spreads. In World Scientific reference on contingent claims analysis in corporate finance (pp. 61–96). World Scientific Publishing. https://doi.org/10.1142/9789814759595_0003

Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2020). Focal loss for dense object detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, 42(2), 318–327. https://doi.org/10.1109/TPAMI.2018.2858826

Linardatos, P., Papastefanopoulos, V., & Kotsiantis, S.B. (2020). Explainable AI: A Review of Machine Learning Interpretability Methods. Entropy, 23.

Ling, C.X., & Sheng, V. (2008). Cost-Sensitive Learning and the Class Imbalance Problem.

Lipton, Z. (2018). The Mythos of Model Interpretability: in machine learning, the concept of interpretability is both important and slippery. Queue, 16. https://doi.org/10.1145/3236386.3241340

Long, J. S. (1997). Regression models for categorical and limited dependent variables: Advanced quantitative techniques in the social sciences (Vol. 7). Sage Publications.

Lou, Y., Caruana, R., Gehrke, J., & Hooker, G. (2013). Accurate intelligible models with pairwise interactions. Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 623–631. https://doi.org/10.1145/2487575.2487579

López, V., Fernández, A., García, S., Palade, V., & Herrera, F. (2013). An insight into classification with imbalanced data: Empirical results and current trends on using data intrinsic characteristics. Information Sciences, 250, 113–141. https://doi.org/10.1016/j.ins.2013.07.007

Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30, 4765–4774. https://doi.org/10.48550/arXiv.1705.07874

Maturo, F., Riccio, D., & Mazzitelli, A. (2025). Explainable gradient boosting for corporate crisis forecasting in Italian businesses. Annals of Operations Research, 353(1), 815–839. https://doi.org/10.1007/s10479-025-06570-3

Minh, D., Wang, H.X., Li, Y.F., & Nguyen, T.N. (2021). Explainable artificial intelligence: a comprehensive review. Artificial Intelligence Review, 55, 3503 - 3568.

Nori, H., Jenkins, S., Koch, P., & Caruana, R. (2019). InterpretML: A unified framework for machine learning interpretability. arXiv preprint arXiv:1909.09223. https://doi.org/10.48550/arXiv.1909.09223

Ohlson, J. A. (1980). Financial Ratios and the Probabilistic Prediction of Bankruptcy. Journal of Accounting Research, 18(1), 109–131. https://doi.org/10.2307/2490395

Prechelt, L. (1998). Early stopping—But when? In G. B. Orr & K. R. Müller (Eds.), Neural networks: Tricks of the trade (Lecture Notes in Computer Science, Vol. 1524). Springer. https://doi.org/10.1007/3-540-49430-8_3

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 1135–1144. https://doi.org/10.1145/2939672.2939778

Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. Nature Machine Intelligence, 1(5), 206–217. https://doi.org/10.1038/s42256-019-0048-x

Shapley, L. S. (1953). A value for n-person games. In H. W. Kuhn & A. W. Tucker (Eds.), Contributions to the theory of games (Vol. 2, pp. 307–318). Princeton University Press.

Sheng, V. S., & Ling, C. X. (2006). Thresholding for making classifiers cost sensitive. Proceedings of the 21st National Conference on Artificial Intelligence, 1, 476–481.

Shumway, T. (2001). Forecasting Bankruptcy More Accurately: A Simple Hazard Model. The Journal of Business, 74(1), 101–124. https://doi.org/10.1086/209665

Srivastava, N., Hinton, G.E., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: a simple way to prevent neural networks from overfitting. J. Mach. Learn. Res., 15, 1929-1958.

Ullah, N., Khan, J., Falco, I., & Sannino, G. (2024). Explainable artificial intelligence: Importance, use domains, stages, output shapes, and challenges. ACM Computing Surveys, 57. https://doi.org/10.1145/3705724

Weber, P., Carl, K. V., & Hinz, O. (2024). Applications of explainable artificial intelligence in finance—a systematic review of finance, information systems, and computer science literature. Management Review Quarterly, 74, 867–907. https://doi.org/10.1007/s11301-023-00320-0

Werbos, P. (1990). Backpropagation through time: What it does and how to do it. Proceedings of the IEEE, 78, 1550–1560. https://doi.org/10.1109/5.58337

Whitaker, R. B. (1999). The early stages of financial distress. Journal of Economics and Finance, 23, 123–132. https://doi.org/10.1007/BF02745946

Wilson, N., Ochotnický, P., & Er, K. (2014). Creation and destruction in transition economies: The SME sector in Slovakia. International Small Business Journal, 34. https://doi.org/10.1177/0266242614558892

Wooldridge, J. M. (2010). Econometric Analysis of Cross Section and Panel Data. The MIT Press. http://www.jstor.org/stable/j.ctt5hhcfr

Youden W. J. (1950). Index for rating diagnostic tests. Cancer, 3(1), 32–35. https://doi.org/10.1002/1097-0142(1950)3:1<32::aid-cncr2820030106>3.0.co;2-3

Zákon č. 7/2005 Z. z. o konkurze a reštrukturalizácii a o zmene a doplnení niektorých zákonov. (2005). Slov-lex. https://www.slov-lex.sk/pravne-predpisy/SK/ZZ/2005/7/

Prehlasujem, že som nástroje AI využil v súlade s princípmi akademickej integrity, a že na využitie týchto nástrojov poukazujem vhodným spôsbom. Nástroj AI som využil pri štylistickom zdokonaľovaní textových pasáži a pri oprave chýb v zdrojom kóde. Všetky odborné analýzy, interpretácie výsledkov a závery sú mojím vlastným dielom.

PRÍLOHY K DIPLOMOVEJ PRÁCI

Reprodukčné notebooky a zdrojový kód empirickej časti sú dostupné v repozitári archivovanom prostredníctvom Zenodo pod DOI: doi.org/10.5281/zenodo.20029429

Tabuľka č.1: Základné nastavenia dátovej prípravy

Parameter	Hodnota použitá v práci
Obdobie vstupných dát	2011 - 2019
Modelové obdobie	2013 - 2019
Tréningové obdobie	2013 – 2016
Validačné obdobie	2017
Testovacie obdobie	2018 – 2019
Typ pozorovania	firmo – rok
Cieľová premenná	zlyhanie podniku v období t+1
Definícia zlyhania	vstup do konkurzu alebo reštrukturalizácie v nasledujúcom období
Random seed	42
Winsorizácia	5. a 95. Percentil
Výpočet winsorizačných hraníc	iba tréningové obdobia
Režim SME filtra	Zjemnený SME/activity filter
Minimálna dĺžka sekvencie pre export BiLSTM	aspoň 2 po sebe nasledujúce roky
Finálne historické okno BiLSTM	seq_len = 4
Hlavné hodnotiace metriky	ROC-AUC, PR-AUC, KS, Brierovo skóre, top-k capture

Tabuľka č.2: Časové rozdelenie modelových datasetov

	Logistická regresia	EBM	BiLSTM
Počet pozorovaní	1 085 539	1 085 539	756 077
Tréning 2013 - 2016	534 710	534 710	336 895
Validácia 2017	159 248	159 248	127 687
Test 2018 - 2019	348 891	348 891	285 092
Miera zlyhania	0,184 %	0,184 %	0,176 %

Tabuľka č.3: Vstupné premenné surového datasetu

Skupina premenných	Premenné
Identifikačné premenné	id, rok, target
Odvetvie a právna forma	sk_nace, pocet_zamestnancov, pravna_forma, datum_vzniku
Aktíva	celkove_aktiva, dlhodoby_nehmotny_majetok, dlhodoby_hmotny_majetok, obezne_aktiva, zasoby, obchodne_pohladavky, peniaze
Vlastné imanie	vlastne_imanie, zakladne_imanie, nerozdeleny_zisk
Záväzky	celkove_zavazky, dlhodobe_zavazky, dlhodobe_obch_zavazky, dlhodobe_danove_dlhy, kratkodobe_zavazky, obchodne_zavazky, kratkodobe_danove_dlhy, kratkodobe_financne_vypomoci
Bankové úvery	bankove_uvery_dlhodobe, bankove_uvery_kratkodobe
Tržby a odpisy	celkove_trzby, trzby_spolu, odpisy, vysledok_hospodarenia_z_hospodarskej_cinnosti
Finančná činnosť	trzby_z_predaja_cennych_papierov_a_podielov, predane_cenne_papiere_a_podiely, vynosy_z_dlhodobeho_financneho_majetku, vynosy_z_kratkodobeho_financneho_majetku, naklady_na_kratkodoby_financny_majetok, vynosy_z_precenenia_cennych_papierov_a_vynosy_z_derivatovych_operacii, naklady_na_precenenie_cennych_papierov_a_naklady_na_derivatove_operacie, tvorba_a_zauctovanie_opravnych_poloziek_k_financnemu_majetku
Úroky, kurzové rozdiely a ostatné finančné položky	vynosove_uroky, nakladove_uroky, kurzove_zisky, kurzove_straty, ostatne_vynosy_z_financnej_cinnosti, ostatne_naklady_na_financnu_cinnost
Výsledok hospodárenia	celkove_dane, ebt, cisty_zisk_strata

Tabuľka č.4: Testovacie vzorky použité pri finálnom porovnaní modelov

	Logistická regresia	EBM	BiLSTM
Testovacia vzorka	348 891	348 891	285 092
Počet zlyhaní	462	462	389
Miera zlyhania	0,132 %	0,132 %	0,136 %
Poznámka	plná testovacia vzorka 2018-2019	plná testovacia vzorka 2018-2019	sekvenčná podvzorka firiem so seq_len = 4

Tabuľka č.5: Finančné ukazovatele a ich výpočet

Premenná	**Vzorec**
cash_ta	peniaze / celkove_aktiva
cash_ratio	peniaze / kratkodobe_zavazky
current_ratio	obezne_aktiva / kratkodobe_zavazky
quick_ratio	(obezne_aktiva - zasoby) / kratkodobe_zavazky
nwc_ta	(obezne_aktiva - kratkodobe_zavazky) / celkove_aktiva
eq_ta	vlastne_imanie / celkove_aktiva
eq_tl	vlastne_imanie / celkove_zavazky
ltd_ta	dlhodobe_zavazky / celkove_aktiva
bl_ta	(bankove_uvery_dlhodobe + bankove_uvery_kratkodobe) / celkove_aktiva
debt_to_equity	celkove_zavazky / vlastne_imanie
debt_ratio / debt_ta	celkove_zavazky / celkove_aktiva
fixed_asset_coverage	(vlastne_imanie + dlhodobe_zavazky) / (dlhodoby_nehmotny_majetok + dlhodoby_hmotny_majetok)
short_debt_ratio	kratkodobe_zavazky / celkove_zavazky
roa1	cisty_zisk_strata / celkove_aktiva
roa2 / roi	ebt / celkove_aktiva
re_ta	nerozdeleny_zisk / celkove_aktiva
roe	cisty_zisk_strata / vlastne_imanie
ros	cisty_zisk_strata / celkove_trzby
ebitda	vysledok_hospodarenia_z_hospodarskej_cinnosti + odpisy
ebitda_margin	ebitda / celkove_trzby
debt_ebitda	celkove_zavazky / ebitda
asset_turnover	celkove_trzby / celkove_aktiva
creditors_days	(365 × obchodne_zavazky) / celkove_trzby
receivables_days	(365 × obchodne_pohladavky) / celkove_trzby
interest_coverage	ebitda / nakladove_uroky
age_log	ln(vek podniku + 1)
log_ta	ln(celkove_aktiva)

*Všetky pomerové ukazovatele boli počítané bezpečným delením (safe divide). Pri nulovom alebo chýbajúcom menovateli je výsledok chýbajúci. Pri EBITDA sa chýbajúce vstupy nahradili 0.

Tabuľka č.6: Dodatočné úprpava extrémnych ukazovateľov pred winsorizáciou

Premenná	**Dolná hranica**	**Horná hranica**
interest_coverage	-100	100
debt_ebitda	-50	50

Tabuľka č.7: Makroekonomické premenné priradené podľa roku - časť 1/2

Rok	**HDP zmena (%)**	**Nezamestnanosť (%)**	**Zamestnanosť ESA zmena (%)**	**Nominálna mzda zmena (%)**
2011	2,6	13,6	1,8	2,2
2012	1,6	13,9	0,1	2,4
2013	0,7	14,2	- 0,8	2,4
2014	2,7	13,2	1,4	4,1
2015	5,2	11,5	2,0	2,9
2016	1,9	9,6	2,4	3,3
2017	2,9	8,1	2,2	4,6
2018	4,1	6,5	2,0	6,2
2019	2,3	5,8	1,0	3,8

Tabuľka č.8: Makroekonomické premenné priradené podľa roku - časť 2/2

Rok	**HICP inflácia (%)**	**ECB refinančná sadzba (%)**	**EURIBOR 3M priemer (%)**	**Dlh/HDP (%)**
2011	4,1	1,00	1,39	43,3
2012	3,7	0,75	0,57	51,7
2013	1,5	0,25	0,22	54,6
2014	- 0,1	0,05	0,21	53,6
2015	- 0,3	0,05	- 0,02	51,6
2016	- 0,5	0,00	- 0,26	52,1
2017	1,4	0,00	- 0,33	51,4
2018	2,5	0,00	- 0,32	49,3
2019	2,8	0,00	- 0,36	48,0

Tabuľka č.9: Definícia zjemneného SME a aktivitného filtra

Komponent filtra	Definícia použitá v práci
Zamestnanecké kritérium	pocet_zamestnancov < 250 alebo chýbajúci údaj o počte zamestnancov
Aktívové kritérium	celkove_aktiva < 43 000 000 EUR
Tržbové kritérium	turnover_for_filter < 50 000 000 EUR
Definícia tržieb pre filter	primárne celkove_trzby; pri chýbajúcej hodnote trzby_spolu
Finančné veľkostné kritérium	aktívové kritérium alebo tržbové kritérium
Aktivitné kritérium podľa aktív	celkove_aktiva >= 5 000 EUR
Aktivitné kritérium podľa tržieb	turnover_for_filter >= 5 000 EUR alebo chýbajúci údaj o tržbách
Finálny filter	zamestnanecké kritérium a finančné veľkostné kritérium a aktivitné kritérium

Tabuľka č.10: Formálny zápis výberového filtra

Krok	Logická podmienka
employee_ok	pocet_zamestnancov < 250 alebo pocet_zamestnancov je chýbajúci
financial_size_ok	celkove_aktiva < 43 000 000 alebo turnover_for_filter < 50 000 000
active_ok	celkove_aktiva >= 5 000 a zároveň (turnover_for_filter >= 5 000 alebo turnover_for_filter je chýbajúci)
sme_mask	employee_ok ∩ financial_size_ok ∩ active_ok

Tabuľka č.11: Veľkosť vzorky po hlavných krokoch spracovania

Krok spracovania	Počet firmo-rokov	Počet pozitívnych pozorovaní	Miera zlyhania
Východiskový dataset	1 591 645	3 431	0,2155 %
Po SME a aktivitnom filtri	1 085 539	1 995	0,184 %
Dataset pre logistickú regresiu	1 085 539	1 995	0,184 %
Dataset pre EBM	1 085 539	1 995	0,184 %
Dataset pre BiLSTM	756 077	1 331	0,176 %

**Poznámka: Pri BiLSTM je počet pozitívnych pozorovaní odvodený z reportovanej miery zlyhania v sekvenčnom datasete, testovacia vzorka BiLSTM obsahuje 389 pozitívnych pozorovaní.*

Tabuľka č.12: Finančné ukazovatele použité na tvorbu dynamických premenných

Základná premenná	Vytvorené transformácie
cash_ta	_lag1, _lag2, _diff1, _diff2
eq_ta	_lag1, _lag2, _diff1, _diff2
ltd_ta	_lag1, _lag2, _diff1, _diff2
roa1	_lag1, _lag2, _diff1, _diff2
re_ta	_lag1, _lag2, _diff1, _diff2
roe	_lag1, _lag2, _diff1, _diff2
ros	_lag1, _lag2, _diff1, _diff2
current_ratio	_lag1, _lag2, _diff1, _diff2
quick_ratio	_lag1, _lag2, _diff1, _diff2
debt_ratio	_lag1, _lag2, _diff1, _diff2
debt_ebitda	_lag1, _lag2, _diff1, _diff2
ebitda_margin	_lag1, _lag2, _diff1, _diff2
interest_coverage	_lag1, _lag2, _diff1, _diff2
asset_turnover	_lag1, _lag2, _diff1, _diff2

**Poznámka: Celkovo bolo vytvorených 56 dynamických premenných. _lag1 označuje hodnotu ukazovateľa v predchádzajúcom roku, _lag2 hodnotu spred dvoch rokov, _diff1 rozdiel oproti predchádzajúcemu roku a _diff2 rozdiel oproti hodnote spred dvoch rokov.*

Tabuľka č.13: Charakteristika exportovaných datasetov

Dataset	Účet	Počet pozorovaní	Počet stĺpcov	Kľúčové špecifiká
data_logit.csv	Logistická regresia	1 085 539	94	surové účtovné položky, odvodené finančné pomery, nefinančné, odvetvové a makro premenné
data_ebm.csv	EBM	1 085 539	155	surové účtovné položky, finančné pomery, lag/diff premenné, odvetvia a makro premenné, NaN nahradené −999
data_rnn.csv	BiLSTM	756 077	126	sekvenčné finančné premenné, dynamické premenné, statické nefinančné, odvetvové a makro premenné

Tabuľka č.14: Skupiny premenných v jednotlivých modelových datasetoch

Skupina premenných	Logit	EBM	BiLSTM
Identifikátor, rok, target	Áno	Áno	Áno
Surové účtovné položky	Áno	Áno	Nie
Finančné pomerové ukazovatele	Áno	Áno	Áno
Dynamické lag/diff premenné	Nie	Áno	Áno
Nefinančné premenné	Áno	Áno	Áno
Odvetvové indikátorové premenné	Áno	Áno	Áno
Makroekonomické premenné	Áno	Áno	Áno
Technická hodnota −999 pre chýbajúce hodnoty	Nie	Áno	Nie
Sekvenčná štruktúra	Nie	Nie	Áno